

Mémoire présenté le :
pour l'obtention du Diplôme Universitaire d'actuariat de l'ISFA
et l'admission à l'Institut des Actuares

Par : Margot SCHMUTZ

Titre : Rationnalisation du passage du BE déterministe au BE stochastique par des modèles de machine learning

Confidentialité : ☒ NON ☐ (Durée : ☐ 1 an ☐ 2 ans)

Les signataires s'engagent à respecter la confidentialité indiquée ci-dessus

*Membres présents du jury de Signature
l'Institut des Actuares*

Entreprise : FORSIDES

Nom :

Signature :

*Directeur de mémoire en entre-
prise :*

Nom : Daniel ZERBIB

Signature :

*Membres présents du jury de
l'ISFA*

Invité :

Nom :

Signature :

***Autorisation de publication et
de mise en ligne sur un site de
diffusion de documents actua-
riels (après expiration de l'éventuel
délai de confidentialité)***

Signature du responsable entreprise

Signature du candidat

Table des matières

Résumé	4
Abstract	5
Remerciements	6
Synthèse	7
Synthesis	8
Déclaration d'utilisation de l'intelligence artificielle	9
Statement on the Use of Artificial Intelligence	10
Liste des acronymes	11
Introduction	1
1 Cadre prudentiel et réglementaire de la valorisation du Best Estimate	3
1.1 Solvabilité II : principes, objectifs et architecture	3
1.1.1 Une architecture en trois piliers	3
1.1.2 Le ratio de solvabilité et la place du Best Estimate	4
1.2 La valorisation des provisions techniques	5
1.2.1 Une valorisation économique des engagements	5
1.2.2 Définition réglementaire du Best Estimate	5
1.2.3 Flux projetés et hypothèses de calcul	6
1.3 Approches déterministe et stochastique	7
1.3.1 Deux méthodes au service d'un même objectif prudentiel	7
1.3.2 Le Best Estimate déterministe	7
1.3.3 Le Best Estimate stochastique	8
1.3.4 Options, garanties et valeur temps	8
2 Modèle ALM interne et construction de la base de données	10
2.1 Le modèle ALM interne	10
2.1.1 Le générateur de scénarios économiques	11

2.1.2	Fonctionnement de SALLTO	13
2.2	Description du portefeuille étudié	14
2.2.1	Portefeuille d'actifs	15
2.2.2	Portefeuille de passifs	16
2.2.3	Autres hypothèses retenues	20
2.3	Méthodologie de construction de la base de données	22
2.3.1	Objectif de la base de données	22
2.3.2	Définition de la variable cible	22
2.3.3	Principe de construction des observations	23
2.3.4	Études préliminaires de sensibilité	23
2.3.5	Construction de la variable de duration	26
2.3.6	Sélection des variables définitives	26
2.3.7	Amplitude des sensibilités retenues	26
2.3.8	Taille de la base de données	27
2.3.9	Lancement automatisé de SALLTO	27
3	Apports du machine learning pour la rationalisation des écarts	29
3.1	Problématique de régression dans le cadre du Best Estimate	30
3.1.1	Formulation du problème	30
3.1.2	Pourquoi le machine learning est adapté à ce contexte	31
3.1.3	Positionnement par rapport aux approches traditionnelles	33
3.2	Présentation des modèles de machine learning utilisés	34
3.2.1	Modèles de référence	35
3.2.2	Modèles non linéaires	36
3.2.3	Avantages et limites de chaque modèle dans le cadre d'étude	39
3.3	Méthodologie d'apprentissage	41
3.3.1	Séparation des données	41
3.3.2	Contrôle de la complexité et choix des hyperparamètres	45
3.3.3	Diagnostics et validation de l'apprentissage	53
3.4	Critères de performance	57
3.4.1	Indices retenus	57
3.4.2	Comparaison des modèles	59
3.4.3	Lecture des performances	60
4	Analyse des résultats et rationalisation des écarts	62
4.1	Statistiques descriptives des données	62
4.1.1	Statistiques descriptives de la variable cible	62
4.1.2	Statistiques descriptives des variables explicatives	63
4.2	Performance des modèles (test, comparaison GLM / RF / XGBoost, stabilité sur les répétitions)	65
4.2.1	Stabilité sur les 10 répétitions	66
4.2.2	Significativité du gain	67
4.2.3	Lecture des indicateurs	67

4.2.4	Sensibilité au mode de découpage	68
4.3	Explicabilité et hiérarchisation des facteurs d'écart (coefficients du GLM, importances, SHAP, effets non linéaires et interactions)	69
4.3.1	Importance SHAP	71
4.3.2	Interactions SHAP	71
4.3.3	Hiérarchie consolidée des facteurs d'écart	72
4.4	Validation externe sur le second portefeuille central	72
4.5	Analyse de variation entre deux dates de valorisation	72
5	Limites, apports et perspectives	73
5.1	Apports opérationnels et réglementaires	73
5.1.1	Une lecture explicite du passage du Best Estimate déterministe au Best Estimate stochastique	73
5.1.2	Une hiérarchisation des facteurs d'écart confrontée à la lecture actuarielle	74
5.1.3	Un métamodèle mobilisable comme outil exploratoire	74
5.1.4	Un cadre méthodologique reproductible	75
5.2	Limites de l'approche	75
5.2.1	Limites tenant à la construction de la base de données	76
5.2.2	Limites tenant au modèle ALM sous-jacent	77
5.2.3	Limites tenant aux modèles statistiques retenus	78
5.2.4	Limites d'interprétation	78
5.2.5	Limites d'usage et enjeux de gouvernance	79
5.3	Perspectives d'amélioration	79
5.3.1	Faire évoluer le plan d'expérience	79
5.3.2	Réduire le bruit de simulation	81
5.3.3	Élargir la famille de métamodèles	81
5.3.4	Approfondir l'analyse explicative	82
5.3.5	Étendre le périmètre d'application	82
5.3.6	Vers une industrialisation encadrée	83
6	Conclusion	84
	Annexes	85

Résumé

Petit résumé en français de mon mémoire ?

Abstract

It's a brief sum up in english !

Remerciements

Synthèse

Un long résumé en français de mon mémoire

Synthesis

Un long résumé en anglais de mon mémoire

Déclaration d'utilisation de l'intelligence artificielle

L'intelligence artificielle générative a été utilisée de manière ponctuelle au cours de la réalisation de ce mémoire, principalement comme outil d'accompagnement dans certaines étapes du travail.

Des outils tels que ChatGPT et Claude ont été sollicités pour faciliter certaines recherches exploratoires, approfondir la compréhension de notions techniques, confronter des pistes de réflexion ou encore améliorer la formulation et l'organisation de certains développements. Ils ont également été utilisés pour la mise en forme de certains éléments techniques, notamment en $\text{\LaTeX}$, ainsi que pour explorer des références ou des travaux susceptibles d'enrichir la recherche bibliographique.

Ces outils ont par ailleurs constitué une aide à la programmation. Ils ont été mobilisés pour l'écriture et la correction de portions de code relatives à l'apprentissage des modèles de machine learning, à la construction des indicateurs de performance et aux représentations graphiques, ainsi que pour la mise au point des scripts d'automatisation des lancements du modèle ALM. Le code produit avec cette assistance a systématiquement été relu, testé et validé, et la structure des traitements comme les choix d'implémentation relèvent du travail mené dans le cadre de ce mémoire.

Ces outils n'ont toutefois pas constitué une source de données ou de résultats pour l'étude. Les informations, références et éléments bibliographiques retenus ont été vérifiés à partir de documents et de sources fiables. De la même manière, les choix de modélisation, les développements effectués dans l'outil, les calculs, les résultats obtenus et leur analyse relèvent du travail réalisé dans le cadre de ce mémoire.

Statement on the Use of Artificial Intelligence

Generative artificial intelligence tools were used occasionally throughout the preparation of this thesis, mainly as support during certain stages of the work.

Tools such as ChatGPT and Claude were used for exploratory research, to improve the understanding of technical concepts, discuss methodological approaches, and refine the wording and structure of certain sections. They were also used to assist with the formatting of technical elements, particularly in $\text{\LaTeX}$, and to identify potentially relevant references and publications.

These tools further provided assistance with programming. They supported the writing and debugging of parts of the code relating to the training of the machine learning models, the computation of performance metrics and the production of graphical outputs, as well as the development of the scripts automating the ALM model runs. All code produced with such assistance was reviewed, tested and validated, and both the structure of the processing chain and the implementation choices are the result of the work carried out for this thesis.

These tools were not used as a source of data or actuarial results. The information, references and bibliographical sources ultimately retained were checked against reliable original sources. Similarly, the modelling choices, developments implemented in the tool, calculations, numerical results and their interpretation are the result of the work carried out for this thesis.

Liste des acronymes

ALM	<i>Asset-Liability Management</i> (gestion actif-passif)
BE	<i>Best Estimate</i>
GLM	<i>Generalized Linear Model</i> (modèle linéaire généralisé)
GSE	Générateur de Scénarios Économiques
MAE	<i>Mean Absolute Error</i> (erreur absolue moyenne)
MCR	<i>Minimum Capital Requirement</i>
NAV	<i>Net Asset Value</i>
PB	Participation aux Bénéfices
PM	Provisions Mathématiques
PPB	Provision pour Participation aux Bénéfices
PPE	Provision pour Participation aux Excédents
PT	Provisions Techniques
RM	<i>Risk Margin</i> (marge de risque)
RMSE	<i>Root Mean Squared Error</i> (racine de l'erreur quadratique moyenne)
SCR	<i>Solvency Capital Requirement</i>
SHAP	<i>SHapley Additive exPlanations</i>
TMG	Taux Minimum Garanti
TVOG	<i>Time Value of Options and Guarantees</i>
UC	Unités de Compte

Introduction

Dans un contexte réglementaire exigeant et en constante évolution, les organismes d'assurance doivent être en mesure de valoriser leurs engagements de manière fiable, tout en assurant la compréhension et la traçabilité des résultats produits. Depuis l'entrée en vigueur de la directive Solvabilité II, le calcul des provisions techniques repose sur une approche économique tenant compte des conditions de marché. Le Best Estimate occupe une place centrale dans cette valorisation puisqu'il correspond à l'estimation des flux futurs liés aux engagements d'assurance.

En assurance vie, le calcul du Best Estimate peut être réalisé à partir d'une approche déterministe ou d'une approche stochastique. L'approche déterministe repose sur une projection fondée sur un scénario économique central. Elle présente l'avantage d'être plus rapide à mettre en œuvre et facilite l'analyse des résultats. L'approche stochastique repose, quant à elle, sur un ensemble de scénarios économiques permettant de prendre en compte l'incertitude liée aux évolutions des marchés financiers.

Cette seconde approche permet notamment de mieux intégrer les effets liés aux options et garanties présentes dans les contrats d'assurance vie. Elle est cependant plus complexe à mettre en œuvre et nécessite des temps de calcul plus importants.

Les résultats obtenus à partir des approches déterministe et stochastique peuvent donc présenter des différences. Ces écarts dépendent à la fois de l'environnement économique, des caractéristiques du portefeuille et des hypothèses utilisées dans le modèle. Leur compréhension constitue un enjeu important, car elle permet de mieux analyser les résultats produits et de renforcer leur justification dans un cadre réglementaire.

L'objectif de ce mémoire est ainsi de rationaliser le passage du Best Estimate déterministe au Best Estimate stochastique. Il ne s'agit pas de remplacer le calcul stochastique, mais de mieux comprendre les facteurs expliquant les différences observées entre les deux méthodes de valorisation. Une attention particulière est portée à l'identification des variables ayant le plus d'influence sur ces écarts.

Pour répondre à cette problématique, une base de données est construite à partir des résultats d'un modèle ALM interne. Différentes hypothèses économiques et contractuelles sont modifiées de manière contrôlée afin de créer plusieurs configurations de portefeuille. Pour chacune de ces configurations, un Best Estimate déterministe et un Best Estimate stochastique sont calculés.

Dans le cadre de ce mémoire, nous aurons recours à plusieurs modèles de machine learning afin d'évaluer leur capacité à reproduire et à expliquer l'écart entre le Best Estimate déterministe et le Best Estimate stochastique. L'objectif n'est pas uniquement d'obtenir de bonnes performances prédictives. Il est

également nécessaire de comprendre le fonctionnement des modèles et d'identifier les variables les plus significatives.

Le mémoire est organisé en plusieurs parties. La première partie présente le cadre réglementaire de Solvabilité II et les principes de calcul du Best Estimate. La deuxième partie décrit le modèle ALM interne utilisé ainsi que la méthodologie de construction de la base de données. La troisième partie présente les modèles de machine learning retenus et la méthodologie d'apprentissage. La quatrième partie est consacrée à l'analyse des résultats et à l'identification des principaux facteurs expliquant les écarts observés. Enfin, la dernière partie présente les limites de l'étude ainsi que les perspectives d'amélioration possibles.

Le mémoire est organisé en cinq parties. La première partie présente le cadre réglementaire de Solvabilité II et les principes de calcul du Best Estimate. La deuxième partie décrit le modèle ALM interne utilisé ainsi que la méthodologie de construction de la base de données. La troisième partie présente les modèles de machine learning retenus et la méthodologie d'apprentissage. La quatrième partie est consacrée à l'analyse des résultats et à l'identification des principaux facteurs expliquant les écarts observés ; la robustesse des modèles y fait l'objet d'une double validation, d'une part sur une seconde base de données construite à partir d'un jeu d'hypothèses distinct, d'autre part au travers une analyse de variation visant à vérifier leur capacité à reproduire l'évolution de l'écart entre deux dates de valorisation du portefeuille. Enfin, la dernière partie présente les limites de l'étude ainsi que les perspectives d'amélioration possibles.

Chapitre 1

Cadre prudentiel et réglementaire de la valorisation du Best Estimate

1.1 Solvabilité II : principes, objectifs et architecture

1.1.1 Une architecture en trois piliers

Le cadre Solvabilité II est organisé autour de trois piliers complémentaires mais seul le pilier 1 sera abordé dans ce mémoire.




FIGURE 1.1 – Architecture de Solvabilité II et place du Best Estimate dans le pilier 1

Le **pilier 1** regroupe les exigences quantitatives. Il définit les règles de valorisation de l'actif et du passif, le calcul des provisions techniques, la détermination des fonds propres ainsi que les exigences de capital. Deux niveaux de capital sont notamment distingués : le *Solvency Capital Requirement* (SCR) et le *Minimum Capital Requirement* (MCR). Le *Best Estimate* étudié dans ce mémoire relève directement de ce premier pilier.

1.1.2 Le ratio de solvabilité et la place du Best Estimate

Les organismes d'assurance doivent détenir des fonds propres éligibles suffisants pour couvrir leur SCR. Le ratio de couverture du SCR, couramment appelé ratio de solvabilité, s'écrit :

$$\text{Ratio de solvabilité} = \frac{\text{Fonds propres éligibles au SCR}}{\text{SCR}}$$

Un ratio égal à 100 % signifie que les fonds propres éligibles sont exactement égaux au capital requis. Le SCR est calibré afin de correspondre à une valeur en risque des fonds propres de base avec un niveau de confiance de 99,5 % sur un horizon d'un an.

Le *Best Estimate* intervient principalement au numérateur de ce ratio, par l'intermédiaire du bilan économique. Toutes choses égales par ailleurs, une hausse du *Best Estimate* augmente les provisions techniques, réduit l'excédent des actifs sur les passifs et diminue ainsi les fonds propres de base. Sa valorisation peut également influencer certains modules du SCR et les mécanismes d'absorption des pertes par les provisions techniques. La maîtrise de son niveau et de sa sensibilité constitue donc un enjeu de pilotage prudentiel, même lorsque l'objet de l'étude n'est pas directement la prédiction du ratio de solvabilité.




FIGURE 1.2 – Effet d'un choc de souscription sur le bilan économique

Le schéma illustre le mécanisme par lequel le Best Estimate agit sur les exigences de capital. Le total du bilan étant fixé par la valeur de marché de l'actif, les fonds propres de base en constituent le solde. Lorsqu'un choc réglementaire fait augmenter le Best Estimate sans affecter l'actif, les fonds propres diminuent d'un montant équivalent : cette variation correspond au SCR du module considéré. Le niveau du Best Estimate, mais aussi sa sensibilité aux hypothèses, conditionnent donc directement l'exigence de capital. A noter que la marge de risque n'est pas représentée, et l'hypothèse d'un actif inchangé ne vaut que pour les chocs de souscription.

1.2 La valorisation des provisions techniques

1.2.1 Une valorisation économique des engagements

L'article 76 de la directive Solvabilité II prévoit que la valeur des provisions techniques corresponde au montant actuel qu'une société d'assurance devrait payer si elle transférait immédiatement ses engagements à une autre entreprise. Leur calcul doit être cohérent avec les informations fournies par les marchés financiers, prudent, fiable et objectif.

La valeur des provisions techniques est égale à la somme du *Best Estimate* et de la marge de risque :

$$PT = BE + RM,$$

où PT désigne les provisions techniques, BE le *Best Estimate* et RM la marge de risque. Ces deux composantes font en principe l'objet d'une évaluation séparée. Cette séparation n'est toutefois pas requise lorsque les flux de trésorerie futurs associés aux engagements peuvent être répliqués de manière fiable au moyen d'instruments financiers pour lesquels il existe une valeur de marché fiable et observable ; la valeur des provisions techniques est alors déterminée directement à partir de la valeur de marché de ces instruments.

Le *Best Estimate* représente la valeur actualisée moyenne des flux futurs nécessaires au règlement des engagements. La marge de risque correspond au coût du capital qu'une entreprise de référence devrait supporter pour reprendre et honorer ces engagements jusqu'à leur extinction.

1.2.2 Définition réglementaire du Best Estimate

L'article 77, paragraphe 2, de la directive définit le *Best Estimate* comme la moyenne pondérée par leur probabilité des flux de trésorerie futurs, compte tenu de la valeur temporelle de l'argent, estimée sur la base de la courbe des taux sans risque pertinents. Il peut être représenté par :

$$BE = \mathbb{E} \left[\sum_{t=1}^T D(0, t) CF_t \right],$$

où CF_t désigne le flux net associé aux engagements à la date t , $D(0, t)$ le facteur d'actualisation entre la date de valorisation et la date t , et T l'horizon d'extinction du portefeuille. Le facteur d'actualisation est déterminé à partir de la courbe des taux sans risque pertinents. Dans une projection déterministe, il s'écrit $D(0, t) = (1 + r_t)^{-t}$, où r_t désigne le taux zéro-coupon de maturité t . Dans une projection stochastique, il dépend de la trajectoire des taux courts propre à chaque scénario.

Cette écriture met en évidence trois dimensions essentielles. Le calcul est prospectif, puisqu'il repose sur les flux futurs et non uniquement sur des données passées. Il est actualisé, afin de prendre en compte la valeur temporelle de l'argent. Enfin, il est probabilisé, car il doit intégrer la distribution des résultats futurs et pas seulement une trajectoire centrale lorsque celle-ci ne suffit pas à représenter les risques.

La directive encadre également les conditions de ce calcul. Celui-ci s'appuie sur des informations actualisées et crédibles, sur des hypothèses réalistes et sur des méthodes actuarielles et statistiques pertinentes. Son périmètre est étendu : la projection intègre l'ensemble des encaissements et des décaissements nécessaires au règlement des engagements sur toute leur durée. Enfin, le *Best Estimate* est déterminé brut de réassurance : les montants recouvrables au titre des traités sont évalués séparément, à l'actif du bilan, conformément à l'article 81 de la directive.

1.2.3 Flux projetés et hypothèses de calcul

Le règlement délégué (UE) 2015/35 précise les principes de projection des flux utilisés pour déterminer le *Best Estimate*. Ceux-ci comprennent notamment les prestations dues aux assurés et aux bénéficiaires, les primes futures incluses dans la frontière des contrats, les frais nécessaires à la gestion des engagements et les paiements liés aux options contractuelles.

Les hypothèses utilisées doivent représenter de manière cohérente les facteurs susceptibles d'affecter les flux futurs. Dans le cas d'un portefeuille d'assurance vie, elles portent notamment sur :

- la mortalité et la longévité ;
- les rachats et les autres comportements des assurés ;
- les frais futurs ;
- les rendements financiers et l'évolution des actifs ;
- les garanties contractuelles ;
- la participation future aux bénéfices ;
- les actions futures de management.

Les actions futures de management peuvent notamment concerner l'allocation d'actifs, la réalisation de plus-values latentes ou la politique de revalorisation des contrats. Elles doivent être réalistes, cohérentes avec les pratiques de l'entreprise et approuvées par son organe de direction.

Les hypothèses de comportement des assurés doivent également intégrer les rachats conjoncturels, qui traduisent notamment leur réaction à l'écart entre le taux servi par le contrat et les rendements proposés par d'autres placements.

Enfin, l'article 82 de la directive impose que les données utilisées soient appropriées, complètes et exactes. Le recours à des approximations demeure possible lorsque les données sont insuffisantes, mais il doit être

justifié et ne pas résulter de défaillances des processus internes de collecte ou de validation.

1.3 Approches déterministe et stochastique

1.3.1 Deux méthodes au service d'un même objectif prudentiel

La réglementation impose le calcul d'une meilleure estimation probabilisée ; elle n'érige pas le *Best Estimate* déterministe et le *Best Estimate* stochastique en deux mesures prudentielles concurrentes. Le choix de la méthode relève du principe de proportionnalité : il doit être adapté à la nature, à l'ampleur et à la complexité des risques affectant les flux. Le règlement délégué impose en outre que le calcul, la méthodologie et les hypothèses retenues soient documentés de manière transparente et suffisamment détaillée pour qu'un expert qualifié puisse reproduire le calcul et en apprécier la conformité.

Une méthode déterministe peut être pertinente lorsque les flux dépendent de manière approximativement linéaire des variables économiques. Dans ce cas, la projection du scénario central fournit une approximation acceptable de la moyenne des scénarios. Dès qu'une convexité apparaît, en présence d'un taux minimum garanti, d'une participation aux bénéfices ou d'options de rachat, la valeur moyenne des flux diffère de leur valeur dans le scénario moyen et une méthode stochastique devient nécessaire. Il en va de même lorsque les actions de gestion dépendent de la trajectoire suivie par les marchés. En épargne euro, l'approche déterministe ne constitue donc pas une valorisation prudentielle acceptable ; elle est utilisée comme outil d'analyse et comme point de comparaison, ce qui correspond à l'usage retenu dans ce mémoire.

1.3.2 Le Best Estimate déterministe

Le *Best Estimate* déterministe est obtenu en projetant le portefeuille selon une trajectoire économique unique, généralement construite à partir d'hypothèses centrales. Il peut être représenté de manière simplifiée par :

$$BE_{\text{det}} = \sum_{t=1}^T D^{\text{det}}(0, t) CF_t^{\text{det}}.$$

Cette méthode permet une lecture directe de l'évolution du portefeuille et se prête facilement aux analyses de sensibilité. Son coût de calcul est limité, puisqu'une seule trajectoire est projetée. Elle fournit ainsi un point de comparaison utile et peut synthétiser une part importante des caractéristiques du portefeuille.

Sa principale limite provient de l'utilisation d'un scénario unique. La projection du scénario moyen ne restitue alors pas nécessairement la moyenne des valeurs obtenues dans l'ensemble des scénarios.

1.3.3 Le Best Estimate stochastique

L'approche stochastique repose sur un ensemble de scénarios économiques représentant différentes évolutions possibles des variables financières. Pour chaque scénario, le modèle ALM projette les actifs, les passifs, les décisions de gestion et les comportements des assurés. Le *Best Estimate* stochastique est ensuite estimé par la moyenne des valeurs actualisées :

$$\widehat{BE}_{sto} = \frac{1}{N} \sum_{n=1}^N \left[\sum_{t=1}^T D^{(n)}(0, t) CF_t^{(n)} \right],$$

où N désigne le nombre de scénarios économiques.

Cette approche permet de représenter les interactions entre les variables financières et les mécanismes propres aux contrats. Elle tient notamment compte du fait qu'une garantie produit un coût dans les scénarios défavorables sans que l'assureur bénéficie nécessairement de manière symétrique des scénarios favorables. Elle permet également de modéliser les politiques de participation aux bénéfices, les réalisations de plus-values, les arbitrages d'allocation et les rachats dynamiques.

Ces mécanismes sont également représentés dans une projection déterministe, puisque le modèle applique les mêmes règles de gestion le long du scénario central. L'apport de l'approche stochastique tient à la valorisation de leur effet sur l'ensemble des trajectoires : la politique de participation aux bénéfices, la réalisation de plus-values latentes, les arbitrages d'allocation et les rachats dynamiques s'activent de manière asymétrique selon l'environnement financier simulé. Un scénario unique n'en restitue que la valeur intrinsèque, tandis que la moyenne des scénarios intègre en outre leur valeur temps.

Le calcul est donc plus complexe, mais également plus coûteux et plus difficile à analyser qu'une projection déterministe.

1.3.4 Options, garanties et valeur temps

Le règlement délégué impose de prendre en compte toutes les garanties financières et options contractuelles incluses dans les contrats, ainsi que les facteurs susceptibles d'influencer leur exercice par les assurés. Pour un portefeuille d'assurance vie, il peut notamment s'agir :

- d'un taux minimum garanti ;
- d'un mécanisme de participation aux bénéfices ;
- d'une garantie en capital ;
- d'une option de rachat ;
- d'un arbitrage entre supports ;
- d'une option de conversion ou de prorogation.

La valeur intrinsèque d'une garantie correspond à son coût dans la situation économique observée à la date de valorisation. Sa valeur temps traduit le coût supplémentaire lié à l'incertitude sur les évolutions futures et à la possibilité que la garantie devienne plus contraignante dans certains scénarios. Dans le

cadre opérationnel retenu dans ce mémoire, la TVOG est approchée par la différence :

$$TVOG = BE_{sto} - BE_{det}.$$

Cette définition doit être comprise dans le périmètre et avec les conventions du modèle utilisé. Elle dépend notamment du scénario déterministe de référence, des règles de participation aux bénéfices et des actions de management modélisées. L'écart ne constitue donc pas une constante propre au portefeuille : il varie avec l'environnement économique, les caractéristiques des contrats et la politique de gestion de l'assureur.

La valeur temps des options et garanties ne constitue donc pas une caractéristique fixe du portefeuille. Elle dépend de l'environnement financier, des caractéristiques des contrats et de la politique de gestion de l'assureur, autant de facteurs dont les effets se combinent de manière non linéaire. Comprendre l'écart entre les deux valorisations suppose dès lors de disposer d'un outil permettant de faire varier ces facteurs de manière contrôlée et d'en observer les effets conjoints.

Chapitre 2

Modèle ALM interne et construction de la base de données

Le chapitre précédent a montré que l'écart entre le *Best Estimate* déterministe et le *Best Estimate* stochastique traduit la valeur temps des options et garanties contenues dans les contrats. Cet écart n'est pas une caractéristique fixe du portefeuille : il dépend de l'environnement financier, des hypothèses contractuelles et des règles de gestion appliquées par l'assureur.

L'objectif est désormais de mesurer cet écart de manière systématique. Cela suppose de disposer d'un outil de projection capable de reproduire le fonctionnement d'un portefeuille d'épargne dans ses deux modes de valorisation, puis de faire varier de façon contrôlée les hypothèses susceptibles d'influencer le résultat.

La démarche retenue repose sur un modèle ALM interne. Un portefeuille central est d'abord défini et projeté selon les deux approches, fournissant un niveau de référence. Différentes sensibilités sont ensuite appliquées à ce portefeuille, chaque configuration donnant lieu à un calcul complet du *Best Estimate* déterministe et du *Best Estimate* stochastique.

Ce chapitre présente successivement le modèle utilisé et son générateur de scénarios économiques, les caractéristiques du portefeuille central, puis la sélection des variables et la construction de la base de données exploitée au chapitre suivant.

2.1 Le modèle ALM interne

Dans le cadre de cette étude, les différentes valorisations du *Best Estimate* sont obtenues à l'aide du modèle ALM interne de Forsides, appelé SALLTO (*Solvency Assets Liabilities Life TOol*). Développé en interne en C#, cet outil permet de projeter dans le temps l'évolution d'une compagnie d'assurance vie en modélisant conjointement son actif et son passif ainsi que les interactions entre ces deux composantes.

L'intérêt d'une telle approche est de représenter les mécanismes propres à l'assurance vie, pour lesquels

l'évolution du passif dépend directement de la situation financière de l'assureur. Les conditions économiques influencent en effet la valeur et le rendement des actifs, mais également les décisions de gestion de l'assureur, telles que le niveau de participation aux bénéfices servi, la réalisation de plus-values ou encore les réallocations d'actifs. Ces décisions peuvent à leur tour modifier le comportement des assurés, notamment en matière de rachats.

SALLTO permet ainsi de projeter les flux, les bilans et les comptes de résultat d'une compagnie d'assurance vie jusqu'à l'extinction du portefeuille. Les projections peuvent être réalisées de manière déterministe ou stochastique, selon la nature des scénarios économiques utilisés.

Le modèle est alimenté par plusieurs catégories de données et d'hypothèses :

- les caractéristiques du portefeuille d'actifs ;
- les caractéristiques du portefeuille de passifs ;
- les hypothèses de comportement des assurés, notamment les rachats ;
- les tables de mortalité ;
- les règles de gestion de l'assureur ;
- les scénarios économiques utilisés pour faire évoluer les différentes variables financières.

Les scénarios économiques sont produits indépendamment de SALLTO par le Générateur de Scénarios Économiques (GSE) développé par Forsides. Ils sont ensuite fournis au modèle ALM afin de faire évoluer l'environnement financier au cours de la projection.

Cette articulation entre le GSE et SALLTO est particulièrement importante dans le cadre de ce mémoire. Pour une même configuration initiale du portefeuille, une projection déterministe permet d'obtenir le BE_{det} , tandis qu'une projection sur un ensemble de scénarios stochastiques permet d'obtenir le BE_{sto} . L'étude de l'écart entre ces deux valorisations repose donc directement sur le fonctionnement conjoint de ces deux outils.

2.1.1 Le générateur de scénarios économiques

Un Générateur de Scénarios Économiques (GSE) a pour objectif de simuler l'évolution future des principales variables économiques et financières susceptibles d'affecter le portefeuille d'un assureur. Le GSE développé par Forsides génère notamment des trajectoires pour :

- les taux d'intérêt nominaux et réels ;
- les marchés actions ;
- l'immobilier ;
- l'inflation ;
- les spreads de crédit.

Ces variables étant liées entre elles, le GSE permet de générer des trajectoires économiques cohérentes sur l'ensemble de l'horizon de projection. Ces trajectoires sont ensuite utilisées dans SALLTO pour déterminer, scénario par scénario, l'évolution des actifs et des passifs ainsi que les actions de management qui en découlent.

Deux cadres de projection peuvent être distingués : le *monde réel* et l'univers *risque neutre*. Dans une projection en monde réel, les distributions des variables économiques cherchent à reproduire les évolutions susceptibles d'être effectivement observées. Le calibrage peut alors reposer sur des données historiques, des anticipations de marché ou des hypothèses à dire d'experts. Ce type de projection est notamment adapté aux études prospectives et aux analyses de risque.

Dans un univers risque neutre, utilisé pour les valorisations économiques sous Solvabilité II, les scénarios doivent être *Market Consistent*, c'est-à-dire cohérents avec les prix des instruments financiers observés à la date de valorisation. Sous la probabilité risque neutre $\mathbb{Q}$, les actifs actualisés sont des martingales. Pour un actif de valeur actualisée $\tilde{S}_t$, cette propriété s'écrit :

$$\mathbb{E}^{\mathbb{Q}} \left[\tilde{S}_T \right] = S_0. \quad (2.1)$$

Ainsi, le rendement espéré d'un actif risqué ne comporte plus de prime de risque : après actualisation, son espérance est égale à sa valeur initiale. Cette propriété permet notamment d'obtenir, par simulation de Monte-Carlo, une valorisation cohérente avec les prix de marché.

Dans le cadre du GSE utilisé, les différentes classes d'actifs reposent sur des modèles stochastiques adaptés à leur dynamique.

Modélisation des taux d'intérêt

Les taux d'intérêt sont modélisés à l'aide du modèle de Hull–White à un facteur, extension du modèle de Vasicek. La dynamique du taux court r_t s'écrit :

$$dr_t = (\theta(t) - ar_t) dt + \sigma_r dW_t, \quad (2.2)$$

où :

- r_t représente le taux court à la date t ;
- a représente la vitesse de retour à la moyenne ;
- σ_r représente la volatilité des taux ;
- $\theta(t)$ est une fonction déterministe permettant d'ajuster le modèle à la courbe des taux observée à la date initiale ;
- W_t est un mouvement brownien.

L'un des principaux intérêts du modèle de Hull–White est sa capacité à reproduire la courbe des taux initiale tout en conservant une formulation suffisamment simple pour permettre son calibrage sur des instruments de marché, notamment des swaptions. Il autorise par ailleurs l'apparition de taux négatifs, propriété utile pour représenter un spectre suffisamment large d'environnements économiques.

Modélisation des actions et de l'immobilier

Les indices actions et immobiliers sont modélisés selon une dynamique de type Black–Scholes. Pour un indice S_t , celle-ci peut s'écrire :

$$\frac{dS_t}{S_t} = \mu dt + \sigma_S dW_t, \quad (2.3)$$

où μ représente la tendance de l'indice, σ_S sa volatilité et W_t un mouvement brownien.

La solution de cette équation peut notamment s'écrire, sur un pas de temps Δt :

$$S_{t+\Delta t} = S_t \exp \left[\left(\mu - \frac{\sigma_S^2}{2} \right) \Delta t + \sigma_S \sqrt{\Delta t} Z \right], \quad Z \sim \mathcal{N}(0, 1). \quad (2.4)$$

Dans un cadre risque neutre, la dérive est déterminée de manière à respecter la cohérence avec les prix de marché. Les volatilités sont quant à elles calibrées à partir de données observées sur les marchés financiers.

Dans le cadre de ce mémoire, le GSE intervient directement dans la construction de la base de données. La courbe des taux ainsi que certains paramètres de volatilité sont modifiés afin de créer différents environnements économiques. Pour chaque paramétrage, les scénarios correspondants sont ensuite transmis à SALLTO afin de réaliser les projections déterministes et stochastiques.

2.1.2 Fonctionnement de SALLTO

Une fois les hypothèses initiales et les scénarios économiques renseignés, SALLTO projette conjointement l'actif et le passif du portefeuille. Le pas de projection est annuel et les différentes opérations sont répétées jusqu'à la fin de l'horizon de projection.

À la date initiale, le modèle est alimenté par la situation du portefeuille à la date de valorisation : bilan, provisions mathématiques, caractéristiques des contrats et portefeuille d'actifs. À chaque pas de temps, le modèle réalise ensuite successivement les principales opérations suivantes :

1. **Vieillessement des actifs.** Les différents actifs évoluent en fonction de leur nature et des trajectoires fournies par le GSE. Les obligations génèrent leurs coupons, sont amorties et éventuellement remboursées à maturité, tandis que la valeur des actifs non amortissables, notamment les actions et l'immobilier, évolue selon les indices économiques simulés.
2. **Vieillessement des passifs.** Les contrats sont projetés d'une année en tenant compte notamment des décès, des arrivées à terme, des rachats, des frais et chargements ainsi que de l'évolution de l'âge et de l'ancienneté des assurés.
3. **Calcul des besoins de trésorerie et opérations sur actifs.** Les encaissements et décaissements générés par l'actif et le passif sont confrontés afin de déterminer le solde de trésorerie. Lorsque cela est nécessaire, des actifs peuvent être cédés. La trésorerie disponible est ensuite réinvestie en fonction de l'allocation stratégique définie dans les règles de gestion.
4. **Mise à jour des mécanismes comptables et financiers.** Les cessions obligataires peuvent notamment conduire à une dotation ou une reprise de la réserve de capitalisation. Les plus ou moins-values réalisées et latentes sont également prises en compte dans la richesse disponible de l'assureur.

5. **Détermination de la participation aux bénéfices.** Le modèle détermine le taux de revalorisation cible puis les ressources permettant de le servir. La Provision pour Participation aux Bénéfices (PPB) peut être reprise ou dotée en fonction de la situation financière de l'assureur.
6. **Application des actions de management.** Si les ressources disponibles ne permettent pas d'atteindre le taux cible, le modèle peut mettre en œuvre les actions de gestion prévues dans le paramétrage, par exemple la réalisation de plus-values latentes. Le taux effectivement servi peut ainsi différer du taux cible lorsque les ressources disponibles sont insuffisantes.
7. **Revalorisation des contrats et calcul des flux.** Les contrats sont revalorisés à partir du taux servi. Les différents flux d'actif et de passif sont alors déterminés et le bilan est mis à jour pour l'année suivante.

Ce mécanisme est répété pour l'ensemble des années de projection et, dans le cas stochastique, pour chacun des scénarios économiques considérés. Le modèle permet ainsi de représenter les interactions successives entre environnement économique, richesse de l'assureur, décisions de gestion et comportement des assurés.

La différence entre les valorisations déterministe et stochastique utilisées dans ce mémoire intervient essentiellement dans les scénarios économiques alimentant cette chaîne de projection. Dans le cas déterministe, une trajectoire économique unique est utilisée. Dans le cas stochastique, SALLTO reproduit cette même mécanique sur un grand nombre de trajectoires issues du GSE. Le *Best Estimate* stochastique est alors obtenu par agrégation des flux actualisés obtenus sur l'ensemble des scénarios.

Cette répétition du modèle ALM pour un grand nombre de scénarios explique également le coût calculatoire nettement supérieur de la valorisation stochastique. Cet écart de complexité constitue précisément l'un des éléments à l'origine de la problématique étudiée dans ce mémoire : déterminer dans quelle mesure l'information issue d'une projection déterministe, combinée aux caractéristiques économiques et contractuelles du portefeuille, permet de reproduire et d'expliquer le résultat obtenu à partir de la projection stochastique.

2.2 Description du portefeuille étudié

La construction de la base de données nécessaire à l'étude repose sur la définition préalable d'un portefeuille central, à partir duquel seront réalisées les différentes sensibilités présentées par la suite.

Le portefeuille retenu est un portefeuille fictif, valorisé au 31 décembre 2025. Il a été construit à partir de données de marché et d'hypothèses représentatives des caractéristiques généralement observées au sein des portefeuilles d'assureurs vie. L'objectif n'est donc pas de reproduire le bilan d'un assureur particulier, mais de disposer d'un portefeuille de référence cohérent avec les pratiques du marché et suffisamment représentatif pour les besoins de l'étude.

Ce portefeuille constitue le point de départ de l'ensemble des projections réalisées dans la suite du mémoire. Les résultats obtenus, et en particulier la relation mise en évidence entre le Best Estimate déterministe et le Best Estimate stochastique, restent ainsi conditionnés aux caractéristiques du portefeuille

central retenu. Cette dépendance devra être prise en compte dans l'interprétation des résultats.

2.2.1 Portefeuille d'actifs

Le portefeuille décrit dans cette section correspond aux actifs en représentation des engagements du fonds euro. Les supports en unités de compte n'y figurent pas : le risque financier étant supporté par l'assuré, ils sont adossés directement aux actifs correspondants et ne relèvent pas de la politique d'allocation de l'assureur. Sa valeur nette comptable (VNC) totale s'élève à 116 millions d'euros au 31 décembre 2025, tandis que sa valeur de marché atteint 113,39 millions d'euros.

L'allocation a été définie de manière à reproduire la structure d'un portefeuille d'actifs représentatif d'un assureur vie. En VNC, elle se compose de 80 % d'obligations à taux fixe, 10 % d'actions globales non long terme, 7 % d'immobilier et 3 % d'actifs monétaires.




FIGURE 2.1 – Allocation d'actif

Les différentes classes d'actifs présentent des niveaux de plus ou moins-values latentes distincts. Les actions présentent ainsi une plus-value latente de 30 % et l'immobilier de 10 %, tandis que la poche obligataire présente une moins-value latente de 7 %. Compte tenu du poids prépondérant des obligations dans l'allocation, le portefeuille présente globalement une légère moins-value latente, de l'ordre de 2 %.

La poche obligataire représente 80 % de la VNC totale du portefeuille d'actifs et constitue ainsi sa principale composante. Elle est composée à 60 % d'obligations souveraines et à 40 % d'obligations corporate. Le portefeuille obligataire présente un rating moyen de A.

Le spread moyen du portefeuille central est de 0,85 %, tandis que la duration moyenne de l'actif s'établit à 6,75. Ces caractéristiques permettent de définir l'exposition initiale du portefeuille aux principaux facteurs de risque de marché, avant application des différentes sensibilités considérées dans la suite de l'étude.

Valorisation au 31/12/2025




FIGURE 2.2 – Détail de la partie actif du portefeuille central

2.2.2 Portefeuille de passifs

Le portefeuille de passifs a également été construit afin de reproduire les principales caractéristiques d'un portefeuille moyen d'assurance vie. Il est constitué d'un encours total de provisions mathématiques (PM) de 145 millions d'euros, réparti entre 100 millions d'euros de PM euro et 45 millions d'euros de PM en unités de compte (UC). Les supports euro représentent ainsi environ 69 % des PM totales, contre 31 % pour les UC.

Afin de limiter les temps de calcul liés aux projections stochastiques, une hypothèse simplificatrice a été retenue concernant la segmentation du portefeuille. Le passif est représenté par seulement 10 model points, dont 5 associés au fonds euro et 5 aux UC. Cette réduction du nombre de model points permet d'alléger significativement les calculs tout en conservant une segmentation du portefeuille adaptée aux objectifs de l'étude.

L'âge moyen (pondéré à la PM) des assurés du portefeuille central est de 63 ans. Les frais de gestion sur encours sont fixés à 0,40 % et le taux de chargement à 0,80 %. Ces hypothèses sont identiques pour l'ensemble des model points.

Le Taux Minimum Garanti (TMG) varie en revanche selon les model points du fonds euro. Le TMG

moyen, pondéré par les PM du fonds euro, s'établit à 0,29 %. Les contrats en UC ne présentent quant à eux aucun TMG. Les caractéristiques détaillées des différents model points, et notamment les niveaux de TMG associés, sont présentées dans le tableau ci-dessous.

Model point	Âge moyen	Part de la PM globale		TMG
Fonds euro — 68 % de la PM globale				
MP 1	55 ans		10 %	0 %
MP 2	60 ans		31 %	0 %
MP 3	65 ans		10 %	0,50 %
MP 4	70 ans		10 %	0,75 %
MP 5	75 ans		7 %	1,00 %
Unités de compte — 32 % de la PM globale				
MP 6	55 ans		5 %	—
MP 7	60 ans		14 %	—
MP 8	65 ans		5 %	—
MP 9	70 ans		5 %	—
MP 10	75 ans		3 %	—

FIGURE 2.3 – Détail des model points du portefeuille central

Le taux servi retenu pour le portefeuille central est de 2,40 %. Le taux de participation aux bénéfices (PB) est fixé à 85 %.

Les rachats des assurés sont décomposés en rachats structurels et en rachats conjoncturels, ou rachats dynamiques. Les rachats structurels correspondent à un taux de 5 %, réparti entre 2 % de rachats totaux et 3 % de rachats partiels. Les rachats conjoncturels, qui permettent de prendre en compte l'évolution du comportement des assurés en fonction de l'environnement économique, sont paramétrés selon le niveau « dynamique moyenne » de SALLTO.

Enfin, la mortalité du portefeuille est modélisée à partir de la table TH0002 et la duration du passif du portefeuille central s'établit à 10,20.

Provisions mathématiques totales — 145 M€ au 31/12/2025

Fonds euro — 100 M€ (69 %)

UC — 45 M€ (31 %)

Contrats et frais		Portefeuille et rachats	
TMG moyen (fonds euro)	0,29 %	Nombre de model points	10
Taux servi	2,40 %	Âge moyen des assurés	63 ans
Frais de gestion sur encours	0,40 %	Rachats structurels totaux	2 %
Taux de chargement	0,80 %	Rachats structurels partiels	3 %
Duration du passif	10,20	Rachats conjoncturels	Dynamique moyenne

FIGURE 2.4 – Détail du passif du portefeuille central

La loi de rachat conjoncturel. Les rachats conjoncturels ne portent pas sur le niveau absolu des rachats, mais sur un supplément — ou une réduction — appliqué au taux de rachat structurel en fonction de l'insatisfaction de l'assuré. SALLTO retient la forme fonctionnelle issue des Orientations Nationales Complémentaires accompagnant l'exercice QIS5, devenue une référence de place.

Soit R le taux servi au titre de l'exercice et TA le taux attendu par l'assuré, approximé par un taux de marché de référence. L'écart $x = R - TA$ constitue la variable d'entrée de la loi. Le taux de rachat conjoncturel s'écrit comme une fonction affine par morceaux :

$$RC(x) = \begin{cases} RC_{\max} & \text{si } x < \alpha, \\ RC_{\max} \frac{x - \beta}{\alpha - \beta} & \text{si } \alpha \leq x < \beta, \\ 0 & \text{si } \beta \leq x \leq \gamma, \\ RC_{\min} \frac{x - \gamma}{\delta - \gamma} & \text{si } \gamma < x \leq \delta, \\ RC_{\min} & \text{si } x > \delta. \end{cases} \quad (2.5)$$

Le taux de rachat total appliqué au *model point* vaut alors $\min(\max(RS + RC(x), 0), 1)$, où RS désigne le taux de rachat structurel.

Les paramètres s'interprètent de la manière suivante :

- β et γ délimitent une zone d'indifférence : tant que l'écart de taux y demeure, le comportement de l'assuré n'est pas modifié et seuls les rachats structurels s'appliquent ;
- α constitue le seuil de saturation à la baisse. En deçà, la rémunération est jugée durablement insuffisante et le supplément de rachat atteint son maximum $RC_{\max}$;

- δ constitue le seuil de saturation à la hausse. Au-delà, la rémunération est jugée suffisamment attractive pour que la réduction des rachats atteigne son plancher $RC_{\min}$, valeur négative traduisant une fidélisation de l'assuré ;
- entre ces seuils, la transition est linéaire.

Les Orientations Nationales Complémentaires ne prescrivent pas un jeu de paramètres unique, mais un intervalle de valeurs plausibles à l'intérieur duquel l'organisme doit justifier sa calibration. Les trois niveaux disponibles dans SALLTO en constituent les bornes et le point médian ; ils sont représentés à la figure 2.5 et reportés au tableau 2.1¹.




FIGURE 2.5 – Loi de rachat conjoncturel selon les trois calibrations retenues

Calibration	α	β	γ	δ	$RC_{\min}$	$RC_{\max}$
Dynamique minimale	-6 %	-2 %	1 %	2 %	-6 %	20 %
Dynamique moyenne	-5 %	-1 %	1 %	3 %	-5 %	30 %
Dynamique maximale	-4 %	0 %	1 %	4 %	-4 %	40 %

TABLE 2.1 – Paramètres des trois calibrations de la loi de rachat conjoncturel

L'asymétrie de la loi confère à l'option de rachat une valeur temps : elle se déclenche dans les scénarios défavorables sans que l'assureur bénéficie d'un gain symétrique dans les scénarios favorables. L'écart entre les trois calibrations est par ailleurs considérable. Pour un écart de taux de -5 %, le supplément de rachat s'établit à 15 % sous la calibration minimale, 30 % sous la calibration moyenne et 40 % sous la calibration maximale : rapporté au taux de rachat structurel de 5 % du portefeuille central, le taux de

1. Les qualificatifs « minimale » et « maximale » désignent les bornes de l'intervalle plausible paramètre par paramètre, et non un ordre uniforme sur l'intensité de la réaction. La calibration minimale présente ainsi un $RC_{\max}$ plus faible, mais également un $RC_{\min}$ plus négatif, et réduit donc davantage les rachats en cas de sur-rémunération.

rachat total passe de 20 % à 45 % selon le seul choix de la calibration. Le portefeuille central retient la calibration moyenne, les deux bornes constituant les modalités de sensibilité associées à cette variable.

2.2.3 Autres hypothèses retenues

En complément des caractéristiques propres à l'actif et au passif, différentes hypothèses économiques et de projection doivent être définies afin de constituer le scénario central.

Les projections sont réalisées sous une hypothèse de run-off, c'est-à-dire sans prise en compte d'affaires nouvelles sur l'horizon de projection. Cette hypothèse est conservée aussi bien pour le portefeuille central que pour l'ensemble des sensibilités étudiées par la suite.

Le Best Estimate stochastique est calculé sur un horizon de 60 ans à partir de 1 000 simulations issues du GSE. Pour le scénario central, la volatilité des actions est fixée à 14,65 % et la volatilité moyenne pondérée des taux à 0,60 %.

La courbe des taux sans risque ainsi que la VA utilisées correspondent aux données du 31 décembre 2025. De la même manière, l'ajustement symétrique appliqué au choc actions, appelé dampener, est celui observé au 31 décembre 2025 et s'élève à 7,9 %.

Le bilan initial comporte par ailleurs une Provision pour Participation aux Excédents (PPE) de 5 millions d'euros, un capital de 9 millions d'euros ainsi qu'une réserve de capitalisation de 2 millions d'euros.

À partir de l'ensemble de ces hypothèses, la Net Asset Value (NAV) du portefeuille central s'élève à 13,54 millions d'euros, pour une Risk Margin de 1,72 million d'euros et un SCR de 7,95 millions d'euros. Le taux de couverture Solvabilité II s'établit ainsi à environ 170 % hors prise en compte de la PPE admissible.

Dans le cadre de l'étude, 60 % de la PPE est considérée comme admissible en fonds propres. En intégrant cette composante, le taux de couverture atteint environ 208 %.




FIGURE 2.6 – Bilan Solvabilité II du portefeuille central

Best Estimate du portefeuille central Les deux modes de projection étudiés dans ce mémoire sont appliqués à ce même portefeuille central. Le Best Estimate obtenu à partir des projections stochastiques s'élève à 143,13 millions d'euros, contre 140,39 millions d'euros dans le cadre de la projection déterministe.

L'écart entre les deux approches est ainsi égal à :

$$BE_{sto} - BE_{det} = 143,13 - 140,39 \approx 2,74 \text{ M.} \quad (2.6)$$

Toutefois, l'utilisation de l'écart en valeur absolue rend sa comparaison fortement dépendante de la taille du portefeuille considéré. Afin de disposer d'une grandeur normalisée, la variable d'intérêt retenue correspond à l'écart entre le Best Estimate stochastique et le Best Estimate déterministe rapporté au montant total des PM :

$$Y = \frac{BE_{sto} - BE_{det}}{\sum PM}. \quad (2.7)$$

Pour le portefeuille central, cette variable vaut ainsi :

$$Y_{central} = \frac{143,13 - 140,39}{145} \approx 1,89 \%. \quad (2.8)$$

Cette valeur constitue le niveau de référence du portefeuille central. Les différentes sensibilités appliquées dans la suite de l'étude permettront alors d'analyser l'évolution de cet écart relatif en fonction des caractéristiques du portefeuille et des hypothèses retenues.

2.3 Méthodologie de construction de la base de données

2.3.1 Objectif de la base de données

L'objectif principal de ce mémoire est d'expliquer les mécanismes conduisant aux différences de valorisation entre un Best Estimate déterministe et un Best Estimate stochastique.

L'enjeu n'est pas de comparer ces deux approches d'un point de vue normatif, mais d'analyser les facteurs qui contribuent aux écarts observés afin d'en améliorer la traçabilité, la justification et la compréhension dans un cadre réglementaire.

Pour répondre à cette problématique, une base de données a été construite à partir des résultats produits par SALLTO. Chaque ligne de la base correspond à une configuration particulière du portefeuille, définie par une combinaison de valeurs prises par les différentes variables soumises à sensibilité.

La base de données est composée de neuf variables explicatives :

- la courbe des taux ;
- le spread ;
- la volatilité des taux ;
- la volatilité des actions ;
- la garantie de taux ;
- le taux de plus-values latentes sur les actions ;
- les rachats conjoncturels ;
- la duration du passif ;
- le taux minimum garanti, noté TMG.

2.3.2 Définition de la variable cible

La base de données adopte une approche centrée sur l'analyse de l'écart entre les deux méthodes de valorisation. La variable cible est définie comme la différence entre le Best Estimate stochastique et le Best Estimate déterministe, rapportée à la somme des provisions mathématiques du portefeuille :

$$Y = \frac{BE_{sto} - BE_{det}}{\sum_i PM_i}, \quad (2.9)$$

Le fait de rapporter l'écart à la somme des provisions mathématiques permet d'obtenir une mesure exprimée en pourcentage de la taille du portefeuille. Cette normalisation facilite la comparaison entre les différentes configurations et rend les résultats plus facilement généralisables.

Cette formulation permet également d'isoler plus directement les facteurs expliquant les divergences entre les deux valorisations. Elle met notamment en évidence les effets liés à l'incertitude économique, aux relations non linéaires et aux options et garanties financières.

Cette approche s'inscrit dans une démarche de transparence et de gouvernance des modèles, en cohérence avec les exigences de Solvabilité II.

2.3.3 Principe de construction des observations

Le jeu de données utilisé dans ce mémoire est construit à partir d'une démarche de sensibilités appliquée à SALLTO. Cette approche consiste à faire varier de manière contrôlée certaines hypothèses du modèle afin d'observer l'impact de ces variations sur la valorisation des engagements d'assurance.

L'objectif est de générer un ensemble d'observations structurées permettant d'analyser, dans un cadre maîtrisé, les relations entre les variables explicatives issues des sensibilités et l'écart entre le Best Estimate stochastique et le Best Estimate déterministe.

Chaque observation de la base correspond donc à une configuration donnée des hypothèses du modèle. Cette configuration est définie par une combinaison de valeurs prises par les neuf variables explicatives.

Les sensibilités sont toutes réalisées à la date de valorisation du 31 décembre 2025, à partir du même portefeuille central et sous hypothèse de run-off. Le volume des provisions mathématiques, leur répartition entre supports euro et unités de compte ainsi que la segmentation en model points demeurent donc identiques d'une configuration à l'autre. Les variations portent exclusivement sur les hypothèses économiques, contractuelles et comportementales retenues pour la projection. En dehors des neuf variables explicatives, l'ensemble des autres hypothèses est maintenu inchangé, de sorte que les écarts observés puissent être rattachés aux seules variables soumises à sensibilité.

Cette démarche permet de limiter les effets extérieurs aux paramètres étudiés. Les variations observées dans les résultats peuvent ainsi être principalement rattachées aux variables soumises à sensibilité.

Pour chaque configuration testée, SALLTO permet de calculer :

- un Best Estimate déterministe ;
- un Best Estimate stochastique ;
- la variable cible définie par l'équation (2.9).

2.3.4 Études préliminaires de sensibilité

Avant de construire la base de données définitive, deux études préliminaires de sensibilité ont été réalisées sur un ensemble plus large de variables.

L'objectif de ces études était d'identifier les variables ayant le plus d'impact sur la TVOG et de ne retenir

dans la base finale que les facteurs les plus pertinents.

Les variables initialement testées étaient les suivantes :

- la volatilité des taux ;
- la volatilité des actions ;
- les rachats conjoncturels ;
- les rachats structurels ;
- l'âge des assurés ;
- le taux minimum garanti ;
- l'inflation ;
- la participation aux bénéfices ;
- la garantie de taux ;
- les chargements ;
- le taux de plus-values latentes sur les actions ;
- le spread ;
- la courbe des taux.

La première étude de sensibilité a été réalisée avec la courbe des taux au 31 décembre 2025. Une seconde étude a ensuite été réalisée avec la courbe des taux au 31 décembre 2021.

La courbe du 31 décembre 2021 a été retenue car elle correspond à un environnement de taux particulièrement bas. Cet environnement permet de mieux mettre en évidence l'impact de certaines variables, notamment celles liées aux garanties financières, dont les effets peuvent être amplifiés lorsque les taux d'intérêt sont faibles.

Afin de couvrir plusieurs environnements économiques, cinq courbes de taux sont finalement utilisées :

- la courbe au 31 décembre 2024 ;
- la courbe au 31 décembre 2023 ;
- la courbe au 31 décembre 2025 ;
- la courbe au 31 décembre 2025 augmentée de 2,5 % ;
- la courbe au 31 décembre 2021.




FIGURE 2.7 – Courbes de taux retenues pour la construction de la base de données

Ce choix permet de couvrir à la fois un environnement de taux bas, avec la courbe au 31 décembre 2021, et un environnement de taux élevés, avec la courbe au 31 décembre 2025 relevée de 2,5

Ces tableaux permettent de comparer l'impact des différentes sensibilités au 31/12/2025 sur les différentes variables testées.




FIGURE 2.8 – Résultats de l'étude préliminaire de sensibilité réalisée avec la courbe des taux au 31 décembre 2025

Le graphique précédent synthétise les résultats de la première étude préliminaire, réalisée avec la courbe des taux au 31 décembre 2025. Chaque barre correspond à une hypothèse soumise à sensibilité et reporte les valeurs extrêmes atteintes, sur l'ensemble des modalités testées, par la variation de l'écart entre les deux valorisations rapportée à son niveau dans la configuration centrale. Les variables sont classées par amplitude décroissante, la couleur distinguant celles qui sont retenues dans la base de données définitive de celles qui sont écartées. Cette figure ne constitue pas un résultat en soi : elle sert de support à la sélection des variables présentée à la section 2.3.6, en distinguant les hypothèses dont la variation modifie sensiblement l'écart entre les deux valorisations de celles dont l'effet demeure marginal. Le détail des valorisations obtenues pour chaque modalité est reporté en annexe. La seconde étude, conduite dans l'environnement de taux du 31 décembre 2021, conduit à la même hiérarchie des variables et n'est donc pas reproduite ici. Elle confirme que les conclusions retenues ne dépendent pas du seul environnement de taux observé au 31 décembre 2025.

2.3.5 Construction de la variable de duration

À la suite des études préliminaires, l'âge des assurés et les rachats structurels n'ont pas été intégrés séparément dans la base de données définitive.

Ces deux variables ont été regroupées à travers une variable de duration du passif. En effet, l'âge des assurés et leur comportement de rachat influencent tous les deux la durée pendant laquelle les contrats restent dans le portefeuille.

La variable de duration permet donc de résumer une partie de l'information portée par ces deux facteurs. Une duration faible correspond à un écoulement plus rapide du passif, tandis qu'une duration élevée correspond à des engagements conservés plus longtemps dans le portefeuille.

2.3.6 Sélection des variables définitives

À la suite des deux études préliminaires, seules les variables ayant l'impact le plus important sur la TVOG ont été conservées.

Les neuf variables retenues sont :

- la courbe des taux ;
- le spread ;
- la volatilité des taux ;
- la volatilité des actions ;
- la garantie de taux ;
- le taux de plus-values latentes sur les actions ;
- les rachats conjoncturels ;
- la duration du passif ;
- le TMG.

Ces variables permettent de représenter à la fois l'environnement économique, les caractéristiques des contrats, la structure du passif et le comportement des assurés.

2.3.7 Amplitude des sensibilités retenues

Pour chacune des variables sélectionnées, plusieurs modalités sont définies autour d'une configuration centrale.

Les cellules grisées correspondent à la configuration centrale du portefeuille. Cette configuration constitue le point de référence de l'étude. Les autres modalités correspondent à des sensibilités à la hausse ou à la baisse par rapport à cette situation centrale.

Vol taux	Rachat conj	Duration	Courbe des taux	Spread	TMG	Garantie de taux	Vol action	PMVL actions
0,9%	Dyn max	7	31/12/2024	2%	2%	Net	20%	50%
0,6%	Dyn moy	10	31/12/2023	1,5%	1%	Brut	14,6%	30%
0,3%	Dyn min	13	31/12/2025	0,85%	0,5%		10,0%	10%
			31/12/2025 +2,5%	0%	0%			-20%
			31/12/2021					

FIGURE 2.9 – Synthèse des variables et des modalités retenues dans la base de données

2.3.8 Taille de la base de données

La base de données est obtenue en croisant l'ensemble des modalités retenues pour les neuf variables explicatives.

Le nombre total de configurations est donc égal à :

$$3 \times 3 \times 3 \times 5 \times 4 \times 4 \times 2 \times 3 \times 4 = 51\,840. \quad (2.10)$$

La base de données finale contient ainsi 51 840 lignes. Chaque ligne correspond à une configuration particulière du portefeuille et contient :

- les valeurs prises par les neuf variables explicatives ;
- le Best Estimate déterministe ;
- le Best Estimate stochastique ;
- l'écart normalisé entre les deux valorisations.

La construction de cette base a donc nécessité le lancement de 51 840 projections dans SALLTO.

Le GSE dépend de trois niveaux de volatilité des taux, de trois niveaux de volatilité des actions et de cinq courbes de taux. Il a donc été nécessaire de générer :

$$3 \times 3 \times 5 = 45 \quad (2.11)$$

jeux de scénarios économiques distincts.

Pour chacun de ces jeux de scénarios, les autres variables ont ensuite été combinées directement dans SALLTO afin d'obtenir l'ensemble des 51 840 configurations.

2.3.9 Lancement automatisé de SALLTO

Le lancement manuel de 51 840 projections n'était pas envisageable compte tenu du volume de calculs nécessaire. Une chaîne de traitement automatisée a donc été développée en Python, articulée autour de trois programmes successifs.

Le premier génère les fichiers d'entrée de SALLTO à partir de la grille des modalités. Chaque fichier regroupe 20 portefeuilles, ce qui conduit à 2 592 fichiers d'entrée pour couvrir l'ensemble des configurations. Le second pilote l'exécution : il lance la projection, choisi le nombre de coeurs disponibles pour

le calcul et attend sa fin avant de passer au lancement suivant. Le troisième consolide la base finale en rapprochant les fichiers de sortie d'un fichier de correspondance recensant, pour chaque projection, les valeurs prises par les neuf variables explicatives.

Le format de sortie de SALLTO a par ailleurs été modifié pour les besoins de l'étude. Seuls le Best Estimate déterministe et le Best Estimate stochastique sont conservés, dans un fichier au format CSV, les sorties détaillées habituellement produites par le modèle étant inutiles à ce stade et coûteuses à stocker sur un tel volume de projections. Afin de conserver néanmoins une capacité de contrôle, une sortie complète est générée toutes les 30 exécutions, soit 87 projections documentées dans leur intégralité sur les 2 592 effectués. Ces sorties permettent de vérifier le bon déroulement des projections et la cohérence des résultats agrégés avec le détail des flux projetés.

Cette automatisation ne constitue pas seulement une réponse à une contrainte de volume. Elle garantit que l'ensemble des configurations est traité selon un processus identique, sans intervention manuelle susceptible d'introduire une erreur de paramétrage, et rend la construction de la base entièrement reproductible.

Chapitre 3

Apports du machine learning pour la rationalisation des écarts

Le chapitre précédent a permis de construire une base de données à partir de projections déterministes et stochastiques réalisées avec SALLTO. Chaque observation correspond à une configuration particulière du portefeuille, obtenue en faisant varier de manière contrôlée différentes hypothèses économiques, financières et contractuelles.

L'objectif est désormais d'exploiter cette base afin d'étudier la relation entre les caractéristiques du portefeuille et l'écart observé entre les deux méthodes de valorisation du Best Estimate. Cette problématique peut être formulée comme un problème d'apprentissage supervisé : à partir d'un ensemble de variables explicatives connues, il s'agit de construire une fonction capable d'estimer une variable cible observée lors des simulations.

Le recours au machine learning poursuit ici un double objectif. Le premier est prédictif : il s'agit d'évaluer dans quelle mesure l'écart entre le Best Estimate déterministe et le Best Estimate stochastique peut être reproduit à partir d'un nombre limité de caractéristiques du portefeuille. Le second, qui constitue un enjeu central de ce mémoire, est explicatif : les modèles doivent permettre d'identifier les variables qui contribuent le plus aux écarts observés et de mieux comprendre les mécanismes à l'origine de ces différences de valorisation.

Dans cette perspective, plusieurs familles de modèles sont étudiées. Un modèle linéaire généralisé est tout d'abord utilisé comme modèle de référence. Deux méthodes fondées sur les arbres de décision, le Random Forest et le XGBoost, sont ensuite introduites afin de représenter des relations potentiellement non linéaires et des interactions plus complexes entre les variables.

3.1 Problématique de régression dans le cadre du Best Estimate

3.1.1 Formulation du problème

La problématique étudiée dans ce mémoire s'inscrit dans le cadre d'une régression supervisée. Pour chaque configuration i du portefeuille, un ensemble de variables explicatives $\mathbf{x}_i$ est connu et associé à une valeur cible y_i obtenue à partir des projections réalisées dans SALLTO.

La variable cible retenue est l'écart entre le Best Estimate stochastique et le Best Estimate déterministe, rapporté au montant total des provisions mathématiques du portefeuille :

$$Y_i = \frac{BE_{sto,i} - BE_{det,i}}{\sum_j PM_{i,j}}. \quad (3.1)$$

Cette normalisation permet de raisonner en écart relatif plutôt qu'en montant absolu. Un écart de plusieurs millions d'euros ne possède en effet pas la même importance selon qu'il concerne un portefeuille de quelques dizaines de millions d'euros ou plusieurs milliards d'euros. La variable Y_i mesure ainsi l'écart entre les deux valorisations en proportion de la taille du portefeuille.

Pour chaque observation, le vecteur des variables explicatives peut être écrit sous la forme :

$$\mathbf{x}_i = (x_{i,1}, x_{i,2}, \dots, x_{i,9}), \quad (3.2)$$

où les neuf composantes correspondent respectivement à la courbe des taux, au spread, à la volatilité moyenne pondérée des taux, à la volatilité des actions, à la garantie de taux, au taux de plus-values latentes sur les actions, aux rachats conjoncturels, à la durée du passif et au taux minimum garanti.

Le problème revient alors à rechercher une fonction f reliant ces caractéristiques à la variable cible :

$$Y_i = f(\mathbf{x}_i) + \varepsilon_i, \quad (3.3)$$

où ε_i représente la composante de l'écart qui n'est pas expliquée par le modèle retenu.

À partir d'un échantillon d'apprentissage composé de n observations,

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n, \quad (3.4)$$

l'objectif est d'estimer une fonction $\hat{f}$ telle que :

$$\hat{Y}_i = \hat{f}(\mathbf{x}_i) \quad (3.5)$$

soit aussi proche que possible de la valeur Y_i issue des calculs réalisés avec SALLTO.

De manière générale, l'apprentissage d'un modèle de régression consiste à rechercher une fonction appartenant à une famille de fonctions $\mathcal{F}$ minimisant une fonction de perte :

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n L(y_i, f(\mathbf{x}_i)), \quad (3.6)$$

où L mesure l'écart entre la valeur réellement obtenue avec SALLTO et celle estimée par le modèle.

La nature de la famille $\mathcal{F}$ constitue précisément l'une des différences majeures entre les modèles étudiés dans ce chapitre. Dans un modèle linéaire, les relations possibles entre les variables explicatives et la cible sont fortement contraintes. À l'inverse, les méthodes fondées sur les arbres de décision permettent de construire des fonctions beaucoup plus flexibles.

Le Best Estimate déterministe n'est volontairement pas retenu comme variable explicative, alors qu'il en constituerait a priori le meilleur prédicteur.

Il intervient directement dans le calcul de la variable cible Y_i : il ne s'agit donc pas d'une caractéristique indépendante du portefeuille, au même titre que les neuf variables retenues, mais d'un terme de la définition même de la cible. L'inclure reviendrait à expliquer Y_i en partie par lui-même. Dans un modèle linéaire, il capterait mécaniquement l'essentiel de la variance de Y_i . Dans les modèles fondés sur les arbres, il dominerait de la même façon l'importance des variables et les contributions SHAP calculées par la suite, non pas parce qu'il révèle un facteur pertinent, mais du seul fait de ce lien de construction. Les effets propres aux autres variables se retrouveraient alors masqués derrière cette corrélation, à l'opposé de l'objectif du mémoire.

Le modèle est donc volontairement restreint aux neuf variables primitives du portefeuille : une contrainte plus exigeante, mais seule à même de révéler les facteurs réellement à l'origine de l'écart.

La base complète contient 51 840 configurations issues d'un même portefeuille central. La structure du portefeuille initial est donc maintenue, tandis que les différentes hypothèses sélectionnées dans le chapitre précédent sont combinées afin de couvrir un ensemble suffisamment large de situations.

Le modèle appris dans ce cadre doit ainsi être interprété comme une approximation du comportement de SALLTO sur le domaine couvert par les sensibilités réalisées. Il ne s'agit pas d'établir une relation actuarielle universelle entre les neuf variables et le Best Estimate, mais de modéliser les relations produites par le modèle ALM pour le portefeuille et les hypothèses considérés.

3.1.2 Pourquoi le machine learning est adapté à ce contexte

Le choix de méthodes de machine learning est principalement motivé par la nature de la relation que l'on cherche à représenter. Le Best Estimate stochastique résulte d'une succession de mécanismes dépendant à la fois de l'environnement économique, des caractéristiques des contrats, du comportement des assurés et des décisions prises par l'assureur.

Dans SALLTO, ces mécanismes interviennent de manière successive au cours de la projection. L'évolution des marchés modifie la valeur et le rendement des actifs. La situation financière obtenue influence ensuite

les possibilités de participation aux bénéfices, les réalisations éventuelles de plus-values ou encore les réallocations d'actifs. Ces décisions peuvent à leur tour modifier le comportement des assurés, notamment les rachats, et donc les flux futurs du portefeuille.

Il n'existe donc pas nécessairement de relation analytique simple permettant d'écrire directement :

$$Y = f(\text{taux, spread, volatilités, TMG, } \dots). \quad (3.7)$$

Le machine learning présente l'intérêt de ne pas imposer a priori une forme fonctionnelle unique à cette relation. Le modèle apprend directement, à partir des simulations disponibles, la structure permettant de relier les variables explicatives à l'écart de valorisation.

Ces mécanismes peuvent conduire à des interactions entre variables. Dans un modèle purement additif, l'effet d'une variable X_j est supposé indépendant des autres variables. Une telle structure peut être représentée par :

$$f(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p. \quad (3.8)$$

Dans cette formulation, une variation d'une unité de x_j produit toujours un effet égal à β_j , quelles que soient les valeurs prises par les autres caractéristiques du portefeuille.

Cette hypothèse peut devenir restrictive lorsqu'un mécanisme ne se déclenche qu'à partir d'un certain niveau, ou lorsque l'effet d'une variable dépend de la situation économique globale. Il serait alors nécessaire d'introduire explicitement des termes d'interaction ou des transformations non linéaires, par exemple :

$$f(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \beta_4 x_1^2 + \dots \quad (3.9)$$

Le principal problème réside alors dans le choix de ces transformations. Lorsque le nombre de variables augmente, le nombre d'interactions potentielles augmente rapidement et leur sélection devient difficile sans connaissance préalable de la forme exacte de la relation.

Les modèles fondés sur les arbres de décision permettent au contraire de détecter automatiquement certaines de ces structures à partir des données. Ils sont capables de segmenter l'espace des variables explicatives et d'identifier des comportements différents selon les zones considérées.

La taille de la base constitue également un élément favorable à l'utilisation de ces méthodes. Les 51 840 observations disponibles fournissent un volume de données permettant d'estimer des modèles plus flexibles qu'une simple régression paramétrique. Cette base présente par ailleurs un caractère contrôlé : chaque observation est issue d'un même portefeuille central et les différences entre observations proviennent directement des sensibilités appliquées aux variables retenues.

Le machine learning présente enfin un intérêt particulier au regard du deuxième objectif du mémoire : l'explication des écarts. L'enjeu n'est pas seulement d'obtenir une fonction $\hat{f}$ présentant une erreur prédictive faible. Il s'agit également de déterminer quelles variables sont déterminantes dans la prédiction et dans quel sens elles interviennent.

Cette exigence conduit à distinguer deux dimensions de la qualité d'un modèle :

- sa performance prédictive, c'est-à-dire sa capacité à reproduire les valeurs obtenues avec SALLTO sur des observations non utilisées pour son apprentissage ;
- son explicabilité, c'est-à-dire la capacité à comprendre les facteurs conduisant aux prédictions obtenues.

Les deux ne sont pas nécessairement équivalentes. Un modèle simple peut être très facilement interprétable mais manquer de flexibilité. À l'inverse, un modèle plus complexe peut présenter une excellente capacité prédictive tout en rendant plus difficile la compréhension directe de son fonctionnement.

Cette problématique est particulièrement importante dans le cadre du présent mémoire puisque l'objectif principal est précisément de rationaliser les différences entre les deux méthodes de calcul du Best Estimate. Un modèle performant mais totalement inexploitable pour comprendre l'origine de ces différences ne répondrait donc que partiellement à la problématique.

Les méthodes d'explicabilité, et notamment la méthode SHAP utilisée ultérieurement, permettront de compléter l'analyse des modèles non linéaires afin de mesurer la contribution des différentes variables aux prédictions obtenues.

3.1.3 Positionnement par rapport aux approches traditionnelles

Le recours au machine learning ne doit pas être interprété comme une volonté de remplacer les modèles ALM ou les projections stochastiques utilisées dans le cadre de Solvabilité II.

Dans cette étude, SALLTO constitue au contraire le modèle de référence. Les valeurs utilisées pour entraîner les modèles de machine learning sont directement issues de ses projections. Le modèle statistique apprend donc à reproduire certaines relations générées par SALLTO ; il ne se substitue pas aux mécanismes actuariels, financiers et comptables qu'il contient.

Cette distinction est fondamentale. La projection stochastique demeure nécessaire pour obtenir une valorisation complète intégrant explicitement les différents scénarios économiques ainsi que les interactions entre l'actif et le passif. Le machine learning constitue ici un outil complémentaire, construit à partir des résultats du modèle ALM.

Il est ainsi possible de distinguer trois niveaux d'analyse.

Le premier repose sur la projection stochastique complète dans SALLTO. Il s'agit de l'approche la plus riche puisque tous les mécanismes du modèle sont simulés pour chacun des scénarios économiques. Elle constitue la référence à laquelle les autres méthodes sont comparées.

Le deuxième repose sur un modèle statistique paramétrique classique. Dans le cadre de cette étude, un modèle linéaire généralisé est utilisé comme modèle de référence. Il permet de tester si l'écart étudié peut être expliqué de manière satisfaisante par une relation relativement simple et additive entre les variables.

Le troisième repose sur des méthodes de machine learning non linéaires. Leur objectif est d'apporter davantage de flexibilité lorsque la structure du problème ne peut pas être correctement représentée par

une relation paramétrique simple.

Cette hiérarchie permet d'éviter de recourir directement à un modèle complexe sans disposer d'un point de comparaison. Le GLM joue ainsi un rôle de benchmark. Si un modèle linéaire permettait déjà d'expliquer correctement les écarts, l'utilisation d'algorithmes plus complexes serait difficile à justifier. À l'inverse, une amélioration significative obtenue par les méthodes non linéaires apporterait des éléments en faveur de l'existence de relations plus complexes dans les résultats produits par le modèle ALM.

La comparaison entre ces modèles ne portera donc pas uniquement sur leur précision. Elle permettra également d'étudier le compromis entre simplicité, performance et capacité d'explication.

Le modèle de machine learning peut ainsi être assimilé à un métamodèle ou à un modèle proxy : il apprend à approximer une sortie d'un modèle numérique plus complexe à partir d'un ensemble réduit de variables explicatives.

Une fois entraîné, un tel proxy présente l'avantage de fournir une estimation pratiquement instantanée de la variable cible pour une configuration appartenant au domaine étudié. Il pourrait donc, dans un contexte opérationnel, être utilisé pour réaliser rapidement des analyses exploratoires ou identifier les configurations méritant ensuite une analyse complète avec le modèle ALM.

Toutefois, cette utilisation doit rester encadrée. La qualité d'un proxy dépend directement de la base ayant servi à son apprentissage. Dans le cadre de ce mémoire, les observations proviennent d'un portefeuille central unique et d'un ensemble défini de sensibilités. Le modèle apprend donc le comportement de SALLTO sur ce domaine particulier.

Il ne peut par conséquent pas être supposé valide pour un portefeuille présentant une structure très différente ou pour des niveaux de variables très éloignés de ceux présents dans la base d'apprentissage. Cette question de domaine de validité constitue une limite importante des méthodes de machine learning et sera prise en compte dans l'interprétation des résultats.

3.2 Présentation des modèles de machine learning utilisés

Afin de déterminer le niveau de complexité nécessaire pour reproduire et expliquer la variable cible, trois modèles sont étudiés. Ils ont été retenus de manière à couvrir différents niveaux de flexibilité.

Le modèle linéaire généralisé constitue une référence simple et directement interprétable. Le Random Forest introduit ensuite des relations non linéaires et des interactions à partir d'un ensemble d'arbres de décision construits indépendamment. Enfin, le XGBoost repose sur une construction séquentielle des arbres et cherche progressivement à corriger les erreurs commises par les modèles précédents.

Ces trois modèles permettront ainsi d'étudier si l'augmentation de la complexité du modèle apporte effectivement une amélioration dans la représentation de l'écart entre valorisations déterministe et stochastique.




FIGURE 3.1 – Schéma récapitulatif des trois architectures étudiées

Le schéma ci dessus représente ces trois constructions à partir d'un même vecteur d'entrée. Les variables mobilisées sont identiques dans les trois cas : ce qui distingue les modèles tient uniquement à la manière dont ces variables sont combinées pour produire l'estimation. Les sections suivantes détaillent successivement chacune de ces architectures.

3.2.1 Modèles de référence

Le premier modèle retenu est un modèle linéaire généralisé, ou GLM (*Generalized Linear Model*). Il constitue le modèle de référence de l'étude.

Les GLM généralisent la régression linéaire en permettant de relier l'espérance conditionnelle de la variable cible aux variables explicatives à travers une fonction de lien g :

$$g(\mathbb{E}[Y | \mathbf{X}]) = \beta_0 + \sum_{j=1}^p \beta_j X_j. \quad (3.10)$$

Dans le cas d'une variable cible continue et d'une fonction de lien identité, cette formulation devient :

$$\mathbb{E}[Y | \mathbf{X}] = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p. \quad (3.11)$$

Chaque coefficient β_j représente alors l'effet associé à la variable X_j , toutes choses égales par ailleurs.

Cette propriété constitue l'un des principaux avantages du GLM dans le cadre de ce mémoire. Le signe d'un coefficient permet d'identifier le sens de la relation entre une variable et la cible, tandis que son amplitude apporte une information sur l'importance de cette relation, sous réserve de tenir compte de l'échelle des différentes variables.

Le modèle constitue donc une première approche particulièrement transparente du problème.

La simplicité du GLM constitue cependant également sa principale limite. En l'absence de termes supplémentaires, il suppose que les effets des différentes variables sont additifs et que la relation avec le prédicteur linéaire peut être décrite à partir d'une forme prédéterminée.

Les interactions doivent notamment être introduites explicitement. Pour représenter une interaction entre deux variables X_1 et X_2 , il faudrait par exemple écrire :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon. \quad (3.12)$$

De la même manière, une relation non linéaire nécessite l'introduction volontaire de transformations telles que X^2 , $\log(X)$ ou d'autres fonctions adaptées.

Dans une problématique où la forme exacte des interactions produites par un modèle ALM n'est pas connue à l'avance, cette contrainte peut limiter la capacité du GLM à représenter l'ensemble des comportements observés.

Le GLM constitue néanmoins un benchmark essentiel. Il permet de déterminer si la complexité supplémentaire introduite par les méthodes non linéaires est réellement nécessaire. Les performances des modèles plus complexes devront donc être analysées relativement à cette référence.

3.2.2 Modèles non linéaires

3.2.2.1 Le Random Forest

Le Random Forest, ou forêt aléatoire, est une méthode d'apprentissage supervisé reposant sur l'agrégation d'un grand nombre d'arbres de décision.

Un arbre de décision construit progressivement une partition de l'espace des variables explicatives. À chaque nœud, une variable et un seuil sont sélectionnés afin de diviser les observations en deux groupes aussi homogènes que possible vis-à-vis de la variable cible.

Pour une variable X_j et un seuil s , la séparation peut être représentée par :

$$R_1(j, s) = \{\mathbf{x} : x_j \leq s\}, \quad R_2(j, s) = \{\mathbf{x} : x_j > s\}. \quad (3.13)$$

Dans un problème de régression, le couple (j, s) est choisi de manière à minimiser l'erreur au sein des deux régions créées.

Ce mécanisme est ensuite reproduit récursivement sur chacune des sous-régions. La prédiction finale d'un arbre correspond à la moyenne des observations appartenant à la feuille terminale dans laquelle se trouve la nouvelle observation.

Un arbre individuel possède une grande flexibilité mais peut être fortement dépendant de l'échantillon ayant servi à sa construction. Il présente donc un risque de variance élevée et de surapprentissage.

Le Random Forest cherche à réduire cette instabilité en combinant plusieurs arbres.

Deux mécanismes principaux sont utilisés.

Tout d'abord, chaque arbre est entraîné sur un échantillon bootstrap de la base d'apprentissage, c'est-à-dire un échantillon obtenu par tirage avec remise parmi les observations disponibles.

Ensuite, à chaque séparation d'un arbre, seule une fraction aléatoire des variables explicatives est proposée pour déterminer la meilleure coupure. Ce mécanisme réduit la corrélation entre les différents arbres et évite qu'une même variable dominante conduise systématiquement à des arbres très similaires.

Pour une forêt composée de B arbres T_b , la prédiction finale s'écrit :

$$\hat{f}_{RF}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}). \quad (3.14)$$

La moyenne des prédictions permet ainsi de réduire la variance associée à un arbre individuel.

Dans le cadre de ce mémoire, le Random Forest présente plusieurs propriétés intéressantes. Il ne nécessite pas de spécifier à l'avance la forme de la relation entre les variables explicatives et la cible. Il peut également faire apparaître naturellement des interactions entre variables puisque les différentes séparations d'un arbre sont conditionnelles aux séparations effectuées précédemment.

Il constitue ainsi une première méthode permettant de tester si l'écart entre les deux Best Estimate présente une structure plus complexe que celle représentable par un GLM.

En contrepartie, l'interprétation du modèle devient moins immédiate. Contrairement au GLM, il n'existe pas un coefficient directement associé à chaque variable. Des méthodes spécifiques doivent être mobilisées pour mesurer l'importance et l'effet des caractéristiques sur les prédictions.

3.2.2.2 Le XGBoost

Le deuxième modèle non linéaire retenu est l'*Extreme Gradient Boosting*, généralement appelé XGBoost.

Comme le Random Forest, XGBoost repose sur des arbres de décision. La logique de construction est toutefois fondamentalement différente.

Dans une forêt aléatoire, les arbres sont construits de manière largement indépendante avant que leurs prédictions soient moyennées. Dans une méthode boosting, les arbres sont au contraire construits successivement. Chaque nouvel arbre vise à améliorer les erreurs commises par l'ensemble des arbres précédents.

La prédiction d'un modèle composé de K arbres peut s'écrire :

$$\hat{y}_i = \sum_{k=1}^K f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F}, \quad (3.15)$$

où $\mathcal{F}$ désigne l'ensemble des arbres de régression pouvant être construits.

À l'étape t , la prédiction devient :

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i). \quad (3.16)$$

Le nouvel arbre f_t n'est donc pas construit indépendamment. Il est choisi afin d'améliorer la fonction objectif à partir des erreurs encore présentes après les étapes précédentes.

La fonction objectif utilisée par XGBoost peut être représentée sous la forme :

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l\left(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)\right) + \Omega(f_t), \quad (3.17)$$

où l représente la fonction de perte utilisée pour mesurer l'erreur prédictive et Ω un terme de régularisation contrôlant la complexité du nouvel arbre.

Une formulation classique du terme de régularisation est :

$$\Omega(f) = \gamma T + \frac{\lambda}{2} \sum_{j=1}^T w_j^2, \quad (3.18)$$

où T correspond au nombre de feuilles de l'arbre et w_j à la valeur associée à la feuille j .

Le paramètre γ pénalise donc l'ajout de feuilles supplémentaires, tandis que λ limite l'amplitude des valeurs attribuées aux feuilles. Ce mécanisme permet de rechercher un compromis entre amélioration de la prédiction et complexité du modèle.

Une autre caractéristique importante du boosting est le learning rate. Plutôt que d'ajouter intégralement chaque nouvel arbre à la prédiction, sa contribution peut être réduite par un paramètre η :

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta f_t(\mathbf{x}_i), \quad 0 < \eta \leq 1. \quad (3.19)$$

Une valeur faible de η conduit généralement à utiliser davantage d'arbres, chacun corrigeant plus progressivement les erreurs du modèle.

XGBoost combine ainsi plusieurs propriétés particulièrement adaptées à la problématique étudiée : il permet de représenter des relations non linéaires, de prendre en compte des interactions entre variables et d'introduire différents mécanismes de régularisation afin de contrôler le surapprentissage.

Sa flexibilité a cependant un coût en termes d'interprétabilité. Le résultat final est la combinaison d'un grand nombre d'arbres et il devient difficile de relier directement une prédiction à une relation simple entre les variables d'entrée et la cible.

Cette limite est particulièrement importante dans le cadre du mémoire, puisque l'explication des écarts constitue un objectif au moins aussi important que leur prédiction. L'utilisation ultérieure de valeurs SHAP permettra donc de compléter l'analyse de XGBoost en quantifiant la contribution de chaque variable aux prédictions du modèle.

3.2.3 Avantages et limites de chaque modèle dans le cadre d'étude

Les trois modèles retenus présentent des niveaux de complexité et d'interprétabilité différents. Leur comparaison doit donc dépasser la seule mesure de leur précision prédictive.

Le GLM présente l'avantage majeur de sa transparence. La relation entre les variables et la cible peut être directement étudiée à travers les coefficients estimés. Il constitue également un modèle rapide à entraîner et relativement peu exposé au surapprentissage lorsque le nombre de variables reste limité.

Sa principale faiblesse réside dans les hypothèses imposées à la relation entre les variables. Si les mécanismes issus du modèle ALM présentent des non-linéarités, des seuils ou des interactions importantes, une structure linéaire peut ne pas être suffisamment flexible.

Le Random Forest permet de lever une grande partie de ces contraintes. Sa construction à partir d'arbres lui permet de représenter des comportements non linéaires sans nécessiter de transformation préalable des variables. Le mécanisme de bootstrap et l'agrégation d'un grand nombre d'arbres limitent par ailleurs l'instabilité d'un arbre de décision individuel.

Son fonctionnement devient toutefois moins directement interprétable. De plus, les prédictions des arbres reposent sur des partitions de valeurs observées lors de l'apprentissage. Leur capacité à extrapoler en dehors du domaine de données couvert par la base est donc limitée.

XGBoost possède généralement une flexibilité encore plus importante. La construction séquentielle permet de concentrer progressivement l'apprentissage sur les observations les plus difficiles à reproduire. Les nombreux paramètres de régularisation permettent également de contrôler finement la complexité du modèle.

Cette flexibilité augmente toutefois le nombre d'hyperparamètres à déterminer et donc le risque de surapprentissage lorsque leur calibration est insuffisante. Elle accentue également l'effet "boîte noire" du modèle, ce qui rend nécessaire l'utilisation d'outils d'explicabilité complémentaires.

Le tableau suivant synthétise les principales caractéristiques des trois modèles dans le contexte de l'étude.

TABLE 3.1 – Comparaison des modèles retenus dans le cadre de l'étude

Modèle	Principaux avantages	Principales limites	Interprétabilité	Rôle dans l'étude
GLM	Simplicité, rapidité, coefficients directement exploitables	Relations principalement linéaires et additives, interactions à spécifier	Élevée	Modèle de référence permettant d'évaluer l'intérêt d'une complexité supplémentaire
Random Forest	Non-linéarités, interactions automatiques, réduction de la variance par agrégation	Extrapolation limitée, perte d'interprétabilité par rapport au GLM	Intermédiaire	Premier modèle non linéaire permettant de représenter des relations complexes
XGBoost	Grande flexibilité, interactions, apprentissage séquentiel et régularisation	Nombreux hyperparamètres, risque de surapprentissage, fonctionnement moins transparent	Faible directement, améliorée par SHAP	Modèle flexible destiné à rechercher une forte capacité de reproduction tout en permettant une analyse a posteriori

Une attention particulière doit enfin être portée à la notion de domaine de validité. Les données utilisées dans ce mémoire ne constituent pas un échantillon aléatoire représentatif de l'ensemble des portefeuilles d'assurance vie. Elles proviennent d'un portefeuille central auquel ont été appliquées différentes sensibilités.

Les modèles appris doivent donc avant tout être considérés comme valides à l'intérieur du domaine couvert par ces sensibilités. Ce point est particulièrement important pour les méthodes fondées sur les arbres, dont la capacité d'extrapolation en dehors des valeurs rencontrées pendant l'apprentissage est faible.

De la même manière, les relations mises en évidence par les modèles ne doivent pas être interprétées comme des relations universelles. Elles décrivent le comportement de SALLTO compte tenu du portefeuille, du GSE, des hypothèses de comportement et des règles de gestion retenues dans cette étude.

Cette dépendance ne constitue pas nécessairement une faiblesse de l'approche. Elle correspond à la nature même d'un métamodèle : son objectif est de reproduire et d'expliquer le comportement d'un modèle complexe sur un domaine déterminé.

Dans les sections suivantes, les différents modèles seront entraînés dans des conditions identiques puis comparés à l'aide de plusieurs indicateurs de performance. Le coefficient de détermination R^2 , la MAE et la RMSE permettront notamment d'évaluer leur capacité à reproduire la variable cible. Ces mesures seront ensuite complétées par une analyse de l'explicabilité des modèles afin de déterminer si l'amélioration éventuelle de la performance prédictive s'accompagne également d'une meilleure compréhension des facteurs à l'origine des écarts entre valorisations déterministe et stochastique.

3.3 Méthodologie d'apprentissage

3.3.1 Séparation des données

L'apprentissage d'un modèle statistique nécessite de distinguer les observations utilisées pour son estimation de celles servant à évaluer sa qualité. Un modèle évalué sur les données ayant servi à sa construction produit en effet une mesure de performance optimiste : il ne s'agit plus alors d'apprécier sa capacité à prédire de nouvelles observations, mais uniquement sa capacité à reproduire celles qu'il a déjà rencontrées.

Cette distinction revêt une importance particulière dans le cadre de cette étude. Les trois modèles retenus présentent des niveaux de flexibilité très différents, et l'un des objectifs de la comparaison consiste précisément à déterminer si la complexité supplémentaire introduite par les méthodes non linéaires apporte un gain réel. Or les modèles les plus flexibles sont également ceux dont la performance mesurée en apprentissage s'éloigne le plus de la performance réellement obtenue sur de nouvelles observations. Une évaluation menée sur les seules données d'apprentissage favoriserait donc mécaniquement le Random Forest et XGBoost, indépendamment de leur véritable apport.

Formellement, l'échantillon complet $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ introduit à l'équation (3.4) est partitionné en deux sous-ensembles disjoints :

$$\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{test}}, \quad \mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{test}} = \emptyset. \quad (3.20)$$

L'estimation de la fonction $\hat{f}$ définie à l'équation (3.6) est réalisée uniquement à partir de $\mathcal{D}_{\text{train}}$. L'échantillon $\mathcal{D}_{\text{test}}$ n'intervient qu'au moment de l'évaluation finale des modèles.

3.3.1.1 Répartition retenue

La base est répartie entre un échantillon d'apprentissage représentant 70 % des observations et un échantillon de test représentant les 30 % restants. Compte tenu des 51 840 configurations disponibles, cette répartition conduit à 36 288 observations pour l'apprentissage et 15 552 observations pour le test.

Ce choix résulte d'un arbitrage entre deux exigences. L'échantillon d'apprentissage doit être suffisamment fourni pour permettre l'estimation de modèles flexibles, en particulier les méthodes fondées sur les arbres, dont la capacité à représenter des relations complexes dépend directement du nombre d'observations disponibles dans chaque région de l'espace des variables explicatives. L'échantillon de test doit pour sa part conserver un effectif suffisant pour que les indicateurs de performance calculés à la section 3.4 soient estimés avec une précision satisfaisante.

La taille de la base rend cet arbitrage relativement peu contraignant. Avec plus de quinze mille observations, l'échantillon de test permet une évaluation stable des indicateurs retenus. Un ratio plus favorable à l'apprentissage n'apporterait par ailleurs qu'un gain marginal, le nombre d'observations disponibles étant déjà très élevé au regard des neuf variables explicatives du modèle.

3.3.1.2 Modalités du tirage

La répartition est effectuée par tirage aléatoire simple, ligne à ligne, parmi les 51 840 configurations de la base. Chaque observation dispose ainsi de la même probabilité d'être affectée à l'échantillon d'apprentissage, indépendamment des valeurs prises par ses variables explicatives.

Cette modalité de tirage appelle une précision quant à la nature de l'évaluation qu'elle permet. La base ne résulte pas d'un échantillonnage aléatoire mais du croisement complet des modalités retenues pour les neuf variables explicatives. Deux configurations peuvent donc y être très proches l'une de l'autre, ne différant que par la modalité d'une seule variable, l'ensemble des autres hypothèses demeurant identiques.

Un tirage aléatoire ligne à ligne conduit par conséquent à ce que des configurations voisines dans la grille se répartissent de part et d'autre de la séparation. Une observation de l'échantillon de test possède ainsi, avec une probabilité élevée, plusieurs configurations directement adjacentes au sein de l'échantillon d'apprentissage.

L'échantillon de test mesure donc la capacité des modèles à interpoler à l'intérieur de la grille des sensibilités réalisées, plutôt que leur capacité à extrapoler vers des configurations réellement inédites. Cette portée doit être gardée à l'esprit lors de la lecture des indicateurs présentés à la section 3.4, en particulier pour les méthodes fondées sur les arbres, dont les limites en matière d'extrapolation ont déjà été relevées.

Cette caractéristique ne remet pas en cause la pertinence de la démarche. L'objectif de l'étude consiste à reproduire et à expliquer le comportement de SALLTO sur le domaine couvert par les sensibilités, conformément au positionnement en métamodèle, et non à prédire des configurations situées hors de ce domaine. Elle justifie néanmoins le recours à la validation externe présentée plus loin dans cette section, seule à même d'évaluer la robustesse des modèles au-delà du domaine d'apprentissage.

3.3.1.3 Répétition de la séparation

La partition définie à l'équation (3.20) dépend du tirage aléatoire ayant présidé à sa construction. Une répartition particulière peut ainsi se révéler légèrement plus favorable à l'un des modèles, et les indicateurs de performance obtenus comportent de ce fait une part de variabilité qui ne reflète pas la qualité intrinsèque des modèles comparés.

La séparation n'est donc pas figée sur un tirage unique. L'opération est répétée à plusieurs reprises, chaque nouvelle répartition donnant lieu à un réentraînement complet des trois modèles et au calcul des indicateurs de performance correspondants.

En notant $\hat{f}^{(s)}$ le modèle estimé à partir de la s -ième répartition et $M(\hat{f}^{(s)})$ l'indicateur de performance associé, la comparaison porte alors sur la moyenne obtenue sur l'ensemble des S répétitions :

$$\bar{M} = \frac{1}{S} \sum_{s=1}^S M(\hat{f}^{(s)}), \quad (3.21)$$

ainsi que sur la dispersion de ces valeurs :

$$\hat{\sigma}_M^2 = \frac{1}{S-1} \sum_{s=1}^S \left(M(\hat{f}^{(s)}) - \bar{M} \right)^2. \quad (3.22)$$

Cette démarche poursuit deux objectifs. Elle fournit d'une part une estimation plus fiable de la performance de chaque modèle, moins dépendante d'une répartition particulière. Elle permet d'autre part d'apprécier la stabilité des résultats : une dispersion faible indique que les performances observées ne résultent pas des circonstances d'un tirage donné, tandis qu'une dispersion importante conduirait à nuancer toute conclusion tirée de la comparaison des modèles.

Ce point présente un intérêt particulier au regard de l'objectif de l'étude. La comparaison entre le GLM et les méthodes non linéaires vise à déterminer si la complexité supplémentaire de ces dernières est justifiée. Un écart de performance dont l'amplitude resterait comparable à la variabilité induite par le seul choix de la répartition ne permettrait pas de conclure en ce sens.

3.3.1.4 Validation croisée au sein de l'échantillon d'apprentissage

La détermination des hyperparamètres décrite à la section 3.3.2 nécessite de comparer plusieurs configurations de chaque modèle. Cette comparaison suppose de disposer d'une mesure de performance calculée sur des observations non utilisées pour l'estimation, sans pour autant mobiliser l'échantillon de test.

Recourir à ce dernier pour sélectionner les hyperparamètres reviendrait en effet à l'intégrer indirectement au processus de construction des modèles. Les valeurs retenues seraient celles produisant les meilleurs résultats sur cet échantillon précis, et la performance finale mesurée sur les mêmes observations perdrait son caractère hors échantillon.

Une validation croisée à k blocs est donc mise en œuvre à l'intérieur du seul échantillon d'apprentissage. Celui-ci est divisé en k sous-ensembles de taille comparable :

$$\mathcal{D}_{\text{train}} = \bigcup_{m=1}^k \mathcal{D}_m, \quad \mathcal{D}_m \cap \mathcal{D}_{m'} = \emptyset \quad \text{pour } m \neq m'. \quad (3.23)$$

Le modèle est ensuite estimé k fois. À chaque itération m , l'apprentissage est réalisé sur les $k-1$ blocs restants et l'évaluation sur le bloc $\mathcal{D}_m$ laissé de côté. L'erreur de validation croisée correspond à la moyenne des erreurs ainsi obtenues :

$$\text{Err}_{\text{CV}} = \frac{1}{k} \sum_{m=1}^k \frac{1}{|\mathcal{D}_m|} \sum_{i \in \mathcal{D}_m} L \left(y_i, \hat{f}^{(-m)}(x_i) \right), \quad (3.24)$$

où $\hat{f}^{(-m)}$ désigne le modèle estimé sans le bloc $\mathcal{D}_m$.

Chaque observation de l'échantillon d'apprentissage contribue ainsi une fois à l'évaluation et $k-1$ fois à l'estimation. Cette organisation permet d'exploiter l'intégralité des données disponibles pour la calibration tout en préservant le caractère hors échantillon de la mesure utilisée pour comparer les configurations.

La configuration d'hyperparamètres retenue est celle minimisant Err_{CV} . Le modèle final est ensuite rées-

timé sur l'intégralité de l'échantillon d'apprentissage à partir de ces valeurs, puis évalué sur l'échantillon de test.

3.3.1.5 Validation externe sur un second portefeuille central

Les dispositifs précédents partagent une limite commune. L'échantillon de test comme les blocs de validation croisée sont issus de la même grille de configurations, construite à partir d'un unique portefeuille central. Ils permettent d'évaluer la capacité des modèles à généraliser à l'intérieur de ce domaine, mais ne renseignent pas sur leur comportement en dehors de celui-ci.

Cette limite correspond directement à la question du domaine de validité. Les relations apprises par les modèles décrivent le comportement de SALLTO compte tenu du portefeuille, du générateur de scénarios économiques et des règles de gestion retenus dans cette étude. Rien ne garantit a priori qu'elles demeurent pertinentes pour un portefeuille présentant une structure différente.

Un dispositif de validation supplémentaire est donc mis en place. Une seconde base de données est construite selon la même démarche que celle décrite au chapitre 2, mais à partir d'un portefeuille central distinct de celui ayant servi à l'apprentissage. Les mêmes variables explicatives et les mêmes modalités de sensibilité y sont appliquées, de sorte que les deux bases demeurent comparables dans leur structure.

Les modèles entraînés sur la première base sont appliqués à ces nouvelles configurations sans aucune réestimation. Aucun paramètre n'est ajusté et aucun hyperparamètre n'est recalibré : les modèles sont utilisés exactement tels qu'ils ont été construits.

Cette validation externe constitue le test de généralisation le plus exigeant de l'étude. Elle permet d'apprécier si les relations identifiées entre les caractéristiques du portefeuille et l'écart de valorisation possèdent une portée dépassant le seul portefeuille central initial, ou si elles demeurent étroitement dépendantes de ses caractéristiques propres.

L'enjeu dépasse la seule vérification technique. Un métamodèle dont les conclusions ne seraient valables que pour un portefeuille donné présenterait un intérêt opérationnel limité, tandis que la stabilité des facteurs explicatifs identifiés d'un portefeuille à l'autre renforcerait leur interprétation actuarielle. Les résultats de cette validation sont présentés au chapitre 4.

TABLE 3.2 – Niveaux de séparation des données et objectifs associés

Niveau	Données mobilisées	Objectif
Validation croisée	Blocs internes à l'échantillon d'apprentissage	Sélection des hyperparamètres sans mobiliser l'échantillon de test
Échantillon de test	30 % de la base, soit 15 552 configurations	Évaluation finale des modèles à l'intérieur du domaine des sensibilités
Répétition des tirages	Plusieurs répartitions successives de la base complète	Vérification de la stabilité des performances au regard du tirage retenu
Validation externe	Base construite à partir d'un second portefeuille central	Évaluation de la généralisation en dehors du portefeuille d'apprentissage

3.3.2 Contrôle de la complexité et choix des hyperparamètres

L'estimation d'un modèle statistique fait intervenir deux catégories de quantités. Les paramètres sont déterminés par l'algorithme lui-même à partir des données d'apprentissage : il s'agit par exemple des coefficients β_j du GLM ou des seuils de division des arbres de décision. Les hyperparamètres sont au contraire fixés avant l'apprentissage et définissent la manière dont celui-ci est conduit.

Ces hyperparamètres déterminent principalement la flexibilité du modèle, c'est-à-dire l'étendue de la famille de fonctions $\mathcal{F}$ dans laquelle la solution est recherchée, conformément à la formulation de l'équation (3.6). Leur calibration constitue donc le principal levier de contrôle du surapprentissage.

3.3.2.1 Nature du risque de surapprentissage dans le cadre de l'étude

Le surapprentissage désigne la situation dans laquelle un modèle reproduit fidèlement les observations ayant servi à son apprentissage, mais perd une partie de sa capacité à prédire correctement de nouvelles observations. Le modèle n'apprend alors plus uniquement la relation systématique reliant les variables explicatives à la cible : il apprend également les fluctuations propres à l'échantillon utilisé.

La nature de ce risque doit être précisée dans le cadre de cette étude. Les observations de la base ne proviennent pas de mesures empiriques bruitées au sens habituel, mais des projections réalisées avec SALLTO. Pour une configuration donnée des neuf variables explicatives, le Best Estimate déterministe est entièrement déterminé par les hypothèses retenues : une même configuration relancée dans le modèle produit exactement le même résultat.

Il n'en va pas de même pour le Best Estimate stochastique. Celui-ci est obtenu en moyennant les flux actualisés sur les 1000 simulations issues du générateur de scénarios économiques. Il constitue donc une estimation par simulation, entachée d'une erreur d'échantillonnage de Monte-Carlo. Un même jeu d'hypothèses relancé avec un autre tirage de scénarios conduirait à une valeur légèrement différente.

Cette erreur d'estimation se répercute directement sur la variable cible, puisque BE_{sto} intervient au numérateur de l'équation (3.1). Elle correspond ainsi à une partie du terme ε_i introduit à l'équation (3.3), qui représente la composante de l'écart non expliquée par les variables explicatives retenues.

Un modèle suffisamment flexible peut chercher à reproduire ces fluctuations plutôt que la relation sous-jacente. Il ajusterait alors des variations qui ne se reproduiraient pas sur un nouveau tirage de scénarios économiques. Le risque de surapprentissage demeure donc réel, malgré le caractère contrôlé de la base de données.

Ce phénomène s'inscrit dans le compromis classique entre biais et variance. Pour une configuration x donnée, l'erreur quadratique moyenne attendue d'un modèle $\hat{f}$ peut se décomposer sous la forme :

$$\mathbb{E} \left[\left(Y - \hat{f}(x) \right)^2 \right] = \underbrace{\left(\mathbb{E} [\hat{f}(x)] - f(x) \right)^2}_{\text{biais}^2} + \underbrace{\mathbb{V} [\hat{f}(x)]}_{\text{variance}} + \underbrace{\sigma^2}_{\text{bruit irréductible}}. \quad (3.25)$$

Un modèle trop contraint présente un biais élevé : il ne parvient pas à représenter la véritable relation f . Un modèle trop flexible présente au contraire une variance élevée : ses prédictions dépendent fortement de

l'échantillon particulier ayant servi à son apprentissage. Le terme σ^2 correspond à la part d'incertitude qu'aucun modèle ne peut expliquer, et qui recouvre ici l'erreur de simulation évoquée précédemment.

Le choix des hyperparamètres revient donc à positionner chaque modèle au meilleur compromis entre ces deux sources d'erreur. Les sections suivantes présentent, pour chacun des trois modèles, les hyperparamètres retenus, leur rôle dans le contrôle de la complexité et les valeurs finalement adoptées.

3.3.2.2 Le GLM

Le GLM constitue le modèle le moins exposé au surapprentissage parmi les trois retenus. La base comporte 51 840 observations pour seulement neuf variables explicatives, soit un rapport entre le nombre d'observations et le nombre de paramètres très largement favorable. La famille de fonctions $\mathcal{F}$ dans laquelle le modèle est recherché est par ailleurs fortement contrainte : elle se limite aux combinaisons linéaires des variables explicatives.

Le modèle ne comporte de ce fait aucun hyperparamètre à calibrer. Les coefficients β_j sont directement estimés par maximum de vraisemblance à partir de l'échantillon d'apprentissage.

Le principal risque associé à ce modèle ne concerne donc pas sa capacité de généralisation, mais la stabilité de ses coefficients. En présence d'une corrélation importante entre plusieurs variables explicatives, les estimateurs $\hat{\beta}_j$ peuvent présenter une variance élevée. Leur amplitude, voire leur signe, devient alors sensible à de faibles variations de l'échantillon. Le modèle conserve dans ce cas une qualité d'ajustement globale satisfaisante, mais l'interprétation individuelle de chaque coefficient perd sa fiabilité.

Cette question est déterminante ici, puisque l'intérêt principal du GLM dans cette étude réside précisément dans la lecture directe de ses coefficients.

Un facteur d'inflation de la variance, ou VIF (*Variance Inflation Factor*), a donc été calculé pour chacune des neuf variables. Cet indicateur mesure dans quelle proportion la variance d'un coefficient estimé se trouve augmentée par la corrélation de la variable concernée avec les autres variables du modèle. Il s'écrit :

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad (3.26)$$

où R_j^2 désigne le coefficient de détermination obtenu en régressant la variable X_j sur l'ensemble des autres variables explicatives. Une valeur proche de 1 traduit une variable pratiquement indépendante des autres. Les seuils de 5 et 10 sont habituellement retenus comme indicateurs d'une colinéarité respectivement modérée et préoccupante.

La structure de la base rend ce diagnostic largement prévisible. Les observations résultent du croisement complet des modalités retenues pour les neuf variables. Chaque modalité d'une variable est donc associée au même nombre d'observations pour chacune des modalités des autres variables. Ce plan factoriel complet assure par construction une quasi-orthogonalité entre les variables explicatives, contrairement à des données observées dans lesquelles les facteurs économiques apparaissent naturellement corrélés.

TABLE 3.3 – Facteur d'inflation de la variance des neuf variables explicatives

Courbe des taux	1,00	Absence de colinéarité
Spread	1,00	Absence de colinéarité
Volatilité des taux	1,00	Absence de colinéarité
Volatilité des actions	1,00	Absence de colinéarité
Garantie de taux	1,00	Absence de colinéarité
PMVL actions	1,00	Absence de colinéarité
Rachats conjoncturels	1,00	Absence de colinéarité
Duration du passif	1,00	Absence de colinéarité
TMG	1,00	Absence de colinéarité

Les neuf variables présentent un VIF égal à 1,00, très en deçà des seuils de 5 et de 10. Ce résultat confirme l'orthogonalité attendue du plan factoriel complet : aucune variable explicative n'est reconstituée, même partiellement, par les huit autres. Les coefficients estimés peuvent donc être interprétés individuellement, et le recours à une pénalisation de type Ridge ou Lasso n'apporterait aucun gain de stabilité.

Une version pénalisée du GLM, de type Ridge ou Lasso, n'a donc pas été retenue. Ces méthodes consistent à ajouter à la fonction de perte un terme pénalisant l'amplitude des coefficients, par exemple :

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \alpha \sum_{j=1}^p \beta_j^2 \right\}, \quad (3.27)$$

où α contrôle l'intensité de la pénalisation. Le paramètre est ici noté α afin d'éviter toute confusion avec le paramètre λ de régularisation de XGBoost introduit à l'équation (3.19).

Trois raisons justifient de ne pas recourir à ces méthodes dans le cadre de cette étude.

- La pénalisation vise principalement à stabiliser les coefficients en présence de colinéarité. Or le plan factoriel complet et le contrôle par VIF écartent déjà ce risque.
- Elle vise également à limiter le surapprentissage lorsque le nombre de variables est élevé au regard du nombre d'observations, ce qui n'est pas le cas ici.
- Elle introduit enfin un biais volontaire sur les coefficients estimés, dont l'amplitude se trouve réduite par construction. Cette contraction nuirait directement à la lecture des effets associés à chaque variable, alors que cette lecture constitue la raison même de la présence du GLM dans l'étude.

La sélection de variables opérée par une pénalisation de type Lasso présenterait par ailleurs un intérêt limité. Les neuf variables retenues résultent déjà d'une sélection préalable, conduite à partir des deux études de sensibilité.

3.3.2.3 Le Random Forest

Le Random Forest repose sur l'agrégation d'arbres de décision, dont le mécanisme de construction a été décrit à la section 3.2.2.1. Quatre hyperparamètres principaux interviennent dans sa calibration.

Profondeur maximale des arbres En l'absence de contrainte, un arbre de décision poursuit la division réursive de l'espace des variables explicatives jusqu'à ce que les régions obtenues deviennent homogènes. Les feuilles terminales peuvent alors ne contenir qu'un très petit nombre d'observations, parfois une seule. La prédiction associée à une telle feuille correspond à la moyenne de ces quelques observations et reproduit donc directement leurs particularités, y compris l'erreur de simulation qui les affecte.

Limiter la profondeur maximale revient à borner le nombre de divisions successives pouvant être appliquées le long d'une branche. La partition de l'espace des variables reste ainsi plus grossière et chaque région conserve un effectif suffisant pour que la moyenne calculée traduise un comportement d'ensemble plutôt qu'une configuration particulière.

Ce paramètre agit directement sur le terme de variance de l'équation (3.25). Une contrainte trop forte conduirait toutefois à un modèle excessivement rigide, incapable de représenter les non-linéarités que la méthode a précisément pour objet de capter.

Quatre modalités ont été retenues pour ce paramètre : des profondeurs maximales de 8, 12 et 16 divisions, ainsi que l'absence de contrainte. La configuration finalement adoptée correspond à cette dernière modalité, la limitation de la profondeur dégradant systématiquement l'erreur de validation croisée, de façon marginale à partir de seize niveaux et très sensible en deçà de douze.

Taille minimale des feuilles Ce paramètre impose qu'une division ne soit acceptée que si chacune des deux régions issues de la séparation contient au moins un nombre minimal d'observations. Il complète la limitation de la profondeur en agissant à un niveau plus local : la profondeur maximale contraint uniformément l'ensemble des branches, tandis que la taille minimale des feuilles s'ajuste à la densité des observations dans chaque zone de l'espace des variables.

Une taille minimale élevée garantit que chaque prédiction repose sur un effectif suffisant. Elle limite ainsi la possibilité pour le modèle d'isoler des configurations particulières dont le comportement s'écarterait de la tendance d'ensemble uniquement du fait de l'erreur de simulation.

Les valeurs 1, 5, 20 et 50 ont été testées. La valeur retenue est de une observation par feuille, toute contrainte plus forte se traduisant par une dégradation de l'erreur de validation croisée.

Nombre de variables candidates à chaque division Le mécanisme de sélection aléatoire des variables décrit à la section 3.2.2.1 est gouverné par un hyperparamètre déterminant le nombre de variables proposées à chaque nœud. Une valeur faible accroît la diversité entre les arbres et réduit leur corrélation, ce qui renforce l'effet de l'agrégation. Une valeur trop faible prive toutefois fréquemment les arbres des variables les plus déterminantes et dégrade la qualité individuelle de chacun d'eux.

Ce compromis mérite une attention particulière dans le cadre de cette étude. Le modèle ne comporte que neuf variables explicatives, toutes retenues pour leur contribution significative à la variable cible.

L'espace des variables est donc réduit et ne contient aucune variable négligeable dont l'exclusion serait sans conséquence.

Les valeurs 3, 5, 7 et 9 ont été testées. La configuration retenue rend l'intégralité des neuf variables disponibles à chaque division.

Ce résultat appelle une précision. En fixant le nombre de variables candidates à la totalité des variables disponibles, la sélection aléatoire décrite à la section 3.2.2.1 devient inopérante : le modèle retenu correspond alors à un *bagging* d'arbres de décision plutôt qu'à un Random Forest au sens strict. Cette configuration s'explique par la structure de la base. Les neuf variables résultent d'une sélection préalable et aucune n'est négligeable ; la décorrélation obtenue en restreignant le nombre de variables candidates prive donc les arbres d'une information utile sans contrepartie. L'écart entre sept et neuf variables candidates reste toutefois limité, de l'ordre de 2 %, ce qui indique que le mécanisme de diversification joue ici un rôle secondaire par rapport au tirage bootstrap.

Nombre d'arbres Il convient de préciser que le nombre d'arbres B ne constitue pas un paramètre de surapprentissage. La prédiction finale du modèle correspond en effet à une moyenne des prédictions individuelles, conformément à l'équation (3.15). Augmenter B revient à moyenner un nombre plus élevé de réalisations d'un même mécanisme aléatoire, ce qui stabilise la prédiction sans accroître la complexité du modèle.

L'ajout d'arbres supplémentaires réduit ainsi la variance du modèle et ses performances se stabilisent à partir d'un certain seuil. Le choix de B relève donc d'un compromis entre stabilité des résultats et temps de calcul, et non d'un arbitrage entre biais et variance. Cette propriété distingue nettement le Random Forest des méthodes de boosting, pour lesquelles le nombre d'arbres joue au contraire un rôle central.

Les valeurs 25, 50, 100, 150, 200, 300, 400 et 500 ont été examinées. Le nombre de 300 arbres a été retenu au vu de la stabilisation de l'erreur *Out of Bag* présentée à la section 3.3.3.2.

TABLE 3.4 – Erreur de validation croisée du Random Forest selon les hyperparamètres testés (points de PM, 300 arbres)

Profondeur maximale (feuilles d'une observation, neuf variables candidates)		
Aucune limite	1,710	0,040
16	1,738	0,040
12	2,110	0,036
8	2,856	0,036
Taille minimale des feuilles (profondeur non contrainte, neuf variables)		
1	1,710	0,040
5	2,070	0,040
20	2,567	0,044
50	2,890	0,050
Variables candidates par division (profondeur non contrainte, feuilles d'une observation)		
9	1,710	0,040
7	1,751	0,036
5	1,872	0,036
3	2,162	0,038

3.3.2.4 Le XGBoost

La construction séquentielle décrite à la section 3.2.2.2 modifie profondément la nature du risque de surapprentissage. Chaque nouvel arbre étant ajouté afin de corriger les erreurs résiduelles des arbres précédents, la complexité de l'ensemble s'accroît à chaque itération. Le nombre d'arbres devient donc lui-même un paramètre de complexité, ce qui justifie la mise en place de plusieurs mécanismes de contrôle complémentaires.

Learning rate. Le paramètre η introduit à l'équation (3.20) réduit la contribution de chaque arbre à la prédiction d'ensemble. Il empêche ainsi qu'une correction de forte amplitude, éventuellement construite à partir d'un nombre restreint d'observations, ne soit intégralement intégrée au modèle.

Une valeur faible de η ralentit la convergence et nécessite un nombre d'arbres plus important, mais chaque correction devient plus progressive et le modèle final dépend moins fortement d'observations particulières.

Les valeurs 0,01, 0,02, 0,05 et 0,1 ont été testées. La valeur retenue est $\eta = 0,02$.

Nombre d'arbres et arrêt anticipé. Le nombre d'arbres n'est pas fixé a priori mais déterminé à partir des données, au moyen d'un mécanisme d'arrêt anticipé (*early stopping*). À chaque itération t , l'erreur du modèle est évaluée sur un échantillon de validation n'ayant pas servi à la construction des arbres. Cette erreur, notée $L_{\text{val}}(t)$, diminue tant que les arbres successifs apportent une information généralisable, puis se stabilise et peut finir par augmenter lorsque le modèle commence à ajuster des fluctuations propres à l'échantillon d'apprentissage.

L'itération retenue correspond à celle minimisant cette erreur :

$$t^* = \arg \min_{1 \leq t \leq K_{\max}} L_{\text{val}}(t). \quad (3.28)$$

En pratique, la construction est interrompue dès qu'aucune amélioration n'est constatée pendant un nombre d'itérations consécutives fixé à l'avance, appelé patience. Ce délai évite d'arrêter prématurément l'apprentissage lors d'une stagnation temporaire de l'erreur. Le modèle finalement conservé correspond alors à l'itération t^* et non à la dernière itération construite.

L'échantillon de validation mobilisé à cette fin est prélevé au sein de l'échantillon d'apprentissage, conformément au protocole défini à la section 3.3.1. L'échantillon de test n'intervient à aucun moment dans la détermination du nombre d'arbres.

Ce mécanisme interagit directement avec le learning rate : plus η est faible, plus les itérations successives apportent des modifications limitées, et plus la détermination du nombre optimal d'arbres devient précise.

Le nombre maximal d'itérations a été fixé à $K_{\max} = 15\,000$ et la patience à 50 itérations. L'arrêt anticipé s'est déclenché à $t^* = 12\,516$ arbres, soit avant la borne autorisée. Cette dernière n'a donc pas contraint la sélection, et le nombre d'arbres retenu résulte effectivement du minimum de l'erreur de validation et non d'une limite fixée a priori.

Profondeur maximale des arbres. La profondeur maximale est contrainte selon le même principe que pour le Random Forest. Ce paramètre présente toutefois une portée supplémentaire dans le cadre de cette étude, car il détermine l'ordre des interactions que le modèle peut représenter.

Un arbre de profondeur d applique en effet au plus d divisions successives le long d'une branche. Il ne peut donc combiner qu'au maximum d variables pour définir une région de l'espace, et représente ainsi des interactions d'ordre au plus d . Une profondeur de 2 permet de capter des interactions entre deux variables, une profondeur de 3 des interactions entre trois variables, et ainsi de suite.

Ce paramètre doit par conséquent être calibré avec attention. Une profondeur trop faible priverait le modèle de la capacité à représenter les interactions entre variables, alors que l'existence de telles interactions constitue précisément l'une des hypothèses motivant le recours aux méthodes non linéaires. Une profondeur trop élevée exposerait à l'inverse le modèle au surapprentissage.

Les profondeurs 2, 3, 4, 5, 6 et 8 ont été testées, et la valeur de 6 a été retenue. L'erreur de validation croisée décroît de façon monotone jusqu'à cette profondeur, ce qui constitue un premier élément en faveur de l'existence d'interactions d'ordre supérieur à deux dans les résultats produits par SALLTO. Ce point sera repris à la section 4.3 à partir de l'analyse des valeurs de Shapley.

Sous-échantillonnage des observations et des variables. Un sous-échantillonnage aléatoire est appliqué lors de la construction de chaque arbre, selon deux dimensions. Le premier porte sur les observations : seule une fraction de l'échantillon d'apprentissage, tirée aléatoirement, est utilisée pour construire un arbre donné. Le second porte sur les variables explicatives : seule une fraction d'entre elles est rendue disponible pour déterminer les divisions.

Ces mécanismes introduisent dans le boosting une logique de diversification proche de celle décrite pour le Random Forest à la section 3.2.2.1. Ils évitent que la construction séquentielle ne se concentre systématiquement sur les mêmes observations ou sur les mêmes variables, et réduisent ainsi la dépendance du modèle final à des configurations particulières.

Comme pour le Random Forest, le sous-échantillonnage des variables doit rester modéré compte tenu du nombre restreint de variables explicatives retenues.

Les fractions 0,6, 0,8 et 1,0 ont été testées pour chacune des deux dimensions. La valeur de 0,8 a été retenue dans les deux cas, soit un sous-échantillonnage modéré conforme à la remarque formulée plus haut sur le nombre restreint de variables explicatives.

Paramètres de régularisation. Les paramètres γ et λ introduits à l'équation (3.19) complètent ces mécanismes en agissant directement sur la fonction objectif. Le premier pénalise l'ajout de feuilles supplémentaires et limite ainsi la subdivision de l'espace par chaque arbre. Le second contraint l'amplitude des valeurs attribuées aux feuilles et limite donc la portée de chaque correction.

Ces deux paramètres opèrent au niveau de chaque arbre pris individuellement, tandis que l'arrêt anticipé agit au niveau du nombre total d'arbres composant le modèle. Ils sont donc complémentaires.

Les valeurs 0,0, 0,1 et 1,0 ont été testées pour γ , et les valeurs 0,5, 1,0, 5,0 et 10,0 pour λ . La configuration retenue associe $\gamma = 0$ et $\lambda = 5$.

Le paramètre γ constitue de loin l'hyperparamètre le plus discriminant de la recherche. Toutes les configurations construites avec $\gamma = 1$ atteignent une erreur de validation croisée voisine de celle du GLM : la pénalisation du gain minimal exigé pour accepter une division bloque alors la construction des arbres et prive le modèle de sa flexibilité. La régularisation opère ici par le sous-échantillonnage et par la contrainte λ sur l'amplitude des valeurs de feuilles, non par la limitation du nombre de divisions.

TABLE 3.5 – Erreur de validation croisée du XGBoost selon les hyperparamètres testés (points de PM, 40 configurations évaluées)

Paramètre γ			
0,0	2,124	2,443	11
0,1	3,292	3,457	15
1,0	3,887	3,938	14
Profondeur maximale (configurations à $\gamma = 0$)			
2	3,206	—	2
3	2,703	—	2
4	2,438	—	3
5	2,418	—	1
6	2,124	—	3

3.3.2.5 Méthode de recherche retenue

La calibration des hyperparamètres du Random Forest et de XGBoost repose sur la validation croisée définie à la section 3.3.1. Chaque configuration candidate est évaluée à partir de l'erreur Err_{CV} de l'équation (3.24), calculée exclusivement au sein de l'échantillon d'apprentissage. La configuration finalement retenue est celle minimisant cette erreur.

Le modèle correspondant est ensuite réestimé sur l'intégralité de l'échantillon d'apprentissage à partir de ces valeurs, puis évalué sur l'échantillon de test.

La méthode d'exploration diffère selon le modèle. L'espace des hyperparamètres du Random Forest se réduit à trois dimensions discrètes, ce qui rend praticable une recherche exhaustive : les 64 combinaisons issues du croisement des quatre profondeurs, des quatre tailles minimales de feuilles et des quatre nombres de variables candidates ont toutes été évaluées.

L'espace du XGBoost en comporte sept, soit plusieurs milliers de combinaisons pour les plages retenues. Une recherche aléatoire portant sur 40 configurations tirées au sein de ces plages a donc été privilégiée, cette approche couvrant l'espace de façon plus efficace qu'une grille de même budget de calcul.

Dans les deux cas, la validation croisée comporte $k = 5$ blocs et le critère d'optimisation est la RMSE, conformément au choix formulé à la section 3.4.2. Le tableau 3.6 récapitule ce dispositif et le tableau 3.7 les valeurs finalement adoptées.

Le tableau ?? synthétise les valeurs finalement adoptées pour chacun des modèles.

TABLE 3.6 – Dispositif de recherche des hyperparamètres

Méthode d'exploration	Recherche exhaustive	Recherche aléatoire
Configurations évaluées	64	40
Blocs de validation croisée	5	5
Critère d'optimisation	RMSE	RMSE
Meilleure ErrCV (points de PM)	1,710	2,124
ErrCV la plus élevée de la grille	3,238	3,971

TABLE 3.7 – Hyperparamètres testés et valeurs retenues pour chacun des modèles

GLM	Aucun	Sans objet	Sans objet
Random Forest	Nombre d'arbres	25 ; 50 ; 100 ; 150 ; 200 ; 300 ; 400 ; 500	300
	Profondeur maximale	8 ; 12 ; 16 ; aucune limite	Aucune limite
	Taille minimale des feuilles	1 ; 5 ; 20 ; 50	1
	Variables par division	3 ; 5 ; 7 ; 9	9
XGBoost	Learning rate η	0,01 ; 0,02 ; 0,05 ; 0,1	0,02
	Nombre d'arbres	Arrêt anticipé ($K_{\max} = 15\,000$, patience 50)	12 516
	Profondeur maximale	2 ; 3 ; 4 ; 5 ; 6 ; 8	6
	Fraction d'observations	0,6 ; 0,8 ; 1,0	0,8
	Fraction de variables	0,6 ; 0,8 ; 1,0	0,8
	γ	0,0 ; 0,1 ; 1,0	0,0
	λ	0,5 ; 1,0 ; 5,0 ; 10,0	5,0

3.3.3 Diagnostics et validation de l'apprentissage

Les hyperparamètres définis à la section précédente visent à positionner chaque modèle au meilleur compromis entre biais et variance. Il reste à vérifier que cet objectif est effectivement atteint.

Cette section présente les diagnostics mis en œuvre à cette fin. Ils interviennent après l'apprentissage et poursuivent une logique différente de celle des hyperparamètres : il ne s'agit plus de contraindre la complexité des modèles, mais de vérifier que les contraintes retenues produisent le résultat attendu.

3.3.3.1 Courbes d'apprentissage

Les courbes d'apprentissage représentent l'évolution conjointe de l'erreur mesurée sur l'échantillon d'apprentissage et de celle mesurée sur l'échantillon de validation, en fonction du nombre d'arbres ou d'itérations construits.

Leur lecture repose sur la comparaison des deux trajectoires. Les deux erreurs diminuent d'abord conjointement, ce qui traduit un apprentissage effectif de la relation entre les variables explicatives et la cible. L'erreur de validation se stabilise ensuite, puis peut augmenter alors que l'erreur d'apprentissage continue de décroître. Ce point d'inflexion marque le moment à partir duquel le modèle cesse d'apprendre une structure généralisable et commence à ajuster les particularités de l'échantillon d'apprentissage.

Ces courbes fournissent ainsi une représentation directe du compromis formalisé à l'équation (3.25). Elles permettent de vérifier que la calibration retenue place effectivement chaque modèle avant ce point d'inflexion.

Leur interprétation diffère toutefois selon la méthode considérée. Pour XGBoost, elles constituent la représentation directe du mécanisme d'arrêt anticipé décrit à la section 3.3.2 : l'itération t^* de l'équation (3.28) correspond au minimum de la courbe de validation. Pour le Random Forest, en revanche, une divergence entre les deux courbes n'est pas attendue à mesure que le nombre d'arbres augmente, puisque ce paramètre ne constitue pas un levier de surapprentissage. La courbe de validation doit y décroître puis se stabiliser, ce qui permet de vérifier que le nombre d'arbres retenu est suffisant.




FIGURE 3.2 – Courbes d'apprentissage pour le Random Forest et XGBoost

La lecture des courbes obtenues confirme les comportements attendus. Pour le XGBoost, le minimum de l'erreur de validation est atteint à $t^* = 12516$ itérations, la RMSE passant de 1,678 point de PM en apprentissage à 2,074 points sur l'échantillon de test. Pour le Random Forest, aucune divergence entre les deux trajectoires n'apparaît à mesure que le nombre d'arbres augmente : l'erreur de validation décroît puis se stabilise, conformément à la propriété rappelée à la section 3.3.2.3.

3.3.3.2 Erreur *Out of Bag*

Le mécanisme de bootstrap décrit à la section 3.2.2.1 offre pour le Random Forest une possibilité d'évaluation intégrée au modèle. Chaque arbre étant construit à partir d'un tirage avec remise parmi les n observations d'apprentissage, une partie de ces observations n'est pas retenue pour la construction d'un arbre donné. La probabilité qu'une observation donnée ne soit jamais tirée lors de la constitution d'un échantillon bootstrap vaut :

$$\left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-1} \approx 0,368. \quad (3.29)$$

Environ 37 % des observations se trouvent donc exclues de la construction de chaque arbre. Ces observations, dites *Out of Bag*, constituent pour cet arbre un échantillon non utilisé lors de l'apprentissage.

En notant $\mathcal{B}_i$ l'ensemble des arbres pour lesquels l'observation i est *Out of Bag*, une prédiction peut être construite en n'agrégeant que ces arbres :

$$\hat{f}_{\text{OOB}}(x_i) = \frac{1}{|\mathcal{B}_i|} \sum_{b \in \mathcal{B}_i} T_b(x_i). \quad (3.30)$$

L'erreur *Out of Bag* correspond alors à l'erreur moyenne obtenue à partir de ces prédictions :

$$\text{Err}_{\text{OOB}} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}_{\text{OOB}}(x_i)). \quad (3.31)$$

Cette mesure fournit une estimation de l'erreur de généralisation sans mobiliser l'échantillon de test, et pour un coût de calcul négligeable puisqu'elle réutilise les arbres déjà construits. Elle permet notamment de vérifier que le nombre d'arbres retenu est suffisant : sa stabilisation indique que l'ajout d'arbres supplémentaires n'apporte plus de gain.

Ce diagnostic demeure propre au Random Forest. Les arbres de XGBoost étant construits séquentiellement sur l'ensemble des observations disponibles, aucun échantillon *Out of Bag* équivalent n'y est défini.

TABLE 3.8 – Stabilisation de l'erreur *Out of Bag* du Random Forest (RMSE en points de PM)

	25	1,707	0,832	—
	50	1,632	0,847	4,42 %
	100	1,595	0,853	2,26 %
	150	1,585	0,855	0,63 %
	200	1,575	0,857	0,60 %
	300	1,572	0,858	0,18 %
	400	1,569	0,858	0,22 %
	500	1,568	0,858	0,04 %

L'erreur *Out of Bag* décroît fortement jusqu'à une centaine d'arbres, puis se stabilise. Le passage de 300 à 500 arbres ne réduit l'erreur que de 0,27 %, gain sans commune mesure avec le coût de calcul associé. Le nombre de 300 arbres retenu à la section 3.3.2.3 se situe donc bien dans la zone de stabilisation.

Cette mesure fournit par ailleurs une vérification indépendante de la performance du modèle. L'erreur *Out of Bag* obtenue avec 300 arbres s'établit à 1,572 point de PM, contre une RMSE de 1,551 point mesurée sur l'échantillon de test. La concordance de ces deux estimations, issues de mécanismes d'évaluation distincts, conforte la validité des indicateurs présentés au chapitre 4.

3.3.3.3 Comparaison des performances en apprentissage et en test

Les indicateurs de performance présentés à la section 3.4 sont calculés à la fois sur l'échantillon d'apprentissage et sur l'échantillon de test, pour chacun des modèles finalement retenus.

Un modèle présentant une performance élevée en apprentissage et nettement dégradée en test manifeste

directement un surapprentissage. À l'inverse, un écart réduit entre les deux échantillons indique que le modèle a principalement appris une structure généralisable à l'intérieur du domaine étudié.

L'ampleur attendue de cet écart diffère selon les modèles. Le GLM, fortement contraint, devrait présenter des performances proches sur les deux échantillons. Les méthodes fondées sur les arbres, plus flexibles, sont susceptibles de manifester un écart plus marqué, dont l'ampleur constitue précisément un indicateur de la qualité de la calibration retenue à la section 3.3.2.

Cette comparaison ne constitue toutefois pas une garantie de généralisation au-delà du domaine étudié. Les deux échantillons proviennent en effet de la même grille de configurations et du même portefeuille central. Un modèle peut donc présenter un écart faible entre apprentissage et test tout en restant fortement dépendant des caractéristiques du portefeuille ayant servi à sa construction, conformément à la limite déjà identifiée à la section 3.2.3.

TABLE 3.9 – Comparaison des performances en apprentissage et en test (RMSE en points de PM)

GLM	3,852	3,922	+0,071	+1,8 %
Random Forest	0,580	1,551	+0,971	+167,3 %
XGBoost	1,678	2,074	+0,396	+23,6 %

Le GLM présente, comme attendu, des performances quasi identiques sur les deux échantillons, l'écart relatif ne dépassant pas 1,8 %. Le XGBoost manifeste un écart plus marqué, de l'ordre de 24 %, cohérent avec sa flexibilité et avec le mécanisme d'arrêt anticipé qui le contraint.

L'écart mesuré pour le Random Forest, supérieur à 167 %, appelle une interprétation plus attentive. Il résulte mécaniquement de la configuration retenue à la section 3.3.2.3 : des arbres non élagués dont les feuilles peuvent ne contenir qu'une seule observation reproduisent presque exactement l'échantillon d'apprentissage. La RMSE de 0,580 point de PM obtenue sur cet échantillon ne mesure donc pas une capacité de généralisation mais une capacité de mémorisation, propre à la construction des arbres individuels.

Trois éléments écartent l'hypothèse d'un surapprentissage effectif. La RMSE de test du Random Forest est la plus faible des trois modèles. L'erreur *Out of Bag*, estimée sans mobiliser l'échantillon de test, s'établit à 1,572 point de PM, soit un niveau très proche de la performance de test. La dispersion des performances sur les dix répétitions de tirage, présentée à la section 4.2, reste enfin inférieure en valeur absolue à celle du GLM. Le modèle apprend donc bien une structure généralisable à l'intérieur du domaine des sensibilités, et l'écart observé traduit la nature de la méthode plutôt qu'une défaillance de calibration.

3.3.3.4 Articulation avec la validation externe

L'ensemble de ces diagnostics s'inscrit dans le protocole défini à la section 3.3.1. La recherche des hyperparamètres s'appuie sur une validation croisée réalisée exclusivement au sein de l'échantillon d'apprentissage, l'échantillon de test n'intervenant qu'au moment de l'évaluation finale.

La validation externe, conduite sur la base construite à partir d'un second portefeuille central, constitue le test de robustesse le plus exigeant de l'étude. Les modèles y sont appliqués sans réestimation à des configurations extérieures au domaine ayant servi à leur apprentissage. Elle permet ainsi d'évaluer ce que

les diagnostics internes ne peuvent mesurer, à savoir la capacité des modèles à conserver leur pertinence en dehors du portefeuille et des sensibilités retenus pour leur construction.

Le tableau 3.10 synthétise l'ensemble du dispositif.

TABLE 3.10 – Diagnostics et niveaux de validation retenus

Diagnostic	Modèles concernés	Objectif
Courbes d'apprentissage	Random Forest, XG-Boost	Identifier le point à partir duquel le modèle cesse d'apprendre une structure généralisable
Erreur <i>Out of Bag</i>	Random Forest	Estimer l'erreur de généralisation sans mobiliser l'échantillon de test
Comparaison apprentissage / test	Les trois modèles	Mesurer directement l'écart de performance révélateur d'un surapprentissage
Validation externe	Les trois modèles	Évaluer la robustesse des modèles en dehors du portefeuille d'apprentissage

3.4 Critères de performance

Les sections précédentes ont défini la manière dont les modèles sont estimés et validés. Il reste à préciser les indicateurs utilisés pour mesurer leur qualité, ainsi que la façon dont ces mesures seront comparées et interprétées.

Dans l'ensemble de cette section, n désigne le nombre d'observations de l'échantillon considéré, y_i la valeur de la variable cible obtenue avec SALLTO et $\hat{y}_i$ la valeur prédite par le modèle.

3.4.1 Indices retenus

Trois indicateurs complémentaires sont retenus. Ils mesurent la même erreur de prédiction, mais en donnent des lectures différentes.

Racine de l'erreur quadratique moyenne (RMSE). La RMSE (*Root Mean Squared Error*) correspond à la racine carrée de la moyenne des erreurs au carré :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (3.32)$$

Elle s'exprime dans la même unité que la variable cible, c'est-à-dire en pourcentage des provisions mathématiques. Cette propriété lui confère une lecture directe : pour le portefeuille central, dont l'écart relatif s'établit à 1,89 % (cf. équation 2.7), une RMSE de 0,10 point de PM représente une erreur de l'ordre de

145 milliers d'euros sur un portefeuille de 145 millions d'euros.

L'élévation au carré confère par ailleurs un poids plus important aux erreurs de forte amplitude. La RMSE pénalise donc davantage un modèle commettant quelques erreurs importantes qu'un modèle dont les erreurs sont réparties de manière homogène.

Erreur absolue moyenne (MAE) La MAE (*Mean Absolute Error*) correspond à la moyenne des écarts en valeur absolue :

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (3.33)$$

Elle s'exprime également en pourcentage des provisions mathématiques et traduit l'amplitude moyenne de l'erreur commise, toutes les observations étant pondérées de manière identique.

La comparaison entre les deux indicateurs apporte une information supplémentaire. La RMSE est toujours supérieure ou égale à la MAE, et l'écart entre elles augmente avec la dispersion des erreurs. Deux valeurs proches indiquent des erreurs d'amplitude homogène sur l'ensemble du domaine, tandis qu'un écart marqué signale que l'erreur se concentre sur un nombre restreint de configurations. Cette seconde situation mérite une attention particulière : elle suggère l'existence de zones du domaine que le modèle reproduit mal, par exemple les environnements de taux les plus bas.

Coefficient de détermination Le coefficient de détermination rapporte l'erreur du modèle à la variabilité totale de la variable cible :

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad \text{où } \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i. \quad (3.34)$$

Il s'interprète comme la part de la variance de la variable cible reproduite par le modèle. Contrairement aux deux indicateurs précédents, il ne possède pas d'unité, ce qui permet de comparer des résultats obtenus sur des bases dont la dispersion diffère. Cette propriété sera utile lors de la validation externe présentée à la section 3.3.2.5, la variabilité de l'écart pouvant différer d'un portefeuille central à l'autre.

Le dénominateur correspond à l'erreur d'un modèle qui prédirait systématiquement la moyenne $\bar{y}$, sans utiliser aucune variable explicative. Le coefficient de détermination compare donc implicitement chaque modèle à cette référence naïve. Une valeur de 0 traduit une performance équivalente à celle de la moyenne, et une valeur négative, possible sur un échantillon de test, indiquerait un modèle moins performant qu'elle.

Biais moyen Les trois indicateurs précédents mesurent l'amplitude de l'erreur mais pas son sens. Un quatrième indicateur complète donc l'analyse :

$$\text{Biais} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i). \quad (3.35)$$

À la différence de la MAE, les erreurs positives et négatives se compensent ici. Une valeur proche de

zéro indique que le modèle ne se trompe pas systématiquement dans le même sens, même si l'amplitude de ses erreurs individuelles peut rester importante. Une valeur nettement différente de zéro signale au contraire une sous-estimation ou une surestimation systématique de l'écart entre les deux valorisations.

Cette vérification présente un intérêt particulier compte tenu de l'usage envisagé pour le métamodèle. Un proxy mobilisé pour des analyses exploratoires (cf. section 3.1.3) pourrait tolérer une dispersion modérée de ses erreurs, mais un biais systématique conduirait à sous-estimer ou surestimer de manière répétée le niveau du Best Estimate stochastique.

Indicateurs écartés Les mesures d'erreur relative, telles que la MAPE (*Mean Absolute Percentage Error*), n'ont pas été retenues. Elles rapportent l'erreur à la valeur observée et deviennent instables lorsque celle-ci s'approche de zéro. Or la variable cible peut prendre des valeurs faibles dans les configurations où les taux d'intérêt sont élevés, le coût des garanties financières se réduisant alors fortement. Ces configurations produiraient des erreurs relatives très importantes sans que cela traduise une réelle dégradation du modèle.

TABLE 3.11 – Indicateurs de performance retenus

Indicateur	Unité	Lecture
RMSE	Point de PM	Amplitude de l'erreur, avec un poids accru pour les erreurs les plus fortes. Critère principal de comparaison
MAE	Point de PM	Amplitude moyenne de l'erreur, toutes observations pondérées de façon identique
R^2	Sans unité	Part de la variance reproduite, par rapport à un modèle prédisant la moyenne
Biais	Point de PM	Sens de l'erreur, permettant de détecter une sous-estimation ou une surestimation systématique

3.4.2 Comparaison des modèles

Les trois modèles sont estimés dans des conditions identiques. Ils s'appuient sur la même répartition de la base, sur les mêmes répétitions de tirage et sur les mêmes échantillons pour le calcul des indicateurs, conformément au protocole défini à la section 3.3.1. Cette homogénéité est nécessaire pour que les différences observées reflètent les propriétés des modèles et non les conditions de leur estimation.

La RMSE constitue le critère principal de comparaison. C'est également elle qui sert de critère d'optimisation lors de la recherche des hyperparamètres décrite à la section 3.3.3.5 : la configuration retenue pour chaque modèle est celle minimisant l'erreur de validation croisée Err_{CV} de l'équation (3.25), calculée à partir de cet indicateur. Les autres mesures interviennent en complément, afin de préciser la nature des erreurs commises plutôt que de départager les modèles.

La comparaison ne porte pas sur la recherche du modèle le plus performant dans l'absolu. Elle vise à déterminer si la complexité supplémentaire introduite par les méthodes non linéaires apporte un gain

réel par rapport au modèle de référence, conformément au rôle de *benchmark* attribué au GLM à la section 3.1.3. Le gain relatif apporté par un modèle m peut ainsi s'écrire :

$$\Delta_m = \frac{\text{RMSE}_{\text{GLM}} - \text{RMSE}_m}{\text{RMSE}_{\text{GLM}}}. \quad (3.36)$$

Cette formulation exprime directement la réduction d'erreur obtenue par rapport à une modélisation linéaire et additive de l'écart.

Un tel gain ne peut toutefois être considéré comme significatif que s'il dépasse la variabilité induite par le seul choix de la répartition des données. La dispersion $\hat{\sigma}_M$ définie à l'équation (3.23) fournit précisément cette échelle de référence : un écart de performance dont l'amplitude resterait comparable à cette dispersion ne permettrait pas de conclure en faveur des méthodes non linéaires.

Les indicateurs sont enfin calculés à chacun des niveaux de validation présentés au tableau 3.2, à savoir l'échantillon d'apprentissage, l'échantillon de test, l'ensemble des répétitions et la base construite à partir du second portefeuille central. La comparaison des modèles s'appuie donc sur quatre lectures distinctes, dont l'articulation est précisée ci-après.

3.4.3 Lecture des performances

Un indicateur de performance ne possède pas de signification en lui-même. Sa lecture suppose de disposer de points de comparaison, et trois références sont mobilisées dans cette étude.

Le modèle naïf La première référence correspond à un modèle prédisant systématiquement la moyenne de la variable cible. Elle est directement intégrée au coefficient de détermination de l'équation (3.34) et constitue le seuil minimal en deçà duquel un modèle n'apporte aucune information.

Le GLM La deuxième référence est le modèle linéaire généralisé. L'écart entre ses performances et celles des méthodes non linéaires renseigne sur la nature de la relation apprise. Un gain faible indiquerait que l'écart entre les deux valorisations est essentiellement gouverné par des effets additifs, tandis qu'un gain marqué apporterait des éléments en faveur de l'existence de non-linéarités et d'interactions dans les résultats produits par SALLTO.

Cette lecture prolonge directement la question posée à la section 3.1.3 et constitue l'un des résultats attendus du chapitre suivant.

Le bruit irréductible La troisième référence tient à la nature même des données. Le Best Estimate stochastique étant estimé à partir de 1 000 simulations, la variable cible comporte une composante d'erreur de Monte-Carlo qu'aucun modèle ne peut reproduire, correspondant au terme σ^2 de l'équation (3.26).

Il en résulte qu'un coefficient de détermination égal à 1 n'est pas atteignable, et ne constitue pas non plus un objectif souhaitable. Un modèle qui s'en approcherait trop reproduirait vraisemblablement les fluctuations de simulation plutôt que la relation sous-jacente, ce qui traduirait un surapprentissage au sens de la section 3.3.3.1. Un modèle dont l'erreur se rapproche du niveau de bruit sans le franchir peut au contraire être considéré comme ayant appris l'essentiel de l'information disponible.

Portée des résultats obtenus sur l'échantillon de test Les performances mesurées sur l'échantillon de test doivent être interprétées à la lumière des modalités de tirage décrites à la section 3.3.2.2. Ce dernier étant constitué par tirage aléatoire au sein d'une grille factorielle complète, les configurations qu'il contient possèdent des voisines directes dans l'échantillon d'apprentissage. Les indicateurs obtenus mesurent donc une capacité d'interpolation à l'intérieur du domaine des sensibilités.

Une dégradation des performances lors de la validation externe est par conséquent attendue, puisque celle-ci porte sur un portefeuille central différent. Son ampleur constitue l'information recherchée : une dégradation limitée suggérerait que les relations apprises dépassent le seul portefeuille d'apprentissage, tandis qu'une dégradation marquée confirmerait la dépendance du métamodèle à ses conditions de construction.

Performance et explication Ces indicateurs ne mesurent enfin qu'une seule des deux dimensions retenues à la section 3.1.2. Un modèle peut reproduire fidèlement la variable cible sans pour autant permettre de comprendre les mécanismes à l'origine des écarts, et la comparaison des performances ne suffit donc pas à départager les modèles au regard de l'objectif du mémoire.

L'analyse conduite au chapitre suivant associe pour cette raison ces mesures à l'examen des coefficients du GLM et aux contributions obtenues par la méthode SHAP, afin de déterminer si une éventuelle amélioration de la performance prédictive s'accompagne également d'une meilleure compréhension des facteurs explicatifs.

Chapitre 4

Analyse des résultats et rationalisation des écarts

4.1 Statistiques descriptives des données

4.1.1 Statistiques descriptives de la variable cible




FIGURE 4.1 – Distribution de la variable cible (écart relatif entre valorisation déterministe et stochastique)

TABLE 4.1 – Distribution de la variable cible sur les 51 840 configurations

Moyenne	2,84 %	2,840	4 118
Écart-type	4,19 %	4,188	6 072
Minimum	-17,74 %	-17,742	-25 726
1 ^{er} quartile	0,79 %	0,790	1 146
Médiane	1,78 %	1,782	2 584
3 ^e quartile	3,87 %	3,870	5 611
Maximum	24,92 %	24,918	36 131

Trois enseignements se dégagent de cette distribution.

La médiane, égale à 1,78 %, est très proche de l'écart relatif du portefeuille central non stressé, établi à 1,89 % à l'équation (2.7). La grille de sensibilités est donc bien centrée sur la configuration de référence, ce qui confirme la cohérence du plan d'expérience construit au chapitre 2.

La moyenne, égale à 2,84 %, dépasse nettement la médiane : la distribution est asymétrique à droite. Les configurations les plus coûteuses en valeur temps des options et garanties, associant taux bas, TMG élevé et duration longue, produisent des écarts très supérieurs à la tendance centrale, alors que les configurations favorables sont bornées par le bas. Cette asymétrie est la traduction directe de la nature optionnelle des garanties évaluées.

L'étendue enfin est considérable, de $-17,74\%$ à $+24,92\%$, soit plus de 42 points de PM ou 61 millions d'euros. Les valeurs négatives correspondent aux environnements dans lesquels la valorisation stochastique ressort en deçà de la valorisation déterministe. L'écart-type de 4,19 points de PM constitue par ailleurs la référence naïve mentionnée à la section 3.4.3 : un modèle prédisant systématiquement la moyenne obtient une RMSE égale à cette valeur.

4.1.2 Statistiques descriptives des variables explicatives

TABLE 4.2 – Statistiques descriptives des neuf variables explicatives

	3,00	1,414	1	3	5
Courbe des taux (ordinal)	3,00	1,414	1	3	5
Spread	1,09 %	0,75 %	0,00 %	1,18 %	2,00 %
Volatilité des taux	0,60 %	0,25 %	0,30 %	0,60 %	0,90 %
Volatilité des actions	15,00 %	4,08 %	10,00 %	15,00 %	20,00 %
Garantie de taux (binaire)	0,50	0,500	0	—	1
PMVL actions	17,50 %	25,86 %	$-20,00\%$	20,00 %	50,00 %
Rachats conjoncturels (ordinal)	2,00	0,817	1	2	3
Duration du passif (années)	10,00	2,450	7	10	13
TMG	0,88 %	0,74 %	0,00 %	0,75 %	2,00 %




FIGURE 4.2 – Matrices de corrélation entre les variables explicatives




FIGURE 4.3 – Corrélations entre la variable cible et les variables explicatives

Les corrélations croisées entre variables explicatives sont toutes nulles, en Pearson comme en Spearman, conséquence directe du plan factoriel complet déjà commentée à la section 3.3.2.2. Seule la dernière ligne des matrices de la figure 4.2 porte donc une information.

Aucune corrélation linéaire avec la variable cible ne dépasse 0,26 en valeur absolue. Prises isolément, les neuf variables rendent ainsi très peu compte de la variabilité de l'écart entre les deux valorisations. Ce constat préfigure directement le coefficient de détermination de 0,14 obtenu par le GLM à la section suivante.

La comparaison des deux coefficients apporte un élément supplémentaire. L'écart entre le coefficient de Spearman et celui de Pearson est systématiquement positif pour les sept variables les plus influentes, et particulièrement marqué pour la courbe des taux, dont la corrélation passe de $-0,171$ à $-0,356$. La relation entre le niveau des taux et l'écart de valorisation est donc monotone mais fortement non linéaire. Obtenu avant toute modélisation, ce résultat constitue le premier indice de l'insuffisance d'une spécification linéaire.

	Modalité la plus fréquente	Part dans les extrêmes	Part dans la base
Courbe des taux	4.000	0.283	0.200
Spread	0.000	0.274	0.250
Volatilité des taux	0.009	0.518	0.333
Volatilité des actions	0.200	0.378	0.333
Garantie de taux	0.000	0.556	0.500
PMVL actions	0.300	0.316	0.250
Rachats conjoncturels	3.000	0.352	0.333
Duration du passif	13.000	0.415	0.333
TMG	0.010	0.307	0.250

FIGURE 4.4 – Configurations extrêmes de la variable cible (écart relatif entre valorisation déterministe et stochastique)

4.2 Performance des modèles (test, comparaison GLM / RF / XGBoost, stabilité sur les répétitions)




FIGURE 4.5 – Comparaison des performances des modèles

TABLE 4.3 – Performances des modèles sur l'échantillon de test (15 552 configurations, indicateurs en points de PM sauf R^2)

Modèle naïf	4,237	2,991	0,000	-0,003	—	6 143
GLM	3,922	2,453	0,143	+0,009	3,853	5 688
Random Forest	1,551	0,759	0,866	+0,003	1,710	2 249
XGBoost	2,074	1,417	0,760	-0,005	2,124	3 007

TABLE 4.4 – Gains apportés par les modèles non linéaires

GLM	7,4 %	référence	—	—
Random Forest	63,4 %	60,5 %	2,372	3 439
XGBoost	51,0 %	47,1 %	1,848	2 680




FIGURE 4.6 – Comparaison des prédictions et des résidus des modèles

4.2.1 Stabilité sur les 10 répétitions

TABLE 4.5 – Stabilité des performances sur les dix répétitions de tirage (RMSE en points de PM)

GLM	3,872	0,034	[3,826 ; 3,935]	0,89 %	0,145
Random Forest	1,550	0,020	[1,518 ; 1,576]	1,30 %	0,863
XGBoost	2,066	0,020	[2,033 ; 2,088]	0,98 %	0,757

4.2.2 Significativité du gain

Le critère de significativité posé à la section 3.4.2 exige que le gain observé dépasse la variabilité induite par le seul choix de la répartition des données. Sur la moyenne des dix répétitions, le gain du Random Forest par rapport au GLM s'établit à 2,322 points de PM, à comparer à un écart-type combiné des deux modèles de 0,040 point. Le gain représente donc environ soixante fois la variabilité de tirage ; le rapport s'établit à quarante-cinq pour le XGBoost.

Les intervalles observés sur les dix répétitions ne se recoupent d'ailleurs à aucun endroit : la RMSE maximale du Random Forest, égale à 1,576, reste très inférieure à la RMSE minimale du XGBoost, égale à 2,033, elle-même très inférieure à la RMSE minimale du GLM, égale à 3,826. La hiérarchie des trois modèles se reproduit donc à l'identique sur chacune des répétitions.

4.2.3 Lecture des indicateurs

Le GLM ne reproduit que 14,3 % de la variance de la variable cible et n'améliore le modèle naïf que de 7,4 %. Une spécification linéaire et additive des neuf sensibilités ne rend donc pratiquement pas compte du comportement de SALLTO. Conformément à la lecture proposée à la section 3.4.3, ce résultat apporte un élément déterminant en faveur de l'existence de non-linéarités et d'interactions dans la formation de l'écart entre les deux valorisations.

Le rapport entre RMSE et MAE renseigne sur la concentration de l'erreur. Il s'établit à 1,60 pour le GLM, à 1,46 pour le XGBoost et à 2,04 pour le Random Forest. L'erreur de ce dernier est donc la plus concentrée : le modèle prédit très précisément la majorité des configurations, avec une erreur absolue moyenne de 0,759 point de PM soit environ 1,1 million d'euros, mais s'écarte plus nettement sur un nombre restreint d'entre elles. Cette situation, anticipée à la section 3.4.1, correspond aux configurations extrêmes du domaine étudié.

Les trois modèles sont enfin pratiquement non biaisés, le biais moyen restant inférieur à 0,01 point de PM en valeur absolue, soit moins de 15 milliers d'euros sur un portefeuille de 145 millions. Aucun ne sur-estime ni ne sous-estime systématiquement le Best Estimate stochastique, ce qui satisfait la condition posée à la section 3.4.1 pour un usage opérationnel du métamodèle.

Une dernière remarque porte sur l'écart entre l'erreur de validation croisée et la RMSE de test. Pour le Random Forest, l'ErrCV s'établit à 1,710 point de PM contre 1,551 point en test, et le même ordonnancement s'observe pour le XGBoost. Cet écart n'a rien d'anormal : en validation croisée, chaque modèle n'est estimé que sur quatre cinquièmes de l'échantillon d'apprentissage, soit environ 29 000 observations contre 36 288 pour le modèle final. L'ErrCV constitue donc une estimation légèrement pessimiste de la performance du modèle réestimé sur l'intégralité de l'échantillon.




FIGURE 4.7 – Hiérarchisation des facteurs d'écart selon les modèles (coefficients du GLM, importances, SHAP)

4.2.4 Sensibilité au mode de découpage

TABLE 4.6 – Sensibilité des performances au mode de constitution des échantillons (points de PM)

GLM	3,894	2,433	0,131	+0,005	-0,7 %
Random Forest	1,653	0,751	0,842	+0,044	+6,6 %
XGBoost	1,944	1,324	0,783	+0,025	-6,2 %

La hiérarchie des trois modèles est strictement conservée et les écarts demeurent inférieurs à 7 %. Les conclusions de cette section ne dépendent donc pas du mode de constitution des échantillons. Le Random Forest se dégrade légèrement tandis que le XGBoost s'améliore, ce qui resserre l'écart entre les deux méthodes sans en inverser l'ordre.

4.3 Explicabilité et hiérarchisation des facteurs d'écart (coefficients du GLM, importances, SHAP, effets non linéaires et interactions)

TABLE 4.7 – Coefficients standardisés du GLM : effet d'une variation d'un écart-type de la variable, en points de PM

Volatilité des taux	+1,0605	0,0202	+52,44	$< 10^{-3}$	[+1,021 ; +1,100]
Courbe des taux	-0,7155	0,0202	-35,38	$< 10^{-3}$	[-0,755 ; -0,676]
Duration du passif	+0,5655	0,0202	+27,96	$< 10^{-3}$	[+0,526 ; +0,605]
TMG	+0,5649	0,0202	+27,94	$< 10^{-3}$	[+0,525 ; +0,605]
PMVL actions	+0,2899	0,0202	+14,33	$< 10^{-3}$	[+0,250 ; +0,329]
Garantie de taux	-0,2867	0,0202	-14,18	$< 10^{-3}$	[-0,326 ; -0,247]
Volatilité des actions	+0,2389	0,0202	+11,81	$< 10^{-3}$	[+0,199 ; +0,279]
Rachats conjoncturels	+0,1446	0,0202	+7,15	$< 10^{-3}$	[+0,105 ; +0,184]
Spread	-0,0703	0,0202	-3,47	$< 10^{-3}$	[-0,110 ; -0,031]

Le signe de chacun des neuf coefficients est conforme à l'intuition actuarielle. La volatilité des taux, la duration du passif et le taux minimum garanti renchérissent le coût des garanties, tandis qu'un niveau de courbe des taux plus élevé le réduit.

Les neuf coefficients sont significatifs à tous les seuils usuels, mais cette significativité doit être relativisée. Avec 36 288 observations et un plan orthogonal, un effet même très faible ressort comme statistiquement significatif : l'amplitude du coefficient constitue ici une information plus utile que la p -valeur. L'erreur-type, identique pour les neuf variables et égale à 0,0202 point de PM, est par ailleurs une conséquence directe de l'orthogonalité du plan factoriel établie à la section 3.3.2.2.




FIGURE 4.8 – Importance des variables selon la permutation (Random Forest et XGBoost)

TABLE 4.8 – Importance par permutation : dégradation de la RMSE de test, en points de PM

	GLM	Random Forest	XGBoost
Courbe des taux	0,127	3,364	2,664
TMG	0,080	2,529	1,849
PMVL actions	0,015	2,372	1,683
Duration du passif	0,081	2,164	1,510
Spread	0,001	1,957	1,265
Volatilité des taux	0,286	1,703	1,170
Rachats conjoncturels	0,004	1,471	0,884
Garantie de taux	0,021	0,656	0,326
Volatilité des actions	0,016	0,101	0,015
Total	0,631	16,317	11,366

La somme des dégradations constitue le premier enseignement de ce tableau. Elle s'établit à 0,63 point de PM pour le GLM contre 16,32 pour le Random Forest, soit un rapport de vingt-six. Le modèle linéaire n'exploite qu'une fraction marginale de l'information contenue dans les neuf variables.

Deux désaccords entre le GLM et les méthodes non linéaires méritent d'être relevés. Le spread est la variable la moins utilisée par le GLM, avec une dégradation de 0,001 point de PM, mais la cinquième du Random Forest avec 1,957 point. Son effet passe donc presque intégralement par des non-linéarités ou des interactions, ce que confirmera l'analyse des valeurs de Shapley. À l'inverse, la volatilité des taux occupe le premier rang chez le GLM et seulement le sixième chez les méthodes fondées sur les arbres : son effet est le plus proprement linéaire des neuf, ce qui explique qu'il soit le seul correctement capté par une spécification additive.

4.3.1 Importance SHAP

TABLE 4.9 – Importance moyenne des variables au sens des valeurs de Shapley (modèle XGBoost)

Courbe des taux	1,238	22,8 %
Volatilité des taux	0,913	16,8 %
TMG	0,686	12,7 %
PMVL actions	0,635	11,7 %
Duration du passif	0,622	11,5 %
Spread	0,464	8,6 %
Rachats conjoncturels	0,353	6,5 %
Garantie de taux	0,294	5,4 %
Volatilité des actions	0,217	4,0 %
Total	5,423	100 %

4.3.2 Interactions SHAP

TABLE 4.10 – Dix interactions les plus marquées au sens des valeurs de Shapley (points de PM)

1	Courbe des taux × TMG	0,872
2	Spread × PMVL actions	0,686
3	Courbe des taux × PMVL actions	0,650
4	Courbe des taux × Duration du passif	0,565
5	Courbe des taux × Rachats conjoncturels	0,491
6	Courbe des taux × Spread	0,484
7	Duration du passif × TMG	0,483
8	Courbe des taux × Volatilité des taux	0,472
9	PMVL actions × TMG	0,429
10	PMVL actions × Rachats conjoncturels	0,300

L'interaction dominante associe la courbe des taux et le taux minimum garanti, pour une contribution de 0,872 point de PM. Elle traduit directement le mécanisme optionnel étudié : le coût de la garantie de taux ne se matérialise que dans les environnements où le rendement de l'actif passe sous le taux garanti. L'effet du TMG dépend donc du niveau des taux, ce qu'une spécification additive ne peut par construction représenter.

L'interaction entre le spread et les plus-values latentes actions, deuxième du classement avec 0,686 point de PM, est la seule interaction majeure ne faisant pas intervenir la courbe des taux. Elle relève du mécanisme de participation aux bénéfices : la capacité de l'assureur à servir un rendement suffisant repose conjointement sur les produits obligataires et sur la réalisation de plus-values latentes.

La courbe des taux apparaît enfin dans six des huit interactions les plus fortes, alors qu'elle n'occupe que le troisième rang en effet marginal chez le GLM. Son influence sur l'écart entre les deux valorisations passe donc massivement par le conditionnement de l'effet des autres variables. Ce résultat éclaire à la fois l'écart entre corrélations de Pearson et de Spearman relevé à la section 4.1 et l'écart de performance

entre le GLM et les méthodes non linéaires établi à la section 4.2.

4.3.3 Hiérarchie consolidée des facteurs d'écart

TABLE 4.11 – Hiérarchie consolidée des facteurs d'écart. Les rangs figurent entre parenthèses ; la dernière colonne donne le rang moyen sur les cinq critères

Courbe des taux	0,715 (2)	0,201 (1)	0,195 (1)	2,664 (1)	1,238 (1)	1,2
TMG	0,565 (4)	0,141 (4)	0,134 (3)	1,849 (2)	0,686 (3)	3,2
Volatilité des taux	1,061 (1)	0,086 (7)	0,152 (2)	1,170 (6)	0,913 (2)	3,6
PMVL actions	0,290 (5)	0,149 (2)	0,109 (5)	1,683 (3)	0,635 (4)	3,8
Duration du passif	0,566 (3)	0,113 (5)	0,121 (4)	1,510 (4)	0,622 (5)	4,2
Spread	0,070 (9)	0,147 (3)	0,105 (6)	1,265 (5)	0,464 (6)	5,8
Rachats conjoncturels	0,145 (8)	0,089 (6)	0,082 (7)	0,884 (7)	0,353 (7)	7,0
Garantie de taux	0,287 (6)	0,042 (8)	0,069 (8)	0,326 (8)	0,294 (8)	7,6
Volatilité des actions	0,239 (7)	0,031 (9)	0,033 (9)	0,015 (9)	0,217 (9)	8,6

La courbe des taux occupe le premier rang sur quatre des cinq critères et obtient le rang moyen le plus favorable. Elle constitue le facteur dominant de l'écart entre valorisation déterministe et stochastique, quelle que soit la méthode d'évaluation retenue. À l'opposé, la volatilité des actions occupe le dernier rang sur quatre critères, ce qui est cohérent avec la structure d'un portefeuille euro majoritairement obligataire.

Les trois mesures issues des méthodes non linéaires s'accordent très largement entre elles, ce qui confère à cette hiérarchie une robustesse méthodologique que ne procurerait pas un indicateur isolé. Les deux seuls désaccords notables proviennent du GLM et ont déjà été identifiés : la volatilité des taux, de premier rang chez le GLM et de sixième rang en importance par permutation, et le spread, de neuvième rang chez le GLM et de troisième chez le Random Forest. Ces deux inversions résument le résultat central du chapitre : le modèle linéaire ne classe correctement que les facteurs dont l'effet est additif.

4.4 Validation externe sur le second portefeuille central

4.5 Analyse de variation entre deux dates de valorisation

Chapitre 5

Limites, apports et perspectives

Les chapitres précédents ont conduit à construire une base de simulations à partir du modèle ALM interne, puis à ajuster trois familles de modèles afin de reproduire et d'expliquer l'écart entre le Best Estimate déterministe et le Best Estimate stochastique. Les résultats obtenus ont été présentés au chapitre 4.

Ce dernier chapitre prend du recul par rapport à ces résultats. Il précise d'abord ce que la démarche apporte concrètement, sur le plan opérationnel comme au regard des exigences prudentielles. Il expose ensuite les limites qui en encadrent la portée, en distinguant celles qui tiennent aux données, au modèle ALM sous-jacent, aux méthodes statistiques retenues et enfin à l'usage qui peut être fait des résultats. Il propose enfin plusieurs pistes d'approfondissement, chacune répondant à l'une des limites identifiées.

Plusieurs de ces limites ont déjà été signalées au fil du mémoire, notamment la question du domaine de validité du métamodèle (cf. section 3.1.3), les difficultés d'extrapolation des méthodes fondées sur les arbres (cf. section 3.2.3) et la présence d'une erreur de simulation irréductible dans la variable cible (cf. section 3.3.2.1). Elles sont reprises ici de manière consolidée, afin de disposer d'une vue d'ensemble de la portée réelle des conclusions.

5.1 Apports opérationnels et réglementaires

5.1.1 Une lecture explicite du passage du Best Estimate déterministe au Best Estimate stochastique

La problématique posée en introduction ne portait pas sur le choix entre les deux méthodes de valorisation, mais sur la compréhension de l'écart qui les sépare. Cet écart, égal à [...] % des provisions mathématiques pour le portefeuille central, est fréquemment constaté en pratique sans faire l'objet d'une décomposition formalisée. Il est alors interprété globalement comme le coût des options et garanties du portefeuille, sans que la contribution respective de chacune de ses composantes soit quantifiée.

La démarche développée dans ce mémoire apporte précisément cette décomposition. Les contributions

obtenues par la méthode SHAP permettent d'attribuer à chaque caractéristique du portefeuille une part de l'écart observé, et ce pour une configuration donnée. L'écart cesse ainsi d'être une grandeur agrégée pour devenir une somme de contributions individuellement identifiables.

Cet apport présente un intérêt direct dans le cadre prudentiel. La directive Solvabilité II impose aux organismes d'assurance de disposer d'un système de gouvernance permettant une gestion saine et prudente de leur activité, et confie à la fonction actuarielle la responsabilité d'apprécier la fiabilité et le caractère adéquat du calcul des provisions techniques. Cette appréciation suppose de pouvoir expliquer les résultats produits, et non seulement de les produire. Une décomposition documentée de l'écart entre les deux modes de valorisation constitue à cet égard un élément de justification mobilisable dans le rapport de la fonction actuarielle, dans les échanges avec l'autorité de contrôle ou lors des travaux de validation interne.

5.1.2 Une hiérarchisation des facteurs d'écart confrontée à la lecture actuarielle

Au-delà de la décomposition configuration par configuration, l'analyse conduite au chapitre 4 aboutit à une hiérarchisation d'ensemble des neuf variables explicatives retenues. Cette hiérarchisation présente un double intérêt.

Elle constitue d'abord un test de cohérence. La théorie actuarielle conduit à attendre un rôle prépondérant des variables gouvernant le coût des garanties financières, en particulier le niveau de la courbe des taux, le taux minimum garanti et la garantie de taux, ainsi que des variables déterminant la richesse mobilisable par l'assureur et la dispersion des trajectoires, telles que le taux de plus-values latentes et les volatilités. La confrontation de cette attente aux résultats obtenus permet d'apprécier si le modèle ALM se comporte conformément aux mécanismes qu'il est censé représenter. [Rappeler ici le classement obtenu et indiquer s'il confirme ou non l'attente.]

Elle apporte ensuite une information quantitative que l'intuition métier seule ne fournit pas. L'ordre des facteurs est en effet rarement contesté ; leur poids relatif l'est davantage. Disposer d'une mesure de l'écart d'importance entre deux variables, et non seulement de leur classement, permet d'orienter les travaux d'analyse vers les hypothèses réellement structurantes.

Un troisième élément mérite d'être souligné. La comparaison entre le GLM et les méthodes non linéaires, présentée à la section 4.1, ne constitue pas seulement un exercice de sélection de modèle. Elle renseigne sur la nature même de la relation apprise. Un gain de performance marqué des méthodes non linéaires indiquerait que l'écart entre les deux valorisations ne se réduit pas à une somme d'effets additifs et que des interactions entre variables interviennent de manière significative, conformément à l'hypothèse formulée à la section 3.1.2. [Conclure au regard des résultats obtenus.]

5.1.3 Un métamodèle mobilisable comme outil exploratoire

Le positionnement retenu à la section 3.1.3 assimile le modèle appris à un métamodèle : il approche une sortie du modèle ALM à partir d'un nombre réduit de caractéristiques du portefeuille. Une fois entraîné, il fournit une estimation de l'écart en un temps négligeable, là où la projection stochastique

correspondante requiert la répétition de la mécanique ALM sur l'ensemble des trajectoires issues du générateur de scénarios économiques.

Ce différentiel de coût calculatoire ouvre plusieurs usages opérationnels, sous réserve des limites exposées à la section 5.2 :

- **le pré-cadrage des travaux de sensibilité**, en permettant de balayer un grand nombre de configurations afin d'identifier celles qui méritent un lancement complet du modèle ALM ;
- **l'appui aux analyses de mouvement**, en apportant une décomposition des facteurs expliquant l'évolution de l'écart entre deux dates de valorisation, dans le prolongement des travaux présentés à la section 4.4 ;
- **le contrôle de premier niveau**, un écart constaté en clôture s'écartant sensiblement de la prédiction du métamodèle constituant un signal justifiant une investigation, sans que cet écart présume d'une anomalie ;
- **l'appui pédagogique**, la restitution des contributions facilitant l'échange avec des interlocuteurs non spécialistes de la modélisation ALM.

5.1.4 Un cadre méthodologique reproductible

L'apport de la démarche ne se limite pas aux résultats obtenus sur le portefeuille étudié. La chaîne mise en place, décrite par la relation (3.10), constitue en elle-même un livrable transposable : définition d'un portefeuille central, sélection des variables à partir d'études préliminaires de sensibilité, construction d'un plan d'expérience, lancement automatisé des projections, apprentissage supervisé et analyse explicative.

Chacune de ces étapes a été documentée et repose sur des choix explicites : critères de sélection des variables (cf. section 2.3.6), amplitude des sensibilités (cf. section 2.3.7), protocole de séparation des données (cf. section 3.3.1), calibration des hyperparamètres (cf. section 3.3.2) et critères d'évaluation (cf. section 3.4). Cette traçabilité répond aux attentes en matière de documentation des modèles et permet de reproduire la démarche sur un autre portefeuille ou à une autre date d'arrêt sans reconstruire la méthodologie.

L'automatisation du lancement de SALLTO (cf. section 2.3.9) mérite d'être mentionnée à ce titre. Elle a rendu possible la production des 51 840 configurations de la base, volume hors de portée d'un lancement manuel, et constitue un actif réutilisable indépendamment de la question traitée dans ce mémoire.

5.2 Limites de l'approche

Les apports décrits ci-dessus sont encadrés par un ensemble de limites qu'il convient d'exposer avec précision. Elles sont présentées ci-après selon leur origine, depuis la construction des données jusqu'à

l'usage des résultats.

5.2.1 Limites tenant à la construction de la base de données

Un portefeuille central unique et fictif. L'ensemble des observations de la base d'apprentissage provient de sensibilités appliquées à un portefeuille central unique, construit à partir d'hypothèses représentatives des pratiques de marché mais ne correspondant à aucun assureur en particulier (cf. section 2.2). Les relations identifiées entre les caractéristiques du portefeuille et l'écart de valorisation demeurent donc conditionnées à la structure de ce portefeuille : allocation d'actifs, composition du passif, niveau des provisions pour participation aux bénéfices et rapport entre engagements garantis et richesse disponible.

La validation externe conduite sur un second portefeuille central (cf. section 4.3) apporte un premier élément de réponse à cette limite, mais ne la lève pas. Deux portefeuilles ne suffisent pas à établir la portée générale des relations mises en évidence, et l'ampleur de la dégradation observée [...] fournit une indication sur la sensibilité du métamodèle à ses conditions de construction plutôt qu'une mesure de sa validité sur l'ensemble des portefeuilles d'assurance vie.

Une base construite par croisement de modalités, non par échantillonnage. La base résulte du croisement complet des modalités retenues pour les neuf variables explicatives (cf. section 2.3.8). Elle ne constitue donc pas un échantillon aléatoire représentatif : chaque configuration y possède le même poids, indépendamment de sa vraisemblance économique. Des combinaisons peu plausibles, associant par exemple un environnement de taux élevés à un taux de plus-values latentes très faible, y sont représentées au même titre que des configurations courantes.

Cette construction est cohérente avec l'objectif poursuivi, qui consiste à explorer le comportement du modèle ALM sur un domaine défini plutôt qu'à reproduire une distribution de portefeuilles observés. Elle interdit en revanche toute lecture probabiliste des résultats : les importances obtenues mesurent l'influence d'une variable sur le domaine exploré, et non son influence attendue dans les conditions effectivement rencontrées par un assureur.

Cette même construction explique par ailleurs la portée limitée de l'échantillon de test. Le tirage étant réalisé ligne à ligne au sein d'une grille factorielle complète, chaque observation de test possède des configurations directement voisines dans l'échantillon d'apprentissage. Les indicateurs présentés à la section 4.1 mesurent donc une capacité d'interpolation à l'intérieur du domaine des sensibilités, non une capacité d'extrapolation (cf. section 3.4.3).

Un ensemble d'hypothèses maintenues constantes. Neuf variables ont été retenues à l'issue des études préliminaires de sensibilité (cf. section 2.3.6). L'ensemble des autres hypothèses du modèle a été maintenu à sa valeur centrale : tables de mortalité, chargements et frais, politique de participation aux bénéfices, règles de dotation et de reprise de la provision pour participation aux excédents, allocation d'actifs cible et décisions de gestion.

Ces hypothèses ne sont pas neutres sur l'écart étudié. La politique de participation aux bénéfices et les règles de gestion des actifs déterminent directement la capacité de l'assureur à absorber les scénarios défavorables, donc le coût des garanties financières. Le métamodèle décrit ainsi le comportement de

l'écart à *politique de gestion donnée*, et ses conclusions ne peuvent être transposées à un assureur dont les décisions de gestion diffèreraient sensiblement.

La sélection elle-même appelle une réserve. Les études préliminaires ont apprécié l'impact des variables candidates en les faisant varier séparément. Une variable dont l'effet propre est modeste mais qui interagit fortement avec une autre a donc pu être écartée à tort. L'inflation et la participation aux bénéfices, testées puis non retenues, appartiennent à cette catégorie de facteurs dont l'effet est susceptible de se manifester principalement en combinaison avec le niveau des taux.

Une variable de duration agrégée. L'âge des assurés et les rachats structurels ont été résumés par une unique variable de duration du passif (cf. section 2.3.5). Ce regroupement se justifie par le fait que ces deux facteurs agissent dans le même sens sur la durée de détention des contrats, mais il entraîne une perte d'information. Deux portefeuilles présentant une duration identique peuvent en effet correspondre à des structures très différentes, l'une reposant sur une population âgée à faible taux de rachat, l'autre sur une population jeune à taux de rachat élevé. Leur sensibilité aux scénarios de taux, et donc leur exposition aux rachats conjoncturels, n'est pas nécessairement comparable.

5.2.2 Limites tenant au modèle ALM sous-jacent

Une limite structurelle mérite d'être clairement énoncée : **le métamodèle apprend le comportement de SALTO, et non la réalité économique sous-jacente**. La variable cible n'est pas une grandeur observée mais une sortie de modèle. Toute approximation, simplification ou erreur de calibration présente dans le modèle ALM est donc reproduite fidèlement par le métamodèle, qui n'offre à cet égard aucune capacité de détection.

Trois éléments de la chaîne de projection appellent une attention particulière.

Le **générateur de scénarios économiques** détermine la distribution des trajectoires alimentant la projection stochastique. Le coût des garanties financières dépend directement de cette distribution, en particulier de la dispersion des taux courts et de la structure de corrélation entre classes d'actifs. Les conclusions relatives au rôle des volatilités demeurent donc conditionnées à la calibration du générateur retenue au 31 décembre 2025.

La **loi de rachat conjoncturel** traduit une hypothèse comportementale dont la calibration repose sur des données historiques limitées, les épisodes de forte tension sur les taux étant peu nombreux. L'importance attribuée à cette variable reflète donc pour partie la forme fonctionnelle retenue dans le modèle plutôt qu'un comportement établi.

Les **décisions de gestion** modélisées, qu'il s'agisse de la politique de réalisation de plus-values ou des règles de dotation à la provision pour participation aux excédents, exercent une influence directe sur l'écart entre les deux valorisations. Elles constituent une représentation simplifiée d'arbitrages en pratique discrétionnaires.

Enfin, le Best Estimate stochastique est estimé à partir de 1 000 simulations et comporte à ce titre une erreur d'échantillonnage de Monte-Carlo, formalisée par le terme σ^2 de l'équation (3.26). Cette erreur affecte directement la variable cible et fixe un plancher à la performance atteignable. Elle introduit égale-

ment un risque spécifique : un modèle suffisamment flexible peut reproduire ces fluctuations de simulation plutôt que la relation sous-jacente, ce que les mécanismes de régularisation décrits à la section 3.3.2 visent précisément à contenir.

5.2.3 Limites tenant aux modèles statistiques retenus

Une capacité d'extrapolation limitée. Les méthodes fondées sur les arbres prédisent, pour toute configuration située au-delà du domaine d'apprentissage, la valeur associée à la feuille terminale la plus proche. Leur prédiction devient donc constante hors du domaine couvert, quelle que soit l'ampleur du dépassement (cf. section 3.2.3). Un environnement de taux plus défavorable que la plus basse des cinq courbes retenues, ou un taux minimum garanti supérieur à la modalité maximale de la base, ne serait pas correctement traité. Cette limite est d'autant plus contraignante que les configurations extrêmes sont précisément celles où le coût des garanties financières devient le plus significatif.

Une stabilité des coefficients conditionnée à l'absence de colinéarité. L'interprétation des coefficients du GLM suppose que les variables explicatives ne soient pas fortement corrélées entre elles. La construction factorielle de la base garantit l'orthogonalité des neuf variables soumises à sensibilité, ce qui constitue une situation favorable. Cette propriété disparaîtrait toutefois si la démarche était appliquée à des données issues d'un portefeuille réel, dans lesquelles le niveau des taux, le taux de plus-values latentes et la durée du passif entretiennent des liens étroits.

Des mesures d'explicabilité qui reposent sur des hypothèses. Les valeurs SHAP décomposent additivement une prédiction en contributions individuelles. Cette décomposition constitue une approximation locale du comportement du modèle et non une mesure d'effet causal. Deux réserves méritent d'être formulées. D'une part, la contribution attribuée à une variable dépend de la manière dont les variables absentes sont marginalisées, ce qui peut conduire à évaluer le modèle sur des combinaisons de valeurs peu vraisemblables. D'autre part, en présence d'interactions, la répartition d'un effet conjoint entre les variables concernées relève d'une convention d'imputation, et non d'une propriété du phénomène étudié.

5.2.4 Limites d'interprétation

Un raisonnement *ceteris paribus*. Chaque observation de la base résulte de la modification d'une ou plusieurs hypothèses, toutes les autres étant maintenues constantes. Les effets identifiés sont donc des effets marginaux au sens strict, alors que les variables évoluent conjointement dans la réalité. Une hausse des taux d'intérêt s'accompagne ainsi mécaniquement d'une baisse des plus-values latentes obligataires et d'une pression accrue sur les rachats conjoncturels. L'effet observé lors d'un changement d'environnement économique résulte de la composition de ces mouvements, et ne correspond donc pas à la seule contribution attribuée à la courbe des taux.

Cette précision est essentielle pour la lecture des résultats du chapitre 4 : les contributions obtenues décrivent la structure du modèle, non l'évolution attendue de l'écart d'un arrêté à l'autre.

Importance statistique et causalité. Une variable identifiée comme importante contribue fortement à la reproduction de la variable cible par le modèle. Il ne s'ensuit pas qu'elle constitue le mécanisme causal à l'origine de l'écart. Une variable fortement liée à un facteur non intégré à la base peut en capter l'effet et voir son importance surestimée. L'interprétation actuarielle des résultats demeure donc nécessaire et ne peut être déduite des seules mesures d'importance.

5.2.5 Limites d'usage et enjeux de gouvernance

Le métamodèle ne saurait se substituer au calcul du Best Estimate réglementaire. Les provisions techniques doivent être évaluées selon les principes fixés par la directive, et une approximation apprise sur un domaine restreint ne satisfait pas aux exigences applicables à une valorisation prudentielle. L'usage envisagé demeure exploratoire, analytique et pédagogique, conformément au positionnement défini à la section 3.1.3.

Cette restriction emporte une conséquence pratique. Si le métamodèle venait à être mobilisé de manière récurrente dans les processus de l'organisme, il relèverait alors du dispositif de gouvernance des modèles : documentation, revue périodique, contrôle des données d'entrée, définition d'un domaine d'emploi et suivi de la performance dans le temps. La légèreté d'utilisation du proxy ne doit pas conduire à un usage non encadré, d'autant que sa rapidité d'exécution en facilite précisément la diffusion.

Une dernière limite tient à la stabilité temporelle. Le métamodèle a été appris à partir de projections réalisées au 31 décembre 2025, avec la calibration du générateur de scénarios économiques et les hypothèses en vigueur à cette date. Une évolution du modèle ALM, de ses hypothèses ou de la calibration du générateur invaliderait progressivement les relations apprises, sans que cette dérive soit nécessairement détectable à la seule lecture des prédictions.

5.3 Perspectives d'amélioration

Les limites exposées ci-dessus ouvrent plusieurs axes de prolongement. Ils sont présentés en suivant la chaîne méthodologique, depuis la construction des données jusqu'à l'usage opérationnel des résultats.

5.3.1 Faire évoluer le plan d'expérience

La construction factorielle complète retenue présente l'avantage de la simplicité et garantit l'orthogonalité des variables. Son coût croît toutefois de manière multiplicative avec le nombre de variables et de modalités : les 51 840 configurations de la base résultent du croisement de neuf variables ne comportant que deux à cinq modalités chacune. Ajouter une dixième variable à trois modalités porterait ce total à plus de 150 000 projections.

Les plans à remplissage d'espace constituent une alternative usuelle en métamodélisation. L'hypercube latin ou les suites à faible discrédance, telles que les suites de Sobol, permettent de couvrir un domaine

TABLE 5.1 – Synthèse des principales limites de l'étude

Origine	Limite	Portée sur les conclusions
Données	Portefeuille central unique et fictif	Résultats conditionnés à la structure du portefeuille retenu
Données	Grille factorielle complète, sans représentativité statistique	Aucune lecture probabiliste des importances obtenues
Données	Hypothèses de gestion et de frais maintenues constantes	Conclusions valables à politique de gestion donnée
Données	Sélection des variables sur sensibilités univariées	Risque d'omission de facteurs à effet d'interaction
Modèle ALM	Le proxy reproduit SALLTO, non la réalité économique	Les approximations du modèle ALM sont héritées
Modèle ALM	Erreur de Monte-Carlo sur 1 000 simulations	Plancher de performance et risque de surapprentissage
Modèles ML	Extrapolation limitée hors du domaine appris	Prédictions non fiables sur les configurations extrêmes
Modèles ML	Hypothèses sous-jacentes aux valeurs SHAP	Contributions à interpréter comme locales et conventionnelles
Interprétation	Construction <i>ceteris paribus</i> des sensibilités	Effets marginaux non transposables à une variation réelle
Usage	Absence de valeur réglementaire du proxy	Usage exploratoire et analytique uniquement

de dimension élevée avec un nombre de points nettement inférieur, tout en évitant la concentration des observations sur un réseau régulier. À budget de calcul constant, une telle approche autoriserait soit l'intégration de variables supplémentaires, notamment l'inflation et les paramètres de la politique de participation aux bénéfices écartés à la section 2.3.6, soit un élargissement du domaine exploré vers les configurations extrêmes.

Ces plans présentent un second avantage : les variables y prennent des valeurs continues plutôt que des modalités discrètes, ce qui permet d'estimer des effets sur l'ensemble d'un intervalle et non aux seuls points de la grille. La question de l'extrapolation, identifiée à la section 5.2.3, s'en trouverait sensiblement atténuée.

5.3.2 Réduire le bruit de simulation

Le terme σ^2 de l'équation (3.26) fixe un plancher à la performance atteignable et complique la distinction entre relation sous-jacente et fluctuation de simulation. Deux voies permettraient de le réduire.

La première consiste à augmenter le nombre de scénarios économiques, l'erreur d'estimation décroissant en $1/\sqrt{N}$. Son coût est toutefois proportionnel au nombre de projections, ce qui la rend difficilement compatible avec la taille de la base.

La seconde repose sur les techniques de réduction de variance. L'emploi de variables antithétiques ou d'un jeu de scénarios communs à l'ensemble des configurations permettrait de diminuer la composante d'erreur sans multiplier le nombre de simulations. L'utilisation d'un jeu commun présenterait un intérêt spécifique dans le cadre de cette étude : les erreurs de simulation deviendraient corrélées entre configurations voisines, de sorte que les écarts observés entre deux configurations traduirait plus fidèlement l'effet de la variable modifiée.

Une troisième voie, moins coûteuse, consisterait à quantifier ce bruit plutôt qu'à le réduire, en relançant un sous-ensemble de configurations avec plusieurs tirages de scénarios. L'ordre de grandeur de σ^2 ainsi estimé fournirait une référence explicite pour la lecture des indicateurs de performance, en cohérence avec l'analyse proposée à la section 3.4.3.

5.3.3 Élargir la famille de métamodèles

Les trois modèles retenus couvrent un spectre allant du modèle linéaire au boosting. Plusieurs autres familles mériteraient d'être examinées.

Les modèles additifs généralisés et les GLM enrichis de fonctions splines permettraient de représenter des effets non linéaires tout en conservant une structure additive lisible. Ils occuperaient une position intermédiaire entre le GLM et les méthodes fondées sur les arbres, en offrant davantage de flexibilité sans renoncer à l'interprétabilité directe des effets.

Le krigeage, ou régression par processus gaussiens, constitue l'approche de référence en métamodélisation de codes de calcul déterministes. Son intérêt principal dans le contexte de cette étude tient à ce qu'il fournit, en plus d'une prédiction, une mesure de l'incertitude associée. Cette incertitude croît naturelle-

ment à mesure que l'on s'éloigne des points d'apprentissage, ce qui apporte une réponse directe à la limite du domaine de validité exposée à la section 5.2.3 : le métamodèle signalerait lui-même les configurations sur lesquelles sa prédiction ne peut être considérée comme fiable. Cette propriété présenterait une valeur particulière dans une perspective d'usage encadré.

Les méthodes de type Least Squares Monte Carlo, développées pour l'accélération des valorisations stochastiques en assurance vie, constituent enfin un point de comparaison naturel. Leur logique diffère de celle retenue ici, puisqu'elles régressent des flux simulés plutôt qu'une sortie agrégée, mais leur confrontation permettrait de situer la démarche par rapport aux pratiques de place.

5.3.4 Approfondir l'analyse explicative

Plusieurs outils complèteraient utilement l'analyse conduite au chapitre 4.

Les valeurs d'interaction SHAP permettent de distinguer, au sein de la contribution attribuée à une variable, la part relevant de son effet propre et celle résultant de sa combinaison avec d'autres variables. Elles apporteraient une réponse quantitative à la question des interactions, centrale dans le choix des méthodes non linéaires.

Les courbes d'effets locaux accumulés, ou courbes ALE, offrent une représentation des effets marginaux plus robuste que les courbes de dépendance partielle lorsque les variables explicatives sont corrélées. Elles présenteraient un intérêt particulier si la démarche était étendue à des données issues de portefeuilles réels.

L'analyse de sensibilité globale, au moyen des indices de Sobol, décomposerait la variance de l'écart en contributions attribuables à chaque variable et à leurs interactions. Cette approche s'articulerait naturellement avec l'évolution du plan d'expérience proposée à la section 5.3.1 et fournirait une hiérarchisation des facteurs fondée sur la décomposition de la variance plutôt que sur le comportement d'un modèle appris.

5.3.5 Étendre le périmètre d'application

La perspective la plus directe consiste à multiplier les portefeuilles centraux. La validation externe conduite sur un second portefeuille (cf. section 4.3) constitue un premier pas, mais une base construite à partir de plusieurs portefeuilles, dont les caractéristiques structurelles seraient elles-mêmes intégrées comme variables explicatives, permettrait au métamodèle d'apprendre l'effet de la structure du portefeuille et non plus seulement celui des sensibilités appliquées à une structure donnée.

D'autres extensions peuvent être envisagées :

- l'intégration des supports en unités de compte, dont la dynamique et l'exposition aux garanties diffèrent sensiblement de celles du fonds en euros ;
- l'application de la démarche aux chocs du SCR, la valorisation des scénarios choqués reposant sur la même mécanique de projection ;

- l'extension à la Risk Margin, dont le calcul mobilise des projections répétées du SCR et constitue à ce titre un candidat naturel à la métamodélisation ;
- l'application aux projections pluriannuelles de l'ORSA, où la répétition des valorisations sur plusieurs exercices rend le gain calculatoire particulièrement significatif.

5.3.6 Vers une industrialisation encadrée

Une utilisation régulière du métamodèle supposerait enfin de traiter la question de son maintien dans le temps. Trois éléments paraissent nécessaires.

Un **domaine d'emploi explicite** devrait être défini, précisant les bornes de chaque variable au-delà desquelles la prédiction n'est plus considérée comme valide, ainsi que les contrôles associés lors de son utilisation.

Un **suivi de performance** devrait être mis en place, comparant à chaque arrêté la prédiction du métamodèle au résultat effectivement produit par le modèle ALM. Une dérive de cet écart signalerait une évolution du modèle sous-jacent ou de ses hypothèses appelant un réapprentissage.

Un **réapprentissage périodique** devrait être organisé, dont la fréquence serait déterminée par le rythme d'évolution du modèle ALM et de la calibration du générateur de scénarios économiques. L'automatisation développée dans le cadre de ce mémoire (cf. section 2.3.9) rend cette opération réalisable à un coût maîtrisé.

TABLE 5.2 – Articulation entre limites identifiées et perspectives proposées

Limite	Perspective associée	Effort de mise en œuvre
Domaine d'apprentissage restreint	Plan à remplissage d'espace, élargissement des bornes	Élevé
Extrapolation non maîtrisée	Krigeage avec intervalle de prédiction	Modéré
Bruit de Monte-Carlo	Réduction de variance ou estimation de σ^2	Modéré
Dépendance au portefeuille central	Base multi-portefeuilles avec variables de structure	Élevé
Interactions insuffisamment quantifiées	Valeurs d'interaction SHAP, indices de Sobol	Faible
Dérive du modèle dans le temps	Suivi de performance et réapprentissage périodique	Faible

Chapitre 6

Conclusion

Annexes