

Mémoire présenté le :

**pour l'obtention du Diplôme Universitaire d'actuariat de l'ISFA
et l'admission à l'Institut des Actuares**

Par : Margot SCHMUTZ

Titre : Rationnalisation du passage du BE déterministe au BE stochastique par des modèles de machine learning

Confidentialité : ☒ NON ☐ (Durée : ☐ 1 an ☐ 2 ans)

Les signataires s'engagent à respecter la confidentialité indiquée ci-dessus

*Membres présents du jury de Signature
l'Institut des Actuares*

Entreprise : FORSIDES

Nom :

Signature :

*Directeur de mémoire en entre-
prise :*

Nom : Daniel ZERBIB

Signature :

Invité :

Nom :

Signature :

*Membres présents du jury de
l'ISFA*

***Autorisation de publication et
de mise en ligne sur un site de
diffusion de documents actua-
riels (après expiration de l'éventuel
délai de confidentialité)***

Signature du responsable entreprise

Signature du candidat

Table des matières

Résumé	4
Abstract	5
Remerciements	6
Synthèse	7
Synthesis	8
Introduction	1
1 Cadre prudentiel et réglementaire de la valorisation du Best Estimate	3
1.1 Solvabilité II : principes, objectifs et architecture	3
1.1.1 Une architecture en trois piliers	3
1.1.2 Le ratio de solvabilité et la place du Best Estimate	3
1.2 La valorisation des provisions techniques	4
1.2.1 Une valorisation économique des engagements	4
1.2.2 Définition réglementaire du Best Estimate	4
1.2.3 Flux projetés et hypothèses de calcul	5
1.3 Approches déterministe et stochastique	6
1.3.1 Deux méthodes au service d'un même objectif prudentiel	6
1.3.2 Le Best Estimate déterministe	6
1.3.3 Le Best Estimate stochastique	7
1.3.4 Options, garanties et valeur temps	7
2 Modèle ALM interne et construction de la base de données	9
2.1 Le modèle ALM interne	9
2.1.1 Le générateur de scénarios économiques	10
2.1.2 Fonctionnement de SALLTO	12
2.2 Description du portefeuille étudié	13
2.2.1 Portefeuille d'actifs	13
2.2.2 Portefeuille de passifs	14
2.2.3 Autres hypothèses retenues	16

2.3	Méthodologie de construction de la base de données	18
2.3.1	Objectif de la base de données	18
2.3.2	Définition de la variable cible	18
2.3.3	Principe de construction des observations	19
2.3.4	Études préliminaires de sensibilité	20
2.3.5	Construction de la variable de duration	22
2.3.6	Sélection des variables définitives	22
2.3.7	Amplitude des sensibilités retenues	23
2.3.8	Taille de la base de données	23
2.3.9	Lancement automatisé de SALLTO	24
3	Apports du machine learning pour la rationalisation des écarts	25
3.1	Problématique de régression dans le cadre du Best Estimate	26
3.1.1	Formulation du problème	26
3.1.2	Pourquoi le machine learning est adapté à ce contexte	27
3.1.3	Positionnement par rapport aux approches traditionnelles	29
3.2	Présentation des modèles de machine learning utilisés	31
3.2.1	Modèles de référence	31
3.2.2	Modèles non linéaires	32
3.2.3	Avantages et limites de chaque modèle dans le cadre d'étude	34
3.3	Méthodologie d'apprentissage	36
3.3.1	Séparation des données	36
3.3.2	Contrôle de la complexité et choix des hyperparamètres	40
3.3.3	Diagnostics et validation de l'apprentissage	47
3.4	Critère de performance	50
3.4.1	Indices retenus	50
3.4.2	Comparaison des modèles	50
3.4.3	Lecture des performances	50
4	Analyse des résultats et rationalisation des écarts	51
4.1	Performance des modèles (test, comparaison GLM / RF / XGBoost, stabilité sur les répétitions)	51
4.2	Explicabilité et hiérarchisation des facteurs d'écart (coefficients du GLM, importances, SHAP, effets non linéaires et interactions)	51
4.3	Validation externe sur le second portefeuille central	51
4.4	Analyse de variation entre deux dates de valorisation	51
5	Limites, apports et perspectives	52
5.1	Apports opérationnels et réglementaires	52
5.2	Limites de l'approche	52
5.3	Perspectives d'amélioration	52
6	Conclusion	53

Résumé

Petit résumé en français de mon mémoire ?

Abstract

It's a brief sum up in english !

Remerciements

Synthèse

Un long résumé en français de mon mémoire

Synthesis

Un long résumé en anglais de mon mémoire

Introduction

Dans un contexte réglementaire exigeant et en constante évolution, les organismes d'assurance doivent être en mesure de valoriser leurs engagements de manière fiable, tout en assurant la compréhension et la traçabilité des résultats produits. Depuis l'entrée en vigueur de la directive Solvabilité II, le calcul des provisions techniques repose sur une approche économique tenant compte des conditions de marché. Le Best Estimate occupe une place centrale dans cette valorisation puisqu'il correspond à l'estimation des flux futurs liés aux engagements d'assurance.

En assurance vie, le calcul du Best Estimate peut être réalisé à partir d'une approche déterministe ou d'une approche stochastique. L'approche déterministe repose sur une projection fondée sur un scénario économique central. Elle présente l'avantage d'être plus rapide à mettre en œuvre et facilite l'analyse des résultats. L'approche stochastique repose, quant à elle, sur un ensemble de scénarios économiques permettant de prendre en compte l'incertitude liée aux évolutions des marchés financiers.

Cette seconde approche permet notamment de mieux intégrer les effets liés aux options et garanties présentes dans les contrats d'assurance vie. Elle est cependant plus complexe à mettre en œuvre et nécessite des temps de calcul plus importants.

Les résultats obtenus à partir des approches déterministe et stochastique peuvent donc présenter des différences. Ces écarts dépendent à la fois de l'environnement économique, des caractéristiques du portefeuille et des hypothèses utilisées dans le modèle. Leur compréhension constitue un enjeu important, car elle permet de mieux analyser les résultats produits et de renforcer leur justification dans un cadre réglementaire.

L'objectif de ce mémoire est ainsi de rationaliser le passage du Best Estimate déterministe au Best Estimate stochastique. Il ne s'agit pas de remplacer le calcul stochastique, mais de mieux comprendre les facteurs expliquant les différences observées entre les deux méthodes de valorisation. Une attention particulière est portée à l'identification des variables ayant le plus d'influence sur ces écarts.

Pour répondre à cette problématique, une base de données est construite à partir des résultats d'un modèle ALM interne. Différentes hypothèses économiques et contractuelles sont modifiées de manière contrôlée afin de créer plusieurs configurations de portefeuille. Pour chacune de ces configurations, un Best Estimate déterministe et un Best Estimate stochastique sont calculés.

Dans le cadre de ce mémoire, nous aurons recours à plusieurs modèles de machine learning afin d'évaluer leur capacité à reproduire et à expliquer l'écart entre le Best Estimate déterministe et le Best Estimate stochastique. L'objectif n'est pas uniquement d'obtenir de bonnes performances prédictives. Il est

également nécessaire de comprendre le fonctionnement des modèles et d'identifier les variables les plus significatives.

Le mémoire est organisé en plusieurs parties. La première partie présente le cadre réglementaire de Solvabilité II et les principes de calcul du Best Estimate. La deuxième partie décrit le modèle ALM interne utilisé ainsi que la méthodologie de construction de la base de données. La troisième partie présente les modèles de machine learning retenus et la méthodologie d'apprentissage. La quatrième partie est consacrée à l'analyse des résultats et à l'identification des principaux facteurs expliquant les écarts observés. Enfin, la dernière partie présente les limites de l'étude ainsi que les perspectives d'amélioration possibles.

Chapitre 1

Cadre prudentiel et réglementaire de la valorisation du Best Estimate

1.1 Solvabilité II : principes, objectifs et architecture

1.1.1 Une architecture en trois piliers

Le cadre Solvabilité II est organisé autour de trois piliers complémentaires mais seul le pilier 1 sera abordé dans ce mémoire.

Schéma : Architecture de Solvabilité II

Le **pilier 1** regroupe les exigences quantitatives. Il définit les règles de valorisation des actifs et des passifs, le calcul des provisions techniques, la détermination des fonds propres ainsi que les exigences de capital. Deux niveaux de capital sont notamment distingués : le *Solvency Capital Requirement* (SCR) et le *Minimum Capital Requirement* (MCR). Le *Best Estimate* étudié dans ce mémoire relève directement de ce premier pilier.

1.1.2 Le ratio de solvabilité et la place du Best Estimate

Les organismes d'assurance doivent détenir des fonds propres éligibles suffisants pour couvrir leur SCR. Le ratio de couverture du SCR, couramment appelé ratio de solvabilité, s'écrit :

$$\text{Ratio de solvabilité} = \frac{\text{Fonds propres éligibles au SCR}}{\text{SCR}}.$$

Un ratio égal à 100 % signifie que les fonds propres éligibles sont exactement égaux au capital requis. Le SCR est calibré afin de correspondre à une valeur en risque des fonds propres de base avec un niveau de confiance de 99,5 % sur un horizon d'un an.

Le *Best Estimate* intervient principalement au numérateur de ce ratio, par l'intermédiaire du bilan économique. Toutes choses égales par ailleurs, une hausse du *Best Estimate* augmente les provisions techniques, réduit l'excédent des actifs sur les passifs et diminue ainsi les fonds propres de base. Sa valorisation peut également influencer certains modules du SCR et les mécanismes d'absorption des pertes par les provisions techniques. La maîtrise de son niveau et de sa sensibilité constitue donc un enjeu de pilotage prudentiel, même lorsque l'objet de l'étude n'est pas directement la prédiction du ratio de solvabilité.

Schéma explicatif

1.2 La valorisation des provisions techniques

1.2.1 Une valorisation économique des engagements

L'article 76 de la directive Solvabilité II prévoit que la valeur des provisions techniques corresponde au montant actuel qu'une société d'assurance devrait payer si elle transférait immédiatement ses engagements à une autre entreprise. Leur calcul doit être cohérent avec les informations fournies par les marchés financiers, prudent, fiable et objectif.

Lorsque les flux associés aux engagements ne peuvent pas être répliqués de manière fiable à l'aide d'instruments financiers disposant d'une valeur de marché observable, les provisions techniques sont calculées comme la somme du *Best Estimate* et de la marge de risque :

$$PT = BE + RM,$$

où PT désigne les provisions techniques, BE le *Best Estimate* et RM la marge de risque.

Le *Best Estimate* représente la valeur actualisée moyenne des flux futurs nécessaires au règlement des engagements. La marge de risque correspond au coût du capital qu'une entreprise de référence devrait supporter pour reprendre et honorer ces engagements jusqu'à leur extinction.

1.2.2 Définition réglementaire du Best Estimate

L'article 77 de la directive définit le *Best Estimate* comme la moyenne pondérée par leur probabilité des flux de trésorerie futurs, compte tenu de la valeur temporelle de l'argent et de la courbe des taux sans

risque pertinente. Il peut être représenté par :

$$BE = \mathbb{E} \left[\sum_{t=1}^T D(0, t) CF_t \right],$$

où CF_t désigne le flux net associé aux engagements à la date t , $D(0, t)$ le facteur d'actualisation entre la date de valorisation et la date t , et T l'horizon d'extinction du portefeuille.

Cette écriture met en évidence trois dimensions essentielles. Le calcul est prospectif, puisqu'il repose sur les flux futurs et non uniquement sur des données passées. Il est actualisé, afin de prendre en compte la valeur temporelle de l'argent. Enfin, il est probabilisé, car il doit intégrer la distribution des résultats futurs et pas seulement une trajectoire centrale lorsque celle-ci ne suffit pas à représenter les risques.

Le calcul doit reposer sur des informations actualisées et crédibles, des hypothèses réalistes ainsi que des méthodes actuarielles et statistiques pertinentes. La projection doit prendre en compte l'ensemble des entrées et sorties de trésorerie nécessaires au règlement des engagements pendant toute leur durée. Le *Best Estimate* est calculé brut de réassurance, les montants recouvrables au titre des contrats de réassurance étant évalués séparément.

1.2.3 Flux projetés et hypothèses de calcul

Le règlement délégué (UE) 2015/35 précise les principes de projection des flux utilisés pour déterminer le *Best Estimate*. Ceux-ci comprennent notamment les prestations dues aux assurés et aux bénéficiaires, les primes futures incluses dans la frontière des contrats, les frais nécessaires à la gestion des engagements et les paiements liés aux options contractuelles.

Les hypothèses utilisées doivent représenter de manière cohérente les facteurs susceptibles d'affecter les flux futurs. Dans le cas d'un portefeuille d'assurance vie, elles portent notamment sur :

- la mortalité et la longévité ;
- les rachats et les autres comportements des assurés ;
- les frais futurs ;
- les rendements financiers et l'évolution des actifs ;
- les garanties contractuelles ;
- la participation future aux bénéfices ;
- les actions futures de management.

Les actions futures de management peuvent notamment concerner l'allocation d'actifs, la réalisation de plus-values latentes ou la politique de revalorisation des contrats. Elles doivent être réalistes, cohérentes

avec les pratiques de l'entreprise et approuvées par son organe de direction.

Les hypothèses de comportement des assurés doivent également intégrer les rachats conjoncturels, qui traduisent notamment leur réaction à l'écart entre le taux servi par le contrat et les rendements proposés par d'autres placements.

La frontière des contrats détermine les flux futurs qui appartiennent aux engagements existants à la date de valorisation. Cette délimitation est essentielle, car elle conditionne les primes, prestations et frais intégrés dans le calcul. Enfin, les données doivent être appropriées. Le recours à des approximations est possible lorsque les données sont insuffisantes, mais il doit être justifié et ne pas résulter de défaillances des processus internes de collecte ou de validation.

1.3 Approches déterministe et stochastique

1.3.1 Deux méthodes au service d'un même objectif prudentiel

La réglementation impose le calcul d'une meilleure estimation probabilisée ; elle n'érige pas le *Best Estimate* déterministe et le *Best Estimate* stochastique en deux mesures prudentielles concurrentes. Le choix de la méthode doit être adapté à la nature des engagements et aux risques affectant les flux. Le règlement délégué exige que le calcul soit réalisé de manière transparente, que la méthode et ses résultats puissent être revus par un expert qualifié et que les dépendances des flux à l'égard d'événements futurs soient correctement reflétées.

Une méthode déterministe peut être pertinente lorsque les flux sont peu sensibles à la dispersion des variables économiques ou lorsque les relations sont suffisamment linéaires. À l'inverse, une méthode stochastique devient nécessaire lorsque la valeur des flux dépend de manière importante de l'ensemble des trajectoires possibles, en particulier en présence d'options, de garanties ou d'actions de gestion dynamiques.

1.3.2 Le Best Estimate déterministe

Le *Best Estimate* déterministe est obtenu en projetant le portefeuille selon une trajectoire économique unique, généralement construite à partir d'hypothèses centrales. Il peut être représenté de manière simplifiée par :

$$BE_{\text{det}} = \sum_{t=1}^T D^{\text{det}}(0, t) CF_t^{\text{det}}.$$

Cette méthode permet une lecture directe de l'évolution du portefeuille et se prête facilement aux analyses de sensibilité. Son coût de calcul est limité, puisqu'une seule trajectoire est projetée. Elle fournit ainsi un point de comparaison utile et peut synthétiser une part importante des caractéristiques du portefeuille.

Sa principale limite provient de l'utilisation d'un scénario unique. La projection du scénario moyen ne

restitue alors pas nécessairement la moyenne des valeurs obtenues dans l'ensemble des scénarios.

1.3.3 Le Best Estimate stochastique

L'approche stochastique repose sur un ensemble de scénarios économiques représentant différentes évolutions possibles des variables financières. Pour chaque scénario, le modèle ALM projette les actifs, les passifs, les décisions de gestion et les comportements des assurés. Le *Best Estimate* stochastique est ensuite estimé par la moyenne des valeurs actualisées :

$$\widehat{BE}_{sto} = \frac{1}{N} \sum_{n=1}^N \left[\sum_{t=1}^T D^{(n)}(0, t) CF_t^{(n)} \right],$$

où N désigne le nombre de scénarios économiques.

Cette approche permet de représenter les interactions entre les variables financières et les mécanismes propres aux contrats. Elle tient notamment compte du fait qu'une garantie produit un coût dans les scénarios défavorables sans que l'assureur bénéficie nécessairement de manière symétrique des scénarios favorables. Elle permet également de modéliser les politiques de participation aux bénéfices, les réalisations de plus-values, les arbitrages d'allocation et les rachats dynamiques.

Le calcul est donc plus complexe, mais également plus coûteux et plus difficile à analyser qu'une projection déterministe.

1.3.4 Options, garanties et valeur temps

Le règlement délégué impose de prendre en compte toutes les garanties financières et options contractuelles incluses dans les contrats, ainsi que les facteurs susceptibles d'influencer leur exercice par les assurés. Pour un portefeuille d'assurance vie, il peut notamment s'agir :

- d'un taux minimum garanti ;
- d'un mécanisme de participation aux bénéfices ;
- d'une garantie en capital ;
- d'une option de rachat ;
- d'une arbitrage entre supports ;
- d'une option de conversion ou de prorogation.

La valeur intrinsèque d'une garantie correspond à son coût dans la situation économique observée à la date de valorisation. Sa valeur temps traduit le coût supplémentaire lié à l'incertitude sur les évolutions futures et à la possibilité que la garantie devienne plus contraignante dans certains scénarios. Dans le

cadre opérationnel retenu dans ce mémoire, la TVOG est approchée par la différence :

$$TVOG = BE_{sto} - BE_{det}.$$

Cette définition doit être comprise dans le périmètre et avec les conventions du modèle utilisé. Elle dépend notamment du scénario déterministe de référence, des règles de participation aux bénéfices et des actions de management modélisées. L'écart ne constitue donc pas une constante propre au portefeuille : il varie avec l'environnement économique, les caractéristiques des contrats et la politique de gestion de l'assureur.

Les facteurs étudiés dans la base de données reflètent précisément ces mécanismes. Une courbe de taux basse peut accroître le coût des garanties et réduire les marges financières disponibles. Une augmentation de la volatilité peut renforcer la valeur temps d'une option en élargissant la distribution des résultats futurs. Le niveau des spreads, les plus-values latentes, la duration du passif, les rachats et le taux minimum garanti modifient également la capacité de l'assureur à servir ses engagements dans les différents scénarios. L'analyse de leur effet conjoint nécessite donc des méthodes capables de représenter des relations non linéaires et des interactions.

Chapitre 2

Modèle ALM interne et construction de la base de données

2.1 Le modèle ALM interne

Dans le cadre de cette étude, les différentes valorisations du *Best Estimate* sont obtenues à l'aide du modèle ALM interne de Forsides, appelé SALLTO (*Solvency Assets Liabilities Life TOol*). Développé en interne en C#, cet outil permet de projeter dans le temps l'évolution d'une compagnie d'assurance vie en modélisant conjointement son actif et son passif ainsi que les interactions entre ces deux composantes.

L'intérêt d'une telle approche est de représenter les mécanismes propres à l'assurance vie, pour lesquels l'évolution du passif dépend directement de la situation financière de l'assureur. Les conditions économiques influencent en effet la valeur et le rendement des actifs, mais également les décisions de gestion de l'assureur, telles que le niveau de participation aux bénéfices servi, la réalisation de plus-values ou encore les réallocations d'actifs. Ces décisions peuvent à leur tour modifier le comportement des assurés, notamment en matière de rachats.

SALLTO permet ainsi de projeter les flux, les bilans et les comptes de résultat d'une compagnie d'assurance vie jusqu'à l'extinction du portefeuille. Les projections peuvent être réalisées de manière déterministe ou stochastique, selon la nature des scénarios économiques utilisés.

Le modèle est alimenté par plusieurs catégories de données et d'hypothèses :

- les caractéristiques du portefeuille d'actifs ;
- les caractéristiques du portefeuille de passifs ;
- les hypothèses de comportement des assurés, notamment les rachats ;

- les tables de mortalité ;
- les règles de gestion de l'assureur ;
- les scénarios économiques utilisés pour faire évoluer les différentes variables financières.

Les scénarios économiques sont produits indépendamment de SALLTO par le Générateur de Scénarios Économiques (GSE) développé par Forsides. Ils sont ensuite fournis au modèle ALM afin de faire évoluer l'environnement financier au cours de la projection.

Cette articulation entre le GSE et SALLTO est particulièrement importante dans le cadre de ce mémoire. Pour une même configuration initiale du portefeuille, une projection déterministe permet d'obtenir le BE_{det} , tandis qu'une projection sur un ensemble de scénarios stochastiques permet d'obtenir le BE_{sto} . L'étude de l'écart entre ces deux valorisations repose donc directement sur le fonctionnement conjoint de ces deux outils.

2.1.1 Le générateur de scénarios économiques

Un Générateur de Scénarios Économiques (GSE) a pour objectif de simuler l'évolution future des principales variables économiques et financières susceptibles d'affecter le portefeuille d'un assureur. Le GSE développé par Forsides génère notamment des trajectoires pour :

- les taux d'intérêt nominaux et réels ;
- les marchés actions ;
- l'immobilier ;
- l'inflation ;
- les spreads de crédit.

Ces variables étant liées entre elles, le GSE permet de générer des trajectoires économiques cohérentes sur l'ensemble de l'horizon de projection. Ces trajectoires sont ensuite utilisées dans SALLTO pour déterminer, scénario par scénario, l'évolution des actifs et des passifs ainsi que les actions de management qui en découlent.

Deux cadres de projection peuvent être distingués : le *monde réel* et l'univers *risque neutre*. Dans une projection en monde réel, les distributions des variables économiques cherchent à reproduire les évolutions susceptibles d'être effectivement observées. Le calibrage peut alors reposer sur des données historiques, des anticipations de marché ou des hypothèses à dire d'experts. Ce type de projection est notamment adapté aux études prospectives et aux analyses de risque.

Dans un univers risque neutre, utilisé pour les valorisations économiques sous Solvabilité II, les scénarios doivent être *Market Consistent*, c'est-à-dire cohérents avec les prix des instruments financiers observés à la date de valorisation. Sous la probabilité risque neutre $\mathbb{Q}$, les actifs actualisés sont des martingales. Pour un actif de valeur actualisée $\tilde{S}_t$, cette propriété s'écrit :

$$\mathbb{E}^{\mathbb{Q}} \left[\tilde{S}_T \right] = S_0. \quad (2.1)$$

Ainsi, le rendement espéré d'un actif risqué ne comporte plus de prime de risque : après actualisation,

son espérance est égale à sa valeur initiale. Cette propriété permet notamment d'obtenir, par simulation de Monte-Carlo, une valorisation cohérente avec les prix de marché.

Dans le cadre du GSE utilisé, les différentes classes d'actifs reposent sur des modèles stochastiques adaptés à leur dynamique.

Modélisation des taux d'intérêt

Les taux d'intérêt sont modélisés à l'aide du modèle de Hull-White à un facteur, extension du modèle de Vasicek. La dynamique du taux court r_t s'écrit :

$$dr_t = (\theta(t) - ar_t) dt + \sigma_r dW_t, \quad (2.2)$$

où :

- r_t représente le taux court à la date t ;
- a représente la vitesse de retour à la moyenne ;
- σ_r représente la volatilité des taux ;
- $\theta(t)$ est une fonction déterministe permettant d'ajuster le modèle à la courbe des taux observée à la date initiale ;
- W_t est un mouvement brownien.

L'un des principaux intérêts du modèle de Hull-White est sa capacité à reproduire la courbe des taux initiale tout en conservant une formulation suffisamment simple pour permettre son calibrage sur des instruments de marché, notamment des swaptions. Il autorise par ailleurs l'apparition de taux négatifs, propriété utile pour représenter un spectre suffisamment large d'environnements économiques.

Modélisation des actions et de l'immobilier

Les indices actions et immobiliers sont modélisés selon une dynamique de type Black-Scholes. Pour un indice S_t , celle-ci peut s'écrire :

$$\frac{dS_t}{S_t} = \mu dt + \sigma_S dW_t, \quad (2.3)$$

où μ représente la tendance de l'indice, σ_S sa volatilité et W_t un mouvement brownien.

La solution de cette équation peut notamment s'écrire, sur un pas de temps Δt :

$$S_{t+\Delta t} = S_t \exp \left[\left(\mu - \frac{\sigma_S^2}{2} \right) \Delta t + \sigma_S \sqrt{\Delta t} Z \right], \quad Z \sim \mathcal{N}(0, 1). \quad (2.4)$$

Dans un cadre risque neutre, la dérive est déterminée de manière à respecter la cohérence avec les prix de marché. Les volatilités sont quant à elles calibrées à partir de données observées sur les marchés financiers.

Dans le cadre de ce mémoire, le GSE intervient directement dans la construction de la base de données. La courbe des taux ainsi que certains paramètres de volatilité sont modifiés afin de créer différents environnements économiques. Pour chaque paramétrage, les scénarios correspondants sont ensuite transmis à SALLTO afin de réaliser les projections déterministes et stochastiques.

2.1.2 Fonctionnement de SALLTO

Une fois les hypothèses initiales et les scénarios économiques renseignés, SALLTO projette conjointement l'actif et le passif du portefeuille. Le pas de projection est annuel et les différentes opérations sont répétées jusqu'à la fin de l'horizon de projection.

À la date initiale, le modèle est alimenté par la situation du portefeuille à la date de valorisation : bilan, provisions mathématiques, caractéristiques des contrats et portefeuille d'actifs. À chaque pas de temps, le modèle réalise ensuite successivement les principales opérations suivantes :

1. **Vieillessement des actifs.** Les différents actifs évoluent en fonction de leur nature et des trajectoires fournies par le GSE. Les obligations génèrent leurs coupons, sont amorties et éventuellement remboursées à maturité, tandis que la valeur des actifs non amortissables, notamment les actions et l'immobilier, évolue selon les indices économiques simulés.
2. **Vieillessement des passifs.** Les contrats sont projetés d'une année en tenant compte notamment des décès, des arrivées à terme, des rachats, des frais et chargements ainsi que de l'évolution de l'âge et de l'ancienneté des assurés.
3. **Calcul des besoins de trésorerie et opérations sur actifs.** Les encaissements et décaissements générés par l'actif et le passif sont confrontés afin de déterminer le solde de trésorerie. Lorsque cela est nécessaire, des actifs peuvent être cédés. La trésorerie disponible est ensuite réinvestie en fonction de l'allocation stratégique définie dans les règles de gestion.
4. **Mise à jour des mécanismes comptables et financiers.** Les cessions obligataires peuvent notamment conduire à une dotation ou une reprise de la réserve de capitalisation. Les plus ou moins-values réalisées et latentes sont également prises en compte dans la richesse disponible de l'assureur.
5. **Détermination de la participation aux bénéfices.** Le modèle détermine le taux de revalorisation cible puis les ressources permettant de le servir. La Provision pour Participation aux Bénéfices (PPB) peut être reprise ou dotée en fonction de la situation financière de l'assureur.
6. **Application des actions de management.** Si les ressources disponibles ne permettent pas d'atteindre le taux cible, le modèle peut mettre en œuvre les actions de gestion prévues dans le paramétrage, par exemple la réalisation de plus-values latentes. Le taux effectivement servi peut ainsi différer du taux cible lorsque les ressources disponibles sont insuffisantes.
7. **Revalorisation des contrats et calcul des flux.** Les contrats sont revalorisés à partir du taux servi. Les différents flux d'actif et de passif sont alors déterminés et le bilan est mis à jour pour l'année suivante.

Ce mécanisme est répété pour l'ensemble des années de projection et, dans le cas stochastique, pour chacun des scénarios économiques considérés. Le modèle permet ainsi de représenter les interactions

successives entre environnement économique, richesse de l'assureur, décisions de gestion et comportement des assurés.

La différence entre les valorisations déterministe et stochastique utilisées dans ce mémoire intervient essentiellement dans les scénarios économiques alimentant cette chaîne de projection. Dans le cas déterministe, une trajectoire économique unique est utilisée. Dans le cas stochastique, SALLTO reproduit cette même mécanique sur un grand nombre de trajectoires issues du GSE. Le *Best Estimate* stochastique est alors obtenu par agrégation des flux actualisés obtenus sur l'ensemble des scénarios.

Cette répétition du modèle ALM pour un grand nombre de scénarios explique également le coût calculatoire nettement supérieur de la valorisation stochastique. Cet écart de complexité constitue précisément l'un des éléments à l'origine de la problématique étudiée dans ce mémoire : déterminer dans quelle mesure l'information issue d'une projection déterministe, combinée aux caractéristiques économiques et contractuelles du portefeuille, permet de reproduire et d'expliquer le résultat obtenu à partir de la projection stochastique.

2.2 Description du portefeuille étudié

La construction de la base de données nécessaire à l'étude repose sur la définition préalable d'un portefeuille central, à partir duquel seront réalisées les différentes sensibilités présentées par la suite.

Le portefeuille retenu est un portefeuille fictif, valorisé au 31 décembre 2025. Il a été construit à partir de données de marché et d'hypothèses représentatives des caractéristiques généralement observées au sein des portefeuilles d'assureurs vie. L'objectif n'est donc pas de reproduire le bilan d'un assureur particulier, mais de disposer d'un portefeuille de référence cohérent avec les pratiques du marché et suffisamment représentatif pour les besoins de l'étude.

Ce portefeuille constitue le point de départ de l'ensemble des projections réalisées dans la suite du mémoire. Les résultats obtenus, et en particulier la relation mise en évidence entre le Best Estimate déterministe et le Best Estimate stochastique, restent ainsi conditionnés aux caractéristiques du portefeuille central retenu. Cette dépendance devra être prise en compte dans l'interprétation des résultats.

2.2.1 Portefeuille d'actifs

Le portefeuille d'actifs présenté dans cette section correspond aux actifs en représentation du fonds euro. Sa valeur nette comptable totale s'élève à 116 millions d'euros au 31 décembre 2025, tandis que sa valeur de marché atteint 113,39 millions d'euros.

L'allocation a été définie de manière à reproduire la structure d'un portefeuille d'actifs représentatif d'un assureur vie. En valeur nette comptable, elle se compose de 80 % d'obligations à taux fixe, 10 % d'actions globales non long terme, 7 % d'immobilier et 3 % d'actifs monétaires.

TABLE 2.1 – Allocation du portefeuille d'actifs central

Classe d'actifs	Allocation en VNC	PMVL
Monétaire	3 %	0 %
Actions globales non long terme	10 %	+30 %
Immobilier	7 %	+10 %
Obligations à taux fixe	80 %	-7 %
Total	100 %	≈ -2 %

Les différentes classes d'actifs présentent des niveaux de plus ou moins-values latentes distincts. Les actions présentent ainsi une plus-value latente de 30 % et l'immobilier de 10 %, tandis que la poche obligataire présente une moins-value latente de 7 %. Compte tenu du poids prépondérant des obligations dans l'allocation, le portefeuille présente globalement une légère moins-value latente, de l'ordre de 2 %.

La poche obligataire représente 80 % de la VNC totale du portefeuille d'actifs et constitue ainsi sa principale composante. Elle est composée à 60 % d'obligations souveraines et à 40 % d'obligations corporate. Le portefeuille obligataire présente un rating moyen de A.

Le spread moyen du portefeuille central est de 0,85 %, tandis que la duration moyenne de l'actif s'établit à 6,75. Ces caractéristiques permettent de définir l'exposition initiale du portefeuille aux principaux facteurs de risque de marché, avant application des différentes sensibilités considérées dans la suite de l'étude.

TABLE 2.2 – Principales caractéristiques du portefeuille d'actifs central

Caractéristique	Valeur
Valeur nette comptable	116 M
Valeur de marché	113,39 M
Part d'obligations souveraines	60 % de la poche obligataire
Part d'obligations corporate	40 % de la poche obligataire
Rating obligataire moyen	A
Spread moyen	0,85 %
Duration moyenne de l'actif	6,75
Plus-value latente globale	≈ -2 %

2.2.2 Portefeuille de passifs

Le portefeuille de passifs a également été construit afin de reproduire les principales caractéristiques d'un portefeuille moyen d'assurance vie. Il est constitué d'un encours total de provisions mathématiques (PM) de 145 millions d'euros, réparti entre 100 millions d'euros de PM euro et 45 millions d'euros de PM en unités de compte (UC). Les supports euro représentent ainsi environ 69 % des PM totales, contre 31 % pour les UC.

Afin de limiter les temps de calcul liés aux projections stochastiques, une hypothèse simplificatrice a été retenue concernant la segmentation du portefeuille. Le passif est représenté par seulement 10 model points, dont 5 associés au fonds euro et 5 aux UC. Cette réduction du nombre de model points permet d'alléger significativement les calculs tout en conservant une segmentation du portefeuille adaptée aux

objectifs de l'étude.

L'âge moyen des assurés du portefeuille central est de 63 ans. Les frais de gestion sur encours sont fixés à 0,40 % et le taux de chargement à 0,80 %. Ces hypothèses sont identiques pour l'ensemble des model points.

Le Taux Minimum Garanti (TMG) varie en revanche selon les model points du fonds euro. Le TMG moyen, pondéré par les PM du fonds euro, s'établit à 0,29 %. Les contrats en UC ne présentent quant à eux aucun TMG. Les caractéristiques détaillées des différents model points, et notamment les niveaux de TMG associés, sont présentées dans le tableau ci-dessous.

Caractéristiques des models points			
Model Point	Age moyen des assurés	Part de PM globale	TMG
1	55	10%	0%
2	60	31%	0%
3	65	10%	0,5%
4	70	10%	0,75%
5	75	7%	1%
6	55	5%	0%
7	60	14%	0%
8	65	5%	0%
9	70	5%	0%
10	75	3%	0%

FIGURE 2.1 – Détail des model points du portefeuille central

Le taux servi retenu pour le portefeuille central est de 2,40 %. Le taux de participation aux bénéfices (PB) est fixé à 85 %.

Les rachats des assurés sont décomposés en rachats structurels et en rachats conjoncturels. Les rachats structurels correspondent à un taux de 5 %, réparti entre 2 % de rachats totaux et 3 % de rachats partiels. Les rachats conjoncturels, qui permettent de prendre en compte l'évolution du comportement des assurés en fonction de l'environnement économique, sont paramétrés selon le niveau « dynamique moyenne » de SALLTO.

Enfin, la mortalité du portefeuille est modélisée à partir de la table TH0002 et la duration du passif du portefeuille central s'établit à 10,20.

TABLE 2.3 – Principales caractéristiques du portefeuille de passifs central

Caractéristique	Valeur
Provisions mathématiques totales	145 M
PM fonds euro	100 M (69 %)
PM unités de compte	45 M (31 %)
Nombre de Model Points	10
Âge moyen des assurés	63 ans
TMG moyen sur les PM euro	0,29 %
Taux servi	2,40 %
Frais de gestion sur encours	0,40 %
Taux de chargement	0,80 %
Rachats structurels totaux	2 %
Rachats structurels partiels	3 %
Rachats conjoncturels	Dynamique moyenne
Duration du passif	10,20

2.2.3 Autres hypothèses retenues

En complément des caractéristiques propres à l'actif et au passif, différentes hypothèses économiques et de projection doivent être définies afin de constituer le scénario central.

Les projections sont réalisées sous une hypothèse de run-off, c'est-à-dire sans prise en compte d'affaires nouvelles sur l'horizon de projection. Cette hypothèse est conservée aussi bien pour le portefeuille central que pour l'ensemble des sensibilités étudiées par la suite.

Le Best Estimate stochastique est calculé sur un horizon de 60 ans à partir de 1 000 simulations issues du GSE. Pour le scénario central, la volatilité des actions est fixée à 14,65 % et la volatilité des taux à 0,60 %.

La courbe des taux sans risque ainsi que la VA utilisées correspondent aux données du 31 décembre 2025. De la même manière, l'ajustement symétrique appliqué au choc actions, appelé dampener, est celui observé au 31 décembre 2025 et s'élève à 7,9 %.

Le bilan initial comporte par ailleurs une Provision pour Participation aux Excédents (PPE) de 5 millions d'euros, un capital de 9 millions d'euros ainsi qu'une réserve de capitalisation de 2 millions d'euros.

À partir de l'ensemble de ces hypothèses, la Net Asset Value (NAV) du portefeuille central s'élève à 13,54 millions d'euros, pour une Risk Margin de 1,72 million d'euros et un SCR de 7,95 millions d'euros. Le taux de couverture Solvabilité II s'établit ainsi à environ 170 % hors prise en compte de la PPE admissible.

Dans le cadre de l'étude, 60 % de la PPE est considérée comme admissible en fonds propres. En intégrant cette composante, le taux de couverture atteint environ 208 %.

TABLE 2.4 – Principaux indicateurs du portefeuille central

Indicateur	Valeur
NAV	13,54 M
Risk Margin	1,72 M
SCR	7,95 M
PPE	5,00 M
Part admissible de la PPE	60 %
Taux de couverture hors PPE	170 %
Taux de couverture avec PPE admissible	208 %

Best Estimate du portefeuille central Les deux modes de projection étudiés dans ce mémoire sont appliqués à ce même portefeuille central. Le Best Estimate obtenu à partir des projections stochastiques s'élève à 143,13 millions d'euros, contre 140,39 millions d'euros dans le cadre de la projection déterministe.

L'écart entre les deux approches est ainsi égal à :

$$BE_{sto} - BE_{det} = 143,13 - 140,39 \approx 2,74 \text{ M.} \quad (2.5)$$

Toutefois, l'utilisation de l'écart en valeur absolue rend sa comparaison fortement dépendante de la taille du portefeuille considéré. Afin de disposer d'une grandeur normalisée, la variable d'intérêt retenue correspond à l'écart entre le Best Estimate stochastique et le Best Estimate déterministe rapporté au montant total des PM :

$$Y = \frac{BE_{sto} - BE_{det}}{\sum PM}. \quad (2.6)$$

Pour le portefeuille central, cette variable vaut ainsi :

$$Y_{central} = \frac{143,13 - 140,39}{145} \approx 1,89 \%. \quad (2.7)$$

Cette valeur constitue le niveau de référence du portefeuille central. Les différentes sensibilités appliquées dans la suite de l'étude permettront alors d'analyser l'évolution de cet écart relatif en fonction des caractéristiques du portefeuille et des hypothèses retenues.

2.3 Méthodologie de construction de la base de données

2.3.1 Objectif de la base de données

L'objectif principal de ce mémoire est d'expliquer les mécanismes conduisant aux différences de valorisation entre un Best Estimate déterministe et un Best Estimate stochastique.

L'enjeu n'est pas de comparer ces deux approches d'un point de vue normatif, mais d'analyser les facteurs qui contribuent aux écarts observés afin d'en améliorer la traçabilité, la justification et la compréhension dans un cadre réglementaire.

Pour répondre à cette problématique, une base de données a été construite à partir des résultats produits par SALLTO. Chaque ligne de la base correspond à une configuration particulière du portefeuille, définie par une combinaison de valeurs prises par les différentes variables soumises à sensibilité.

La base de données est composée de neuf variables explicatives :

- la courbe des taux ;
- le spread ;
- la volatilité des taux ;
- la volatilité des actions ;
- la garantie de taux ;
- le taux de plus-values latentes sur les actions ;
- les rachats conjoncturels ;
- la duration du passif ;
- le taux minimum garanti, noté TMG.

2.3.2 Définition de la variable cible

La base de données adopte une approche centrée sur l'analyse de l'écart entre les deux méthodes de valorisation. La variable cible est définie comme la différence entre le Best Estimate stochastique et le Best Estimate déterministe, rapportée à la somme des provisions mathématiques du portefeuille :

$$Y = \frac{BE_{sto} - BE_{det}}{\sum_i PM_i}, \quad (2.8)$$

Le fait de rapporter l'écart à la somme des provisions mathématiques permet d'obtenir une mesure exprimée en pourcentage de la taille du portefeuille. Cette normalisation facilite la comparaison entre les différentes configurations et rend les résultats plus facilement généralisables.

Cette formulation permet également d'isoler plus directement les facteurs expliquant les divergences entre les deux valorisations. Elle met notamment en évidence les effets liés à l'incertitude économique, aux relations non linéaires et aux options et garanties financières.

Cette approche s'inscrit dans une démarche de transparence et de gouvernance des modèles, en cohérence avec les exigences de Solvabilité II.

2.3.3 Principe de construction des observations

Le jeu de données utilisé dans ce mémoire est construit à partir d'une démarche de sensibilités appliquée à SALLTO. Cette approche consiste à faire varier de manière contrôlée certaines hypothèses du modèle afin d'observer l'impact de ces variations sur la valorisation des engagements d'assurance.

L'objectif est de générer un ensemble d'observations structurées permettant d'analyser, dans un cadre maîtrisé, les relations entre les variables explicatives issues des sensibilités et l'écart entre le Best Estimate stochastique et le Best Estimate déterministe.

Chaque observation de la base correspond donc à une configuration donnée des hypothèses du modèle. Cette configuration est définie par une combinaison de valeurs prises par les neuf variables explicatives.

Les sensibilités sont réalisées à une date de valorisation donnée et sur un périmètre de passif constant. En dehors des variables explicitement soumises à sensibilité, l'ensemble des autres hypothèses est maintenu identique au cours des calculs.

Cette démarche permet de limiter les effets extérieurs aux paramètres étudiés. Les variations observées dans les résultats peuvent ainsi être principalement rattachées aux variables soumises à sensibilité.

Pour chaque configuration testée, SALLTO permet de calculer :

- un Best Estimate déterministe ;
- un Best Estimate stochastique ;
- la variable cible définie par l'équation (2.8).

2.3.4 Études préliminaires de sensibilité

Avant de construire la base de données définitive, deux études préliminaires de sensibilité ont été réalisées sur un ensemble plus large de variables.

L'objectif de ces études était d'identifier les variables ayant le plus d'impact sur la TVOG et de ne retenir dans la base finale que les facteurs les plus pertinents.

Les variables initialement testées étaient les suivantes :

- la volatilité des taux ;
- la volatilité des actions ;
- les rachats conjoncturels ;
- les rachats structurels ;
- l'âge des assurés ;
- le taux minimum garanti ;
- l'inflation ;
- la participation aux bénéfices ;
- la garantie de taux ;
- les chargements ;
- le taux de plus-values latentes sur les actions ;
- le spread ;
- la courbe des taux.

La première étude de sensibilité a été réalisée avec la courbe des taux au 31 décembre 2025. Une seconde étude a ensuite été réalisée avec la courbe des taux au 31 décembre 2021.

La courbe du 31 décembre 2021 a été retenue car elle correspond à un environnement de taux particulièrement bas. Cet environnement permet de mieux mettre en évidence l'impact de certaines variables, notamment celles liées aux garanties financières, dont les effets peuvent être amplifiés lorsque les taux d'intérêt sont faibles.

Afin de couvrir plusieurs environnements économiques, cinq courbes de taux sont finalement utilisées :

- la courbe au 31 décembre 2024 ;
- la courbe au 31 décembre 2023 ;
- la courbe au 31 décembre 2025 ;
- la courbe au 31 décembre 2025 augmentée de 2,5 % ;
- la courbe au 31 décembre 2021.




FIGURE 2.2 – Courbes de taux retenues pour la construction de la base de données

Ces tableaux permettent de comparer l'impact des différentes sensibilités au 31/12/2025 sur les différentes variables testées.

TAUX 2024															
	Central	Vol total		Vol Actions		Rachats conjoncturels		Rachats structurels				Age			
BE sta	119 M€	119 M€	121 M€	119 M€	120 M€	118 M€	121 M€	117 M€	118 M€	120 M€	120 M€	119 M€	119 M€	120 M€	120 M€
BE det	117 M€	117 M€	117 M€	117 M€	117 M€	117 M€	120 M€	114 M€	116 M€	118 M€	118 M€	116 M€	116 M€	117 M€	118 M€
delta BE sta central	0,0%	-0,3%	1,2%	-0,2%	0,4%	-0,8%	1,7%	-1,4%	-0,6%	0,2%	0,2%	-0,3%	-0,3%	0,4%	0,3%
delta BE det central	0,0%	0,0%	0,0%	0,0%	0,0%	0,0%	2,5%	-2,1%	-0,9%	0,8%	1,4%	-0,9%	-0,9%	0,6%	1,3%
delta BE	2,1%	1,1%	5,4%	1,9%	2,5%	1,3%	1,3%	2,9%	2,4%	1,9%	1,7%	2,5%	2,3%	1,9%	1,7%
TVOS	2,46 M€	1,3 M€	3,9 M€	2,2 M€	2,9 M€	1,5 M€	1,6 M€	0,3 M€	2,8 M€	2,2 M€	2,3 M€	2,9 M€	2,7 M€	2,2 M€	2,8 M€
Delta TVOS en €	0,8 M€	-1,1 M€	0,5 M€	-0,3 M€	0,4 M€	-1,0 M€	-0,9 M€	0,8 M€	0,3 M€	-0,2 M€	-0,4 M€	0,3 M€	0,3 M€	-0,3 M€	-0,3 M€
Delta TVOS en %	0%	-46%	20%	-12%	16%	-60%	-59%	34%	13%	-9%	-17%	20%	11%	-13%	-19%
Delta écarté en %	0%	46%	20%	12%	16%	60%	59%	34%	13%	9%	17%	20%	11%	13%	19%
	A garder	A garder	A voir	A voir	A garder	A garder	A garder/A voir	A garder/A voir	A garder/A voir	A garder/A voir	A voir	A voir	A voir	A voir	A voir

FIGURE 2.3 – Résultats de l'étude préliminaire de sensibilité – première partie

TMG			Inflation			PB			Garantie de taux		Chargement		
8%	+8.5%	+1%	8%	3%	4%	90%	95%	100%	Net	9%	0.5%	1%	1.5%
119 M€	120 M€	120 M€	119 M€	119 M€	119 M€	119 M€	120 M€	122 M€	119 M€	125 M€	120 M€	119 M€	118 M€
116 M€	117 M€	117 M€	117 M€	117 M€	117 M€	117 M€	118 M€	119 M€	117 M€	123 M€	118 M€	116 M€	116 M€
-0.2%	0.4%	0.9%	0.0%	0.0%	0.0%	0.3%	1.0%	2.3%	-0.1%	5.0%	0.7%	-0.3%	-0.9%
-0.2%	0.3%	0.5%	0.0%	0.0%	0.0%	0.2%	0.8%	2.2%	0.0%	5.8%	0.8%	-0.4%	-0.8%
2.1%	2.3%	2.6%	2.1%	2.1%	2.1%	2.2%	2.3%	2.2%	2.0%	1.3%	2.0%	2.2%	2.0%
2.4 M€	2.7 M€	3.0 M€	2.5 M€	2.5 M€	2.5 M€	2.6 M€	2.7 M€	2.6 M€	2.3 M€	1.6 M€	2.4 M€	2.6 M€	2.4 M€
0.0 M€	0.2 M€	0.5 M€	0.0 M€	0.0 M€	0.0 M€	0.1 M€	0.3 M€	0.1 M€	-0.2 M€	-0.8 M€	-0.1 M€	0.1 M€	-0.1 M€
-1%	8%	22%	0%	0%	0%	4%	12%	6%	-7%	-34%	-4%	5%	-4%
1%	8%	22%	0%	0%	0%	4%	12%	6%	7%	34%	4%	5%	4%
A garder	A garder	A garder	A voir	A voir	A voir	A voir	A voir	A voir	A voir	A voir	A voir	A voir	A voir

FIGURE 2.4 – Résultats de l'étude préliminaire de sensibilité – deuxième partie

PMVL Actions				Spread				Courbe des taux			
50%	20.0%	0%	-20.0%	-0.50%	+0.5%	+1%	+1.5%	31/12/2024	31/12/2023	31/12/2025 +2.5%	31/12/2021
120 M€	118 M€	116 M€	115 M€	121 M€	117 M€	116 M€	111 M€	123 M€	122 M€	118 M€	140 M€
117 M€	115 M€	114 M€	112 M€	118 M€	115 M€	113 M€	109 M€	120 M€	119 M€	115 M€	136 M€
0.7%	-1.3%	-2.5%	-3.8%	1.5%	-1.4%	-2.7%	-5.5%	3.2%	2.3%	-0.7%	17.8%
0.7%	-1.3%	-2.5%	-4.0%	1.5%	-1.5%	-3.2%	-5.8%	2.6%	1.8%	-1.1%	16.7%
2.1%	2.1%	2.1%	2.3%	2.1%	2.2%	2.6%	2.0%	2.7%	2.5%	2.3%	3.0%
2.5 M€	2.4 M€	2.4 M€	2.6 M€	2.44 M€	2.31 M€	3.0 M€	2.2 M€	3.3 M€	3.0 M€	2.9 M€	4.2 M€
0.0 M€	-0.1 M€	-0.1 M€	0.1 M€	0.0 M€	0.1 M€	0.5 M€	-0.3 M€	0.0 M€	0.5 M€	0.0 M€	1.7 M€
2%	-2%	-2%	5%	-1%	2%	21%	-11%	33%	22%	19%	69%
2%	2%	2%	5%	1%	2%	21%	11%	33%	22%	19%	69%
A voir	A voir	A voir	A voir	A garder	A garder	A garder	A garder	A garder	A garder	A garder	A garder

FIGURE 2.5 – Résultats de l'étude préliminaire de sensibilité – troisième partie

2.3.5 Construction de la variable de duration

À la suite des études préliminaires, l'âge des assurés et les rachats structurels n'ont pas été intégrés séparément dans la base de données définitive.

Ces deux variables ont été regroupées à travers une variable de duration du passif. En effet, l'âge des assurés et leur comportement de rachat influencent tous les deux la durée pendant laquelle les contrats restent dans le portefeuille.

La variable de duration permet donc de résumer une partie de l'information portée par ces deux facteurs. Une duration faible correspond à un écoulement plus rapide du passif, tandis qu'une duration élevée correspond à des engagements conservés plus longtemps dans le portefeuille.

2.3.6 Sélection des variables définitives

À la suite des deux études préliminaires, seules les variables ayant l'impact le plus important sur la TVOG ont été conservées.

Les neuf variables retenues sont :

1. la courbe des taux ;
2. le spread ;
3. la volatilité des taux ;
4. la volatilité des actions ;
5. la garantie de taux ;

6. le taux de plus-values latentes sur les actions ;
7. les rachats conjoncturels ;
8. la duration du passif ;
9. le TMG.

Ces variables permettent de représenter à la fois l'environnement économique, les caractéristiques des contrats, la structure du passif et le comportement des assurés.

2.3.7 Amplitude des sensibilités retenues

Pour chacune des variables sélectionnées, plusieurs modalités sont définies autour d'une configuration centrale.

Les cellules grisées correspondent à la configuration centrale du portefeuille. Cette configuration constitue le point de référence de l'étude. Les autres modalités correspondent à des sensibilités à la hausse ou à la baisse par rapport à cette situation centrale.

Vol taux	Rachat conj	Duration	Courbe des taux	Spread	TMG	Garantie de taux	Vol action	PMVL actions
0,9%	Dyn max	7	31/12/2024	2%	2%	Net	20,0%	30,0%
0,6%	Dyn moy	10	31/12/2023	1,5%	1%	Brut	14,6%	10,0%
0,3%	Dyn min	13	31/12/2025	0,85%	0,5%		10,0%	0,0%
			31/12/2025 +2,5%	0%	0%			-20,0%
			31/12/2021					

FIGURE 2.6 – Synthèse des variables et des modalités retenues dans la base de données

2.3.8 Taille de la base de données

La base de données est obtenue en croisant l'ensemble des modalités retenues pour les neuf variables explicatives.

Le nombre total de configurations est donc égal à :

$$3 \times 3 \times 3 \times 5 \times 4 \times 4 \times 2 \times 3 \times 4 = 51\,840. \quad (2.9)$$

La base de données finale contient ainsi 51 840 lignes. Chaque ligne correspond à une configuration particulière du portefeuille et contient :

- les valeurs prises par les neuf variables explicatives ;
- le Best Estimate déterministe ;
- le Best Estimate stochastique ;
- l'écart normalisé entre les deux valorisations.

La construction de cette base a donc nécessité le lancement de 51 840 projections dans SALLTO.

Le GSE dépend de trois niveaux de volatilité des taux, de trois niveaux de volatilité des actions et de cinq courbes de taux. Il a donc été nécessaire de générer :

$$3 \times 3 \times 5 = 45 \quad (2.10)$$

jeux de scénarios économiques distincts.

Pour chacun de ces jeux de scénarios, les autres variables ont ensuite été combinées directement dans SALLTO afin d'obtenir l'ensemble des 51 840 configurations.

2.3.9 Lancement automatisé de SALLTO

Le lancement manuel de 51 840 projections n'était pas envisageable compte tenu du volume de calculs nécessaire. Une procédure d'automatisation a donc été mise en place afin de lancer successivement les différentes configurations dans SALLTO.

Cette automatisation poursuit plusieurs objectifs :

- modifier les hypothèses du fichier d'entrée ;
- sélectionner le jeu de scénarios économiques correspondant ;
- lancer automatiquement SALLTO ;
- attendre la fin de chaque projection ;
- récupérer et enregistrer les fichiers de sortie ;
- associer chaque résultat à la configuration correspondante ;
- regrouper les résultats dans une base de données unique.

Chapitre 3

Apports du machine learning pour la rationalisation des écarts

Le chapitre précédent a permis de construire une base de données à partir de projections déterministes et stochastiques réalisées avec SALLTO. Chaque observation correspond à une configuration particulière du portefeuille, obtenue en faisant varier de manière contrôlée différentes hypothèses économiques, financières et contractuelles.

L'objectif est désormais d'exploiter cette base afin d'étudier la relation entre les caractéristiques du portefeuille et l'écart observé entre les deux méthodes de valorisation du *Best Estimate*. Cette problématique peut être formulée comme un problème d'apprentissage supervisé : à partir d'un ensemble de variables explicatives connues, il s'agit de construire une fonction capable d'estimer une variable cible observée lors des simulations.

Le recours au machine learning poursuit ici un double objectif. Le premier est prédictif : il s'agit d'évaluer dans quelle mesure l'écart entre le *Best Estimate* déterministe et le *Best Estimate* stochastique peut être reproduit à partir d'un nombre limité de caractéristiques du portefeuille. Le second, qui constitue un enjeu central de ce mémoire, est explicatif : les modèles doivent permettre d'identifier les variables qui contribuent le plus aux écarts observés et de mieux comprendre les mécanismes à l'origine de ces différences de valorisation.

Dans cette perspective, plusieurs familles de modèles sont étudiées. Un modèle linéaire généralisé est tout d'abord utilisé comme modèle de référence. Deux méthodes fondées sur les arbres de décision, le *Random Forest* et le *XGBoost*, sont ensuite introduites afin de représenter des relations potentiellement non linéaires et des interactions plus complexes entre les variables.

3.1 Problématique de régression dans le cadre du Best Estimate

3.1.1 Formulation du problème

La problématique étudiée dans ce mémoire s'inscrit dans le cadre d'une régression supervisée. Pour chaque configuration i du portefeuille, un ensemble de variables explicatives $\mathbf{x}_i$ est connu et associé à une valeur cible y_i obtenue à partir des projections réalisées dans SALLTO.

La variable cible retenue est l'écart entre le *Best Estimate* stochastique et le *Best Estimate* déterministe, rapporté au montant total des provisions mathématiques du portefeuille :

$$Y_i = \frac{BE_{sto,i} - BE_{det,i}}{\sum_j PM_{i,j}}. \quad (3.1)$$

Cette normalisation permet de raisonner en écart relatif plutôt qu'en montant absolu. Un écart de plusieurs millions d'euros ne possède en effet pas la même importance selon qu'il concerne un portefeuille de quelques dizaines de millions d'euros ou plusieurs milliards d'euros. La variable Y_i mesure ainsi l'écart entre les deux valorisations en proportion de la taille du portefeuille.

Pour chaque observation, le vecteur des variables explicatives peut être écrit sous la forme :

$$\mathbf{x}_i = (x_{i,1}, x_{i,2}, \dots, x_{i,9}), \quad (3.2)$$

où les neuf composantes correspondent respectivement à la courbe des taux, au spread, à la volatilité des taux, à la volatilité des actions, à la garantie de taux, au taux de plus-values latentes sur les actions, aux rachats conjoncturels, à la duration du passif et au taux minimum garanti.

Le problème revient alors à rechercher une fonction f reliant ces caractéristiques à la variable cible :

$$Y_i = f(\mathbf{x}_i) + \varepsilon_i, \quad (3.3)$$

où ε_i représente la composante de l'écart qui n'est pas expliquée par le modèle retenu.

À partir d'un échantillon d'apprentissage composé de n observations,

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n, \quad (3.4)$$

l'objectif est d'estimer une fonction $\hat{f}$ telle que :

$$\hat{Y}_i = \hat{f}(\mathbf{x}_i) \quad (3.5)$$

soit aussi proche que possible de la valeur Y_i issue des calculs réalisés avec SALLTO.

De manière générale, l'apprentissage d'un modèle de régression consiste à rechercher une fonction appartenant à une famille de fonctions $\mathcal{F}$ minimisant une fonction de perte :

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n L(y_i, f(\mathbf{x}_i)), \quad (3.6)$$

où L mesure l'écart entre la valeur réellement obtenue avec SALLTO et celle estimée par le modèle.

La nature de la famille $\mathcal{F}$ constitue précisément l'une des différences majeures entre les modèles étudiés dans ce chapitre. Dans un modèle linéaire, les relations possibles entre les variables explicatives et la cible sont fortement contraintes. À l'inverse, les méthodes fondées sur les arbres de décision permettent de construire des fonctions beaucoup plus flexibles.

Le Best Estimate déterministe n'est volontairement pas retenu comme variable explicative, alors qu'il en constituerait a priori le meilleur prédicteur.

Il intervient directement dans le calcul de la variable cible Y_i (équation 3.1) : il ne s'agit donc pas d'une caractéristique indépendante du portefeuille, au même titre que les neuf variables retenues, mais d'un terme de la définition même de la cible. L'inclure reviendrait à expliquer Y_i en partie par lui-même. Dans un modèle linéaire, il capterait mécaniquement l'essentiel de la variance de Y_i . Dans les modèles fondés sur les arbres, il dominerait de la même façon l'importance des variables et les contributions SHAP calculées par la suite, non pas parce qu'il révèle un facteur pertinent, mais du seul fait de ce lien de construction. Les effets propres aux autres variables se retrouveraient alors masqués derrière cette corrélation, à l'opposé de l'objectif du mémoire.

Le modèle est donc volontairement restreint aux neuf variables primitives du portefeuille : une contrainte plus exigeante, mais seule à même de révéler les facteurs réellement à l'origine de l'écart.

La base complète contient 51 840 configurations issues d'un même portefeuille central. La structure du portefeuille initial est donc maintenue, tandis que les différentes hypothèses sélectionnées dans le chapitre précédent sont combinées afin de couvrir un ensemble suffisamment large de situations.

Le modèle appris dans ce cadre doit ainsi être interprété comme une approximation du comportement de SALLTO sur le domaine couvert par les sensibilités réalisées. Il ne s'agit pas d'établir une relation actuarielle universelle entre les neuf variables et le *Best Estimate*, mais de modéliser les relations produites par le modèle ALM pour le portefeuille et les hypothèses considérés.

3.1.2 Pourquoi le machine learning est adapté à ce contexte

Le choix de méthodes de machine learning est principalement motivé par la nature de la relation que l'on cherche à représenter. Le *Best Estimate* stochastique résulte d'une succession de mécanismes dépendant à la fois de l'environnement économique, des caractéristiques des contrats, du comportement des assurés et des décisions prises par l'assureur.

Dans SALLTO, ces mécanismes interviennent de manière successive au cours de la projection. L'évolution des marchés modifie la valeur et le rendement des actifs. La situation financière obtenue influence ensuite

les possibilités de participation aux bénéfices, les réalisations éventuelles de plus-values ou encore les réallocations d'actifs. Ces décisions peuvent à leur tour modifier le comportement des assurés, notamment les rachats, et donc les flux futurs du portefeuille.

Il n'existe donc pas nécessairement de relation analytique simple permettant d'écrire directement :

$$Y = f(\text{taux, spread, volatilités, TMG, } \dots). \quad (3.7)$$

Le machine learning présente l'intérêt de ne pas imposer a priori une forme fonctionnelle unique à cette relation. Le modèle apprend directement, à partir des simulations disponibles, la structure permettant de relier les variables explicatives à l'écart de valorisation.

Cette propriété est particulièrement intéressante dans le cadre de l'assurance vie, où les effets de certaines variables peuvent dépendre du niveau pris par d'autres variables. Par exemple, l'impact d'une garantie financière peut dépendre de l'environnement de taux dans lequel se trouve le portefeuille. De même, la volatilité d'un actif ne produit pas nécessairement les mêmes effets selon le niveau de richesse disponible ou les caractéristiques du passif.

Ces mécanismes peuvent conduire à des **interactions** entre variables. Dans un modèle purement additif, l'effet d'une variable X_j est supposé indépendant des autres variables. Une telle structure peut être représentée par :

$$f(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p. \quad (3.8)$$

Dans cette formulation, une variation d'une unité de x_j produit toujours un effet égal à β_j , quelles que soient les valeurs prises par les autres caractéristiques du portefeuille.

Cette hypothèse peut devenir restrictive lorsqu'un mécanisme ne se déclenche qu'à partir d'un certain niveau, ou lorsque l'effet d'une variable dépend de la situation économique globale. Il serait alors nécessaire d'introduire explicitement des termes d'interaction ou des transformations non linéaires, par exemple :

$$f(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \beta_4 x_1^2 + \dots \quad (3.9)$$

Le principal problème réside alors dans le choix de ces transformations. Lorsque le nombre de variables augmente, le nombre d'interactions potentielles augmente rapidement et leur sélection devient difficile sans connaissance préalable de la forme exacte de la relation.

Les modèles fondés sur les arbres de décision permettent au contraire de détecter automatiquement certaines de ces structures à partir des données. Ils sont capables de segmenter l'espace des variables explicatives et d'identifier des comportements différents selon les zones considérées.

La taille de la base constitue également un élément favorable à l'utilisation de ces méthodes. Les 51 840 observations disponibles fournissent un volume de données permettant d'estimer des modèles plus flexibles qu'une simple régression paramétrique. Cette base présente par ailleurs un caractère contrôlé : chaque observation est issue d'un même portefeuille central et les différences entre observations proviennent

directement des sensibilités appliquées aux variables retenues.

Le machine learning présente enfin un intérêt particulier au regard du deuxième objectif du mémoire : l'explication des écarts. L'enjeu n'est pas seulement d'obtenir une fonction $\hat{f}$ présentant une erreur prédictive faible. Il s'agit également de déterminer quelles variables sont déterminantes dans la prédiction et dans quel sens elles interviennent.

Cette exigence conduit à distinguer deux dimensions de la qualité d'un modèle :

- sa **performance prédictive**, c'est-à-dire sa capacité à reproduire les valeurs obtenues avec SALLTO sur des observations non utilisées pour son apprentissage ;
- son **explicabilité**, c'est-à-dire la capacité à comprendre les facteurs conduisant aux prédictions obtenues.

Les deux ne sont pas nécessairement équivalentes. Un modèle simple peut être très facilement interprétable mais manquer de flexibilité. À l'inverse, un modèle plus complexe peut présenter une excellente capacité prédictive tout en rendant plus difficile la compréhension directe de son fonctionnement.

Cette problématique est particulièrement importante dans le cadre du présent mémoire puisque l'objectif principal est précisément de rationaliser les différences entre les deux méthodes de calcul du *Best Estimate*. Un modèle performant mais totalement inexploitable pour comprendre l'origine de ces différences ne répondrait donc que partiellement à la problématique.

Les méthodes d'explicabilité, et notamment la méthode SHAP utilisée ultérieurement, permettront de compléter l'analyse des modèles non linéaires afin de mesurer la contribution des différentes variables aux prédictions obtenues.

3.1.3 Positionnement par rapport aux approches traditionnelles

Le recours au machine learning ne doit pas être interprété comme une volonté de remplacer les modèles ALM ou les projections stochastiques utilisées dans le cadre de Solvabilité II.

Dans cette étude, SALLTO constitue au contraire le **modèle de référence**. Les valeurs utilisées pour entraîner les modèles de machine learning sont directement issues de ses projections. Le modèle statistique apprend donc à reproduire certaines relations générées par SALLTO ; il ne se substitue pas aux mécanismes actuariels, financiers et comptables qu'il contient.

Cette distinction est fondamentale. La projection stochastique demeure nécessaire pour obtenir une valorisation complète intégrant explicitement les différents scénarios économiques ainsi que les interactions entre l'actif et le passif. Le machine learning constitue ici un **outil complémentaire**, construit à partir des résultats du modèle ALM.

Il est ainsi possible de distinguer trois niveaux d'analyse.

Le premier repose sur la projection stochastique complète dans SALLTO. Il s'agit de l'approche la plus riche puisque tous les mécanismes du modèle sont simulés pour chacun des scénarios économiques. Elle constitue la référence à laquelle les autres méthodes sont comparées.

Le deuxième repose sur un modèle statistique paramétrique classique. Dans le cadre de cette étude, un modèle linéaire généralisé est utilisé comme modèle de référence. Il permet de tester si l'écart étudié peut être expliqué de manière satisfaisante par une relation relativement simple et additive entre les variables.

Le troisième repose sur des méthodes de machine learning non linéaires. Leur objectif est d'apporter davantage de flexibilité lorsque la structure du problème ne peut pas être correctement représentée par une relation paramétrique simple.

Cette hiérarchie permet d'éviter de recourir directement à un modèle complexe sans disposer d'un point de comparaison. Le GLM joue ainsi un rôle de *benchmark*. Si un modèle linéaire permettait déjà d'expliquer correctement les écarts, l'utilisation d'algorithmes plus complexes serait difficile à justifier. À l'inverse, une amélioration significative obtenue par les méthodes non linéaires apporterait des éléments en faveur de l'existence de relations plus complexes dans les résultats produits par le modèle ALM.

La comparaison entre ces modèles ne portera donc pas uniquement sur leur précision. Elle permettra également d'étudier le compromis entre simplicité, performance et capacité d'explication.

Le positionnement retenu peut être résumé par la chaîne suivante :

SALLTO → Base de simulations → Apprentissage d'un proxy → Analyse des facteurs d'écart
--

(3.10)

Le modèle de machine learning peut ainsi être assimilé à un **métamodèle** ou à un **modèle proxy** : il apprend à approximer une sortie d'un modèle numérique plus complexe à partir d'un ensemble réduit de variables explicatives.

Une fois entraîné, un tel proxy présente l'avantage de fournir une estimation pratiquement instantanée de la variable cible pour une configuration appartenant au domaine étudié. Il pourrait donc, dans un contexte opérationnel, être utilisé pour réaliser rapidement des analyses exploratoires ou identifier les configurations méritant ensuite une analyse complète avec le modèle ALM.

Toutefois, cette utilisation doit rester encadrée. La qualité d'un proxy dépend directement de la base ayant servi à son apprentissage. Dans le cadre de ce mémoire, les observations proviennent d'un portefeuille central unique et d'un ensemble défini de sensibilités. Le modèle apprend donc le comportement de SALLTO sur ce domaine particulier.

Il ne peut par conséquent pas être supposé valide pour un portefeuille présentant une structure très différente ou pour des niveaux de variables très éloignés de ceux présents dans la base d'apprentissage. Cette question de domaine de validité constitue une limite importante des méthodes de machine learning et sera prise en compte dans l'interprétation des résultats.

3.2 Présentation des modèles de machine learning utilisés

Afin de déterminer le niveau de complexité nécessaire pour reproduire et expliquer la variable cible, trois modèles sont étudiés. Ils ont été retenus de manière à couvrir différents niveaux de flexibilité.

Le modèle linéaire généralisé constitue une référence simple et directement interprétable. Le *Random Forest* introduit ensuite des relations non linéaires et des interactions à partir d'un ensemble d'arbres de décision construits indépendamment. Enfin, le *XGBoost* repose sur une construction séquentielle des arbres et cherche progressivement à corriger les erreurs commises par les modèles précédents.

Ces trois modèles permettront ainsi d'étudier si l'augmentation de la complexité du modèle apporte effectivement une amélioration dans la représentation de l'écart entre valorisations déterministe et stochastique.

3.2.1 Modèles de référence

Le premier modèle retenu est un modèle linéaire généralisé, ou GLM (*Generalized Linear Model*). Il constitue le modèle de référence de l'étude.

Les GLM généralisent la régression linéaire en permettant de relier l'espérance conditionnelle de la variable cible aux variables explicatives à travers une fonction de lien g :

$$g(\mathbb{E}[Y | \mathbf{X}]) = \beta_0 + \sum_{j=1}^p \beta_j X_j. \quad (3.11)$$

Dans le cas d'une variable cible continue et d'une fonction de lien identité, cette formulation devient :

$$\mathbb{E}[Y | \mathbf{X}] = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p. \quad (3.12)$$

Chaque coefficient β_j représente alors l'effet associé à la variable X_j , toutes choses égales par ailleurs.

Cette propriété constitue l'un des principaux avantages du GLM dans le cadre de ce mémoire. Le signe d'un coefficient permet d'identifier le sens de la relation entre une variable et la cible, tandis que son amplitude apporte une information sur l'importance de cette relation, sous réserve de tenir compte de l'échelle des différentes variables.

Le modèle constitue donc une première approche particulièrement transparente du problème.

La simplicité du GLM constitue cependant également sa principale limite. En l'absence de termes supplémentaires, il suppose que les effets des différentes variables sont additifs et que la relation avec le prédicteur linéaire peut être décrite à partir d'une forme prédéterminée.

Les interactions doivent notamment être introduites explicitement. Pour représenter une interaction entre deux variables X_1 et X_2 , il faudrait par exemple écrire :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon. \quad (3.13)$$

De la même manière, une relation non linéaire nécessite l'introduction volontaire de transformations telles que X^2 , $\log(X)$ ou d'autres fonctions adaptées.

Dans une problématique où la forme exacte des interactions produites par un modèle ALM n'est pas connue à l'avance, cette contrainte peut limiter la capacité du GLM à représenter l'ensemble des comportements observés.

Le GLM constitue néanmoins un benchmark essentiel. Il permet de déterminer si la complexité supplémentaire introduite par les méthodes non linéaires est réellement nécessaire. Les performances des modèles plus complexes devront donc être analysées relativement à cette référence.

3.2.2 Modèles non linéaires

3.2.2.1 Le Random Forest

La *Random Forest*, ou forêt aléatoire, est une méthode d'apprentissage supervisé reposant sur l'agrégation d'un grand nombre d'arbres de décision.

Un arbre de décision construit progressivement une partition de l'espace des variables explicatives. À chaque nœud, une variable et un seuil sont sélectionnés afin de diviser les observations en deux groupes aussi homogènes que possible vis-à-vis de la variable cible.

Pour une variable X_j et un seuil s , la séparation peut être représentée par :

$$R_1(j, s) = \{\mathbf{x} : x_j \leq s\}, \quad R_2(j, s) = \{\mathbf{x} : x_j > s\}. \quad (3.14)$$

Dans un problème de régression, le couple (j, s) est choisi de manière à minimiser l'erreur au sein des deux régions créées.

Ce mécanisme est ensuite reproduit récursivement sur chacune des sous-régions. La prédiction finale d'un arbre correspond à la moyenne des observations appartenant à la feuille terminale dans laquelle se trouve la nouvelle observation.

Un arbre individuel possède une grande flexibilité mais peut être fortement dépendant de l'échantillon ayant servi à sa construction. Il présente donc un risque de variance élevée et de surapprentissage.

La *Random Forest* cherche à réduire cette instabilité en combinant plusieurs arbres.

Deux mécanismes principaux sont utilisés.

Tout d'abord, chaque arbre est entraîné sur un échantillon bootstrap de la base d'apprentissage, c'est-à-dire un échantillon obtenu par tirage avec remise parmi les observations disponibles.

Ensuite, à chaque séparation d'un arbre, seule une fraction aléatoire des variables explicatives est proposée pour déterminer la meilleure coupure. Ce mécanisme réduit la corrélation entre les différents arbres et

évite qu'une même variable dominante conduise systématiquement à des arbres très similaires.

Pour une forêt composée de B arbres T_b , la prédiction finale s'écrit :

$$\hat{f}_{RF}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}). \quad (3.15)$$

La moyenne des prédictions permet ainsi de réduire la variance associée à un arbre individuel.

Dans le cadre de ce mémoire, le *Random Forest* présente plusieurs propriétés intéressantes. Il ne nécessite pas de spécifier à l'avance la forme de la relation entre les variables explicatives et la cible. Il peut également faire apparaître naturellement des interactions entre variables puisque les différentes séparations d'un arbre sont conditionnelles aux séparations effectuées précédemment.

Il constitue ainsi une première méthode permettant de tester si l'écart entre les deux *Best Estimate* présente une structure plus complexe que celle représentable par un GLM.

En contrepartie, l'interprétation du modèle devient moins immédiate. Contrairement au GLM, il n'existe pas un coefficient directement associé à chaque variable. Des méthodes spécifiques doivent être mobilisées pour mesurer l'importance et l'effet des caractéristiques sur les prédictions.

3.2.2.2 Le XGBoost

Le deuxième modèle non linéaire retenu est l'*Extreme Gradient Boosting*, généralement appelé XGBoost.

Comme le *Random Forest*, XGBoost repose sur des arbres de décision. La logique de construction est toutefois fondamentalement différente.

Dans une forêt aléatoire, les arbres sont construits de manière largement indépendante avant que leurs prédictions soient moyennées. Dans une méthode de *boosting*, les arbres sont au contraire construits successivement. Chaque nouvel arbre vise à améliorer les erreurs commises par l'ensemble des arbres précédents.

La prédiction d'un modèle composé de K arbres peut s'écrire :

$$\hat{y}_i = \sum_{k=1}^K f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F}, \quad (3.16)$$

où $\mathcal{F}$ désigne l'ensemble des arbres de régression pouvant être construits.

À l'étape t , la prédiction devient :

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i). \quad (3.17)$$

Le nouvel arbre f_t n'est donc pas construit indépendamment. Il est choisi afin d'améliorer la fonction objectif à partir des erreurs encore présentes après les étapes précédentes.

La fonction objectif utilisée par XGBoost peut être représentée sous la forme :

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l\left(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)\right) + \Omega(f_t), \quad (3.18)$$

où l représente la fonction de perte utilisée pour mesurer l'erreur prédictive et Ω un terme de régularisation contrôlant la complexité du nouvel arbre.

Une formulation classique du terme de régularisation est :

$$\Omega(f) = \gamma T + \frac{\lambda}{2} \sum_{j=1}^T w_j^2, \quad (3.19)$$

où T correspond au nombre de feuilles de l'arbre et w_j à la valeur associée à la feuille j .

Le paramètre γ pénalise donc l'ajout de feuilles supplémentaires, tandis que λ limite l'amplitude des valeurs attribuées aux feuilles. Ce mécanisme permet de rechercher un compromis entre amélioration de la prédiction et complexité du modèle.

Une autre caractéristique importante du boosting est le *learning rate*. Plutôt que d'ajouter intégralement chaque nouvel arbre à la prédiction, sa contribution peut être réduite par un paramètre η :

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta f_t(\mathbf{x}_i), \quad 0 < \eta \leq 1. \quad (3.20)$$

Une valeur faible de η conduit généralement à utiliser davantage d'arbres, chacun corrigeant plus progressivement les erreurs du modèle.

XGBoost combine ainsi plusieurs propriétés particulièrement adaptées à la problématique étudiée : il permet de représenter des relations non linéaires, de prendre en compte des interactions entre variables et d'introduire différents mécanismes de régularisation afin de contrôler le surapprentissage.

Sa flexibilité a cependant un coût en termes d'interprétabilité. Le résultat final est la combinaison d'un grand nombre d'arbres et il devient difficile de relier directement une prédiction à une relation simple entre les variables d'entrée et la cible.

Cette limite est particulièrement importante dans le cadre du mémoire, puisque l'explication des écarts constitue un objectif au moins aussi important que leur prédiction. L'utilisation ultérieure de valeurs SHAP permettra donc de compléter l'analyse de XGBoost en quantifiant la contribution de chaque variable aux prédictions du modèle.

3.2.3 Avantages et limites de chaque modèle dans le cadre d'étude

Les trois modèles retenus présentent des niveaux de complexité et d'interprétabilité différents. Leur comparaison doit donc dépasser la seule mesure de leur précision prédictive.

Le GLM présente l'avantage majeur de sa transparence. La relation entre les variables et la cible peut être directement étudiée à travers les coefficients estimés. Il constitue également un modèle rapide à entraîner et relativement peu exposé au surapprentissage lorsque le nombre de variables reste limité.

Sa principale faiblesse réside dans les hypothèses imposées à la relation entre les variables. Si les mécanismes issus du modèle ALM présentent des non-linéarités, des seuils ou des interactions importantes, une structure linéaire peut ne pas être suffisamment flexible.

Le *Random Forest* permet de lever une grande partie de ces contraintes. Sa construction à partir d'arbres lui permet de représenter des comportements non linéaires sans nécessiter de transformation préalable des variables. Le mécanisme de bootstrap et l'agrégation d'un grand nombre d'arbres limitent par ailleurs l'instabilité d'un arbre de décision individuel.

Son fonctionnement devient toutefois moins directement interprétable. De plus, les prédictions des arbres reposent sur des partitions de valeurs observées lors de l'apprentissage. Leur capacité à extrapoler en dehors du domaine de données couvert par la base est donc limitée.

XGBoost possède généralement une flexibilité encore plus importante. La construction séquentielle permet de concentrer progressivement l'apprentissage sur les observations les plus difficiles à reproduire. Les nombreux paramètres de régularisation permettent également de contrôler finement la complexité du modèle.

Cette flexibilité augmente toutefois le nombre d'hyperparamètres à déterminer et donc le risque de surapprentissage lorsque leur calibration est insuffisante. Elle accentue également l'effet "boîte noire" du modèle, ce qui rend nécessaire l'utilisation d'outils d'explicabilité complémentaires.

Le tableau 3.1 synthétise les principales caractéristiques des trois modèles dans le contexte de l'étude.

TABLE 3.1 – Comparaison des modèles retenus dans le cadre de l'étude

Modèle	Principaux avantages	Principales limites	Interprétabilité	Rôle dans l'étude
GLM	Simplicité, rapidité, coefficients directement exploitables	Relations principalement linéaires et additives, interactions à spécifier	Élevée	Modèle de référence permettant d'évaluer l'intérêt d'une complexité supplémentaire
Random Forest	Non-linéarités, interactions automatiques, réduction de la variance par agrégation	Extrapolation limitée, perte d'interprétabilité par rapport au GLM	Intermédiaire	Premier modèle non linéaire permettant de représenter des relations complexes
XGBoost	Grande flexibilité, interactions, apprentissage séquentiel et régularisation	Nombreux hyperparamètres, risque de surapprentissage, fonctionnement moins transparent	Faible directement, améliorée par SHAP	Modèle flexible destiné à rechercher une forte capacité de reproduction tout en permettant une analyse a posteriori

Une attention particulière doit enfin être portée à la notion de **domaine de validité**. Les données utilisées dans ce mémoire ne constituent pas un échantillon aléatoire représentatif de l'ensemble des portefeuilles d'assurance vie. Elles proviennent d'un portefeuille central auquel ont été appliquées différentes sensibilités.

Les modèles appris doivent donc avant tout être considérés comme valides à l'intérieur du domaine couvert par ces sensibilités. Ce point est particulièrement important pour les méthodes fondées sur les arbres, dont la capacité d'extrapolation en dehors des valeurs rencontrées pendant l'apprentissage est faible.

De la même manière, les relations mises en évidence par les modèles ne doivent pas être interprétées comme des relations universelles. Elles décrivent le comportement de SALLTO compte tenu du portefeuille, du GSE, des hypothèses de comportement et des règles de gestion retenues dans cette étude.

Cette dépendance ne constitue pas nécessairement une faiblesse de l'approche. Elle correspond à la nature même d'un métamodèle : son objectif est de reproduire et d'expliquer le comportement d'un modèle complexe sur un domaine déterminé.

Dans les sections suivantes, les différents modèles seront entraînés dans des conditions identiques puis comparés à l'aide de plusieurs indicateurs de performance. Le coefficient de détermination R^2 , la MAE et la RMSE permettront notamment d'évaluer leur capacité à reproduire la variable cible. Ces mesures seront ensuite complétées par une analyse de l'explicabilité des modèles afin de déterminer si l'amélioration éventuelle de la performance prédictive s'accompagne également d'une meilleure compréhension des facteurs à l'origine des écarts entre valorisations déterministe et stochastique.

3.3 Méthodologie d'apprentissage

3.3.1 Séparation des données

L'apprentissage d'un modèle statistique nécessite de distinguer les observations utilisées pour son estimation de celles servant à évaluer sa qualité. Un modèle évalué sur les données ayant servi à sa construction produit en effet une mesure de performance optimiste : il ne s'agit plus alors d'apprécier sa capacité à prédire de nouvelles observations, mais uniquement sa capacité à reproduire celles qu'il a déjà rencontrées.

Cette distinction revêt une importance particulière dans le cadre de cette étude. Les trois modèles retenus présentent des niveaux de flexibilité très différents (cf. section 3.2.3), et l'un des objectifs de la comparaison consiste précisément à déterminer si la complexité supplémentaire introduite par les méthodes non linéaires apporte un gain réel. Or les modèles les plus flexibles sont également ceux dont la performance mesurée en apprentissage s'éloigne le plus de la performance réellement obtenue sur de nouvelles observations. Une évaluation menée sur les seules données d'apprentissage favoriserait donc mécaniquement le Random Forest et XGBoost, indépendamment de leur véritable apport.

Formellement, l'échantillon complet $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ introduit à l'équation (3.4) est partitionné en deux sous-ensembles disjoints :

$$\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{test}}, \quad \mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{test}} = \emptyset. \quad (3.21)$$

L'estimation de la fonction $\hat{f}$ définie à l'équation (3.6) est réalisée uniquement à partir de $\mathcal{D}_{\text{train}}$. L'échan-

tillon $\mathcal{D}_{\text{test}}$ n'intervient qu'au moment de l'évaluation finale des modèles, présentée à la section 3.4.

3.3.1.1 Répartition retenue

La base est répartie entre un échantillon d'apprentissage représentant 70 % des observations et un échantillon de test représentant les 30 % restants. Compte tenu des 51 840 configurations disponibles (cf. section 2.3.8), cette répartition conduit à 36 288 observations pour l'apprentissage et 15 552 observations pour le test.

Ce choix résulte d'un arbitrage entre deux exigences. L'échantillon d'apprentissage doit être suffisamment fourni pour permettre l'estimation de modèles flexibles, en particulier les méthodes fondées sur les arbres, dont la capacité à représenter des relations complexes dépend directement du nombre d'observations disponibles dans chaque région de l'espace des variables explicatives. L'échantillon de test doit pour sa part conserver un effectif suffisant pour que les indicateurs de performance calculés à la section 3.4 soient estimés avec une précision satisfaisante.

La taille de la base rend cet arbitrage relativement peu contraignant. Avec plus de quinze mille observations, l'échantillon de test permet une évaluation stable des indicateurs retenus. Un ratio plus favorable à l'apprentissage n'apporterait par ailleurs qu'un gain marginal, le nombre d'observations disponibles étant déjà très élevé au regard des neuf variables explicatives du modèle.

3.3.1.2 Modalités du tirage

La répartition est effectuée par tirage aléatoire simple, ligne à ligne, parmi les 51 840 configurations de la base. Chaque observation dispose ainsi de la même probabilité d'être affectée à l'échantillon d'apprentissage, indépendamment des valeurs prises par ses variables explicatives.

Cette modalité de tirage appelle une précision quant à la nature de l'évaluation qu'elle permet. La base ne résulte pas d'un échantillonnage aléatoire mais du croisement complet des modalités retenues pour les neuf variables explicatives (cf. section 2.3.8). Deux configurations peuvent donc y être très proches l'une de l'autre, ne différant que par la modalité d'une seule variable, l'ensemble des autres hypothèses demeurant identiques.

Un tirage aléatoire ligne à ligne conduit par conséquent à ce que des configurations voisines dans la grille se répartissent de part et d'autre de la séparation. Une observation de l'échantillon de test possède ainsi, avec une probabilité élevée, plusieurs configurations directement adjacentes au sein de l'échantillon d'apprentissage.

L'échantillon de test mesure donc la capacité des modèles à interpoler à l'intérieur de la grille des sensibilités réalisées, plutôt que leur capacité à extrapoler vers des configurations réellement inédites. Cette portée doit être gardée à l'esprit lors de la lecture des indicateurs présentés à la section 3.4, en particulier pour les méthodes fondées sur les arbres, dont les limites en matière d'extrapolation ont déjà été relevées à la section 3.2.3.

Cette caractéristique ne remet pas en cause la pertinence de la démarche. L'objectif de l'étude consiste à reproduire et à expliquer le comportement de SALLTO sur le domaine couvert par les sensibilités, conformément au positionnement en métamodèle défini à la section 3.1.3, et non à prédire des configurations

situées hors de ce domaine. Elle justifie néanmoins le recours à la validation externe présentée plus loin dans cette section, seule à même d'évaluer la robustesse des modèles au-delà du domaine d'apprentissage.

3.3.1.3 Répétition de la séparation

La partition définie à l'équation (3.21) dépend du tirage aléatoire ayant présidé à sa construction. Une répartition particulière peut ainsi se révéler légèrement plus favorable à l'un des modèles, et les indicateurs de performance obtenus comportent de ce fait une part de variabilité qui ne reflète pas la qualité intrinsèque des modèles comparés.

La séparation n'est donc pas figée sur un tirage unique. L'opération est répétée à plusieurs reprises, chaque nouvelle répartition donnant lieu à un réentraînement complet des trois modèles et au calcul des indicateurs de performance correspondants.

En notant $\hat{f}^{(s)}$ le modèle estimé à partir de la s -ième répartition et $M(\hat{f}^{(s)})$ l'indicateur de performance associé, la comparaison porte alors sur la moyenne obtenue sur l'ensemble des S répétitions :

$$\bar{M} = \frac{1}{S} \sum_{s=1}^S M(\hat{f}^{(s)}), \quad (3.22)$$

ainsi que sur la dispersion de ces valeurs :

$$\hat{\sigma}_M^2 = \frac{1}{S-1} \sum_{s=1}^S \left(M(\hat{f}^{(s)}) - \bar{M} \right)^2. \quad (3.23)$$

Cette démarche poursuit deux objectifs. Elle fournit d'une part une estimation plus fiable de la performance de chaque modèle, moins dépendante d'une répartition particulière. Elle permet d'autre part d'apprécier la stabilité des résultats : une dispersion faible indique que les performances observées ne résultent pas des circonstances d'un tirage donné, tandis qu'une dispersion importante conduirait à nuancer toute conclusion tirée de la comparaison des modèles.

Ce point présente un intérêt particulier au regard de l'objectif de l'étude. La comparaison entre le GLM et les méthodes non linéaires vise à déterminer si la complexité supplémentaire de ces dernières est justifiée (cf. section 3.1.3). Un écart de performance dont l'amplitude resterait comparable à la variabilité induite par le seul choix de la répartition ne permettrait pas de conclure en ce sens.

3.3.1.4 Validation croisée au sein de l'échantillon d'apprentissage

La détermination des hyperparamètres décrite à la section 3.3.2 nécessite de comparer plusieurs configurations de chaque modèle. Cette comparaison suppose de disposer d'une mesure de performance calculée sur des observations non utilisées pour l'estimation, sans pour autant mobiliser l'échantillon de test.

Recourir à ce dernier pour sélectionner les hyperparamètres reviendrait en effet à l'intégrer indirectement au processus de construction des modèles. Les valeurs retenues seraient celles produisant les meilleurs résultats sur cet échantillon précis, et la performance finale mesurée sur les mêmes observations perdrait

son caractère hors échantillon.

Une validation croisée à k blocs est donc mise en œuvre à l'intérieur du seul échantillon d'apprentissage. Celui-ci est divisé en k sous-ensembles de taille comparable :

$$\mathcal{D}_{\text{train}} = \bigcup_{m=1}^k \mathcal{D}_m, \quad \mathcal{D}_m \cap \mathcal{D}_{m'} = \emptyset \quad \text{pour } m \neq m'. \quad (3.24)$$

Le modèle est ensuite estimé k fois. À chaque itération m , l'apprentissage est réalisé sur les $k - 1$ blocs restants et l'évaluation sur le bloc $\mathcal{D}_m$ laissé de côté. L'erreur de validation croisée correspond à la moyenne des erreurs ainsi obtenues :

$$\text{Err}_{\text{CV}} = \frac{1}{k} \sum_{m=1}^k \frac{1}{|\mathcal{D}_m|} \sum_{i \in \mathcal{D}_m} L(y_i, \hat{f}^{(-m)}(x_i)), \quad (3.25)$$

où $\hat{f}^{(-m)}$ désigne le modèle estimé sans le bloc $\mathcal{D}_m$.

Chaque observation de l'échantillon d'apprentissage contribue ainsi une fois à l'évaluation et $k - 1$ fois à l'estimation. Cette organisation permet d'exploiter l'intégralité des données disponibles pour la calibration tout en préservant le caractère hors échantillon de la mesure utilisée pour comparer les configurations.

La configuration d'hyperparamètres retenue est celle minimisant Err_{CV} . Le modèle final est ensuite réestimé sur l'intégralité de l'échantillon d'apprentissage à partir de ces valeurs, puis évalué sur l'échantillon de test.

3.3.1.5 Validation externe sur un second portefeuille central

Les dispositifs précédents partagent une limite commune. L'échantillon de test comme les blocs de validation croisée sont issus de la même grille de configurations, construite à partir d'un unique portefeuille central. Ils permettent d'évaluer la capacité des modèles à généraliser à l'intérieur de ce domaine, mais ne renseignent pas sur leur comportement en dehors de celui-ci.

Cette limite correspond directement à la question du domaine de validité soulevée à la section 3.2.3. Les relations apprises par les modèles décrivent le comportement de SALLTO compte tenu du portefeuille, du générateur de scénarios économiques et des règles de gestion retenus dans cette étude. Rien ne garantit a priori qu'elles demeurent pertinentes pour un portefeuille présentant une structure différente.

Un dispositif de validation supplémentaire est donc mis en place. Une seconde base de données est construite selon la même démarche que celle décrite au chapitre 2, mais à partir d'un portefeuille central distinct de celui ayant servi à l'apprentissage. Les mêmes variables explicatives et les mêmes modalités de sensibilité y sont appliquées, de sorte que les deux bases demeurent comparables dans leur structure.

Les modèles entraînés sur la première base sont appliqués à ces nouvelles configurations sans aucune réestimation. Aucun paramètre n'est ajusté et aucun hyperparamètre n'est recalibré : les modèles sont utilisés exactement tels qu'ils ont été construits.

Cette validation externe constitue le test de généralisation le plus exigeant de l'étude. Elle permet d'apprécier si les relations identifiées entre les caractéristiques du portefeuille et l'écart de valorisation possèdent une portée dépassant le seul portefeuille central initial, ou si elles demeurent étroitement dépendantes de ses caractéristiques propres.

L'enjeu dépasse la seule vérification technique. Un métamodèle dont les conclusions ne seraient valables que pour un portefeuille donné présenterait un intérêt opérationnel limité, tandis que la stabilité des facteurs explicatifs identifiés d'un portefeuille à l'autre renforcerait leur interprétation actuarielle. Les résultats de cette validation sont présentés au chapitre 4.

TABLE 3.2 – Niveaux de séparation des données et objectifs associés

Niveau	Données mobilisées	Objectif
Validation croisée	Blocs internes à l'échantillon d'apprentissage	Sélection des hyperparamètres sans mobiliser l'échantillon de test
Échantillon de test	30 % de la base, soit 15 552 configurations	Évaluation finale des modèles à l'intérieur du domaine des sensibilités
Répétition des tirages	Plusieurs répartitions successives de la base complète	Vérification de la stabilité des performances au regard du tirage retenu
Validation externe	Base construite à partir d'un second portefeuille central	Évaluation de la généralisation en dehors du portefeuille d'apprentissage

3.3.2 Contrôle de la complexité et choix des hyperparamètres

L'estimation d'un modèle statistique fait intervenir deux catégories de quantités. Les paramètres sont déterminés par l'algorithme lui-même à partir des données d'apprentissage : il s'agit par exemple des coefficients β_j du GLM ou des seuils de division des arbres de décision. Les hyperparamètres sont au contraire fixés avant l'apprentissage et définissent la manière dont celui-ci est conduit.

Ces hyperparamètres déterminent principalement la flexibilité du modèle, c'est-à-dire l'étendue de la famille de fonctions $\mathcal{F}$ dans laquelle la solution est recherchée, conformément à la formulation de l'équation (3.6). Leur calibration constitue donc le principal levier de contrôle du surapprentissage.

3.3.2.1 Nature du risque de surapprentissage dans le cadre de l'étude

Le surapprentissage désigne la situation dans laquelle un modèle reproduit fidèlement les observations ayant servi à son apprentissage, mais perd une partie de sa capacité à prédire correctement de nouvelles observations. Le modèle n'apprend alors plus uniquement la relation systématique reliant les variables explicatives à la cible : il apprend également les fluctuations propres à l'échantillon utilisé.

La nature de ce risque doit être précisée dans le cadre de cette étude. Les observations de la base ne proviennent pas de mesures empiriques bruitées au sens habituel, mais des projections réalisées avec SALLTO. Pour une configuration donnée des neuf variables explicatives, le Best Estimate détermine

est entièrement déterminé par les hypothèses retenues : une même configuration relancée dans le modèle produit exactement le même résultat.

Il n'en va pas de même pour le Best Estimate stochastique. Celui-ci est obtenu en moyennant les flux actualisés sur les 1 000 simulations issues du générateur de scénarios économiques (cf. section 2.2.3). Il constitue donc une estimation par simulation, entachée d'une erreur d'échantillonnage de Monte-Carlo. Un même jeu d'hypothèses relancé avec un autre tirage de scénarios conduirait à une valeur légèrement différente.

Cette erreur d'estimation se répercute directement sur la variable cible, puisque BE_{sto} intervient au numérateur de l'équation (3.1). Elle correspond ainsi à une partie du terme ε_i introduit à l'équation (3.3), qui représente la composante de l'écart non expliquée par les variables explicatives retenues.

Un modèle suffisamment flexible peut chercher à reproduire ces fluctuations plutôt que la relation sous-jacente. Il ajusterait alors des variations qui ne se reproduiraient pas sur un nouveau tirage de scénarios économiques. Le risque de surapprentissage demeure donc réel, malgré le caractère contrôlé de la base de données.

Ce phénomène s'inscrit dans le compromis classique entre biais et variance. Pour une configuration x donnée, l'erreur quadratique moyenne attendue d'un modèle $\hat{f}$ peut se décomposer sous la forme :

$$\mathbb{E} \left[\left(Y - \hat{f}(x) \right)^2 \right] = \underbrace{\left(\mathbb{E} [\hat{f}(x)] - f(x) \right)^2}_{\text{biais}^2} + \underbrace{\mathbb{V} [\hat{f}(x)]}_{\text{variance}} + \underbrace{\sigma^2}_{\text{bruit irréductible}}. \quad (3.26)$$

Un modèle trop contraint présente un biais élevé : il ne parvient pas à représenter la véritable relation f . Un modèle trop flexible présente au contraire une variance élevée : ses prédictions dépendent fortement de l'échantillon particulier ayant servi à son apprentissage. Le terme σ^2 correspond à la part d'incertitude qu'aucun modèle ne peut expliquer, et qui recouvre ici l'erreur de simulation évoquée précédemment.

Le choix des hyperparamètres revient donc à positionner chaque modèle au meilleur compromis entre ces deux sources d'erreur. Les sections suivantes présentent, pour chacun des trois modèles, les hyperparamètres retenus, leur rôle dans le contrôle de la complexité et les valeurs finalement adoptées.

3.3.2.2 Le GLM

Le GLM constitue le modèle le moins exposé au surapprentissage parmi les trois retenus. La base comporte 51 840 observations pour seulement neuf variables explicatives, soit un rapport entre le nombre d'observations et le nombre de paramètres très largement favorable. La famille de fonctions $\mathcal{F}$ dans laquelle le modèle est recherché est par ailleurs fortement contrainte, comme indiqué à la section 3.1.1 : elle se limite aux combinaisons linéaires des variables explicatives.

Le modèle ne comporte de ce fait aucun hyperparamètre à calibrer. Les coefficients β_j sont directement estimés par maximum de vraisemblance à partir de l'échantillon d'apprentissage.

Le principal risque associé à ce modèle ne concerne donc pas sa capacité de généralisation, mais la stabilité de ses coefficients. En présence d'une corrélation importante entre plusieurs variables explicatives, les estimateurs $\hat{\beta}_j$ peuvent présenter une variance élevée. Leur amplitude, voire leur signe, devient alors

sensible à de faibles variations de l'échantillon. Le modèle conserve dans ce cas une qualité d'ajustement globale satisfaisante, mais l'interprétation individuelle de chaque coefficient perd sa fiabilité.

Cette question est déterminante ici, puisque l'intérêt principal du GLM dans cette étude réside précisément dans la lecture directe de ses coefficients (cf. section 3.2.1).

Un facteur d'inflation de la variance, ou VIF (*Variance Inflation Factor*), a donc été calculé pour chacune des neuf variables. Cet indicateur mesure dans quelle proportion la variance d'un coefficient estimé se trouve augmentée par la corrélation de la variable concernée avec les autres variables du modèle. Il s'écrit :

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad (3.27)$$

où R_j^2 désigne le coefficient de détermination obtenu en régressant la variable X_j sur l'ensemble des autres variables explicatives. Une valeur proche de 1 traduit une variable pratiquement indépendante des autres. Les seuils de 5 et 10 sont habituellement retenus comme indicateurs d'une colinéarité respectivement modérée et préoccupante.

La structure de la base rend ce diagnostic largement prévisible. Les observations résultent du croisement complet des modalités retenues pour les neuf variables (cf. section 2.3.8). Chaque modalité d'une variable est donc associée au même nombre d'observations pour chacune des modalités des autres variables. Ce plan factoriel complet assure par construction une quasi-orthogonalité entre les variables explicatives, contrairement à des données observées dans lesquelles les facteurs économiques apparaissent naturellement corrélés.

[Insérer ici les valeurs de VIF obtenues pour les neuf variables et le commentaire associé.]

Une version pénalisée du GLM, de type Ridge ou Lasso, n'a pas été retenue. Ces méthodes consistent à ajouter à la fonction de perte un terme pénalisant l'amplitude des coefficients, par exemple :

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \alpha \sum_{j=1}^p \beta_j^2 \right\}, \quad (3.28)$$

où α contrôle l'intensité de la pénalisation. Le paramètre est ici noté α afin d'éviter toute confusion avec le paramètre λ de régularisation de XGBoost introduit à l'équation (3.19).

Trois raisons justifient de ne pas recourir à ces méthodes dans le cadre de cette étude.

- La pénalisation vise principalement à stabiliser les coefficients en présence de colinéarité. Or le plan factoriel complet et le contrôle par VIF écartent déjà ce risque.
- Elle vise également à limiter le surapprentissage lorsque le nombre de variables est élevé au regard du nombre d'observations, ce qui n'est pas le cas ici.
- Elle introduit enfin un biais volontaire sur les coefficients estimés, dont l'amplitude se trouve réduite

par construction. Cette contraction nuirait directement à la lecture des effets associés à chaque variable, alors que cette lecture constitue la raison même de la présence du GLM dans l'étude.

La sélection de variables opérée par une pénalisation de type Lasso présenterait par ailleurs un intérêt limité. Les neuf variables retenues résultent déjà d'une sélection préalable, conduite à partir des deux études de sensibilité présentées à la section 2.3.6.

3.3.2.3 Le Random Forest

Le Random Forest repose sur l'agrégation d'arbres de décision, dont le mécanisme de construction a été décrit à la section 3.2.2.1. Quatre hyperparamètres principaux interviennent dans sa calibration.

Profondeur maximale des arbres. En l'absence de contrainte, un arbre de décision poursuit la division récursive de l'espace des variables explicatives jusqu'à ce que les régions obtenues deviennent homogènes. Les feuilles terminales peuvent alors ne contenir qu'un très petit nombre d'observations, parfois une seule. La prédiction associée à une telle feuille correspond à la moyenne de ces quelques observations et reproduit donc directement leurs particularités, y compris l'erreur de simulation qui les affecte.

Limiter la profondeur maximale revient à borner le nombre de divisions successives pouvant être appliquées le long d'une branche. La partition de l'espace des variables reste ainsi plus grossière et chaque région conserve un effectif suffisant pour que la moyenne calculée traduise un comportement d'ensemble plutôt qu'une configuration particulière.

Ce paramètre agit directement sur le terme de variance de l'équation (3.26). Une contrainte trop forte conduirait toutefois à un modèle excessivement rigide, incapable de représenter les non-linéarités que la méthode a précisément pour objet de capter.

[Plage testée et valeur retenue.]

Taille minimale des feuilles. Ce paramètre impose qu'une division ne soit acceptée que si chacune des deux régions issues de la séparation contient au moins un nombre minimal d'observations. Il complète la limitation de la profondeur en agissant à un niveau plus local : la profondeur maximale contraint uniformément l'ensemble des branches, tandis que la taille minimale des feuilles s'ajuste à la densité des observations dans chaque zone de l'espace des variables.

Une taille minimale élevée garantit que chaque prédiction repose sur un effectif suffisant. Elle limite ainsi la possibilité pour le modèle d'isoler des configurations particulières dont le comportement s'écarterait de la tendance d'ensemble uniquement du fait de l'erreur de simulation.

[Plage testée et valeur retenue.]

Nombre de variables candidates à chaque division. Le mécanisme de sélection aléatoire des variables décrit à la section 3.2.2.1 est gouverné par un hyperparamètre déterminant le nombre de variables proposées à chaque nœud. Une valeur faible accroît la diversité entre les arbres et réduit leur

corrélation, ce qui renforce l'effet de l'agrégation. Une valeur trop faible prive toutefois fréquemment les arbres des variables les plus déterminantes et dégrade la qualité individuelle de chacun d'eux.

Ce compromis mérite une attention particulière dans le cadre de cette étude. Le modèle ne comporte que neuf variables explicatives, toutes retenues pour leur contribution significative à la variable cible (cf. section 2.3.6). L'espace des variables est donc réduit et ne contient aucune variable négligeable dont l'exclusion serait sans conséquence.

[Plage testée et valeur retenue.]

Nombre d'arbres. Il convient de préciser que le nombre d'arbres B ne constitue pas un paramètre de surapprentissage. La prédiction finale du modèle correspond en effet à une moyenne des prédictions individuelles, conformément à l'équation (3.15). Augmenter B revient à moyenner un nombre plus élevé de réalisations d'un même mécanisme aléatoire, ce qui stabilise la prédiction sans accroître la complexité du modèle.

L'ajout d'arbres supplémentaires réduit ainsi la variance du modèle et ses performances se stabilisent à partir d'un certain seuil. Le choix de B relève donc d'un compromis entre stabilité des résultats et temps de calcul, et non d'un arbitrage entre biais et variance. Cette propriété distingue nettement le Random Forest des méthodes de boosting, pour lesquelles le nombre d'arbres joue au contraire un rôle central.

[Valeur retenue et justification, éventuellement appuyée sur la stabilisation de l'erreur *Out of Bag* présentée à la section 3.3.3.]

3.3.2.4 Le XGBoost

La construction séquentielle décrite à la section 3.2.2.2 modifie profondément la nature du risque de surapprentissage. Chaque nouvel arbre étant ajouté afin de corriger les erreurs résiduelles des arbres précédents, la complexité de l'ensemble s'accroît à chaque itération. Le nombre d'arbres devient donc lui-même un paramètre de complexité, ce qui justifie la mise en place de plusieurs mécanismes de contrôle complémentaires.

Learning rate. Le paramètre η introduit à l'équation (3.20) réduit la contribution de chaque arbre à la prédiction d'ensemble. Il empêche ainsi qu'une correction de forte amplitude, éventuellement construite à partir d'un nombre restreint d'observations, ne soit intégralement intégrée au modèle.

Une valeur faible de η ralentit la convergence et nécessite un nombre d'arbres plus important, mais chaque correction devient plus progressive et le modèle final dépend moins fortement d'observations particulières.

[Plage testée et valeur retenue.]

Nombre d'arbres et arrêt anticipé. Le nombre d'arbres n'est pas fixé a priori mais déterminé à partir des données, au moyen d'un mécanisme d'arrêt anticipé (*early stopping*). À chaque itération t , l'erreur du modèle est évaluée sur un échantillon de validation n'ayant pas servi à la construction des arbres. Cette erreur, notée $L_{\text{val}}(t)$, diminue tant que les arbres successifs apportent une information

généralisable, puis se stabilise et peut finir par augmenter lorsque le modèle commence à ajuster des fluctuations propres à l'échantillon d'apprentissage.

L'itération retenue correspond à celle minimisant cette erreur :

$$t^* = \arg \min_{1 \leq t \leq K_{\max}} L_{\text{val}}(t). \quad (3.29)$$

En pratique, la construction est interrompue dès qu'aucune amélioration n'est constatée pendant un nombre d'itérations consécutives fixé à l'avance, appelé patience. Ce délai évite d'arrêter prématurément l'apprentissage lors d'une stagnation temporaire de l'erreur. Le modèle finalement conservé correspond alors à l'itération t^* et non à la dernière itération construite.

L'échantillon de validation mobilisé à cette fin est prélevé au sein de l'échantillon d'apprentissage, conformément au protocole défini à la section 3.3.1. L'échantillon de test n'intervient à aucun moment dans la détermination du nombre d'arbres.

Ce mécanisme interagit directement avec le *learning rate* : plus η est faible, plus les itérations successives apportent des modifications limitées, et plus la détermination du nombre optimal d'arbres devient précise.

[Nombre maximal d'itérations autorisé, patience retenue et nombre d'arbres finalement conservé.]

Profondeur maximale des arbres. La profondeur maximale est contrainte selon le même principe que pour le Random Forest. Ce paramètre présente toutefois une portée supplémentaire dans le cadre de cette étude, car il détermine l'ordre des interactions que le modèle peut représenter.

Un arbre de profondeur d applique en effet au plus d divisions successives le long d'une branche. Il ne peut donc combiner qu'au maximum d variables pour définir une région de l'espace, et représente ainsi des interactions d'ordre au plus d . Une profondeur de 2 permet de capter des interactions entre deux variables, une profondeur de 3 des interactions entre trois variables, et ainsi de suite.

Ce paramètre doit par conséquent être calibré avec attention. Une profondeur trop faible priverait le modèle de la capacité à représenter les interactions entre variables, alors que l'existence de telles interactions constitue précisément l'une des hypothèses motivant le recours aux méthodes non linéaires (cf. section 3.1.2). Une profondeur trop élevée exposerait à l'inverse le modèle au surapprentissage.

[Plage testée et valeur retenue.]

Sous-échantillonnage des observations et des variables. Un sous-échantillonnage aléatoire est appliqué lors de la construction de chaque arbre, selon deux dimensions. Le premier porte sur les observations : seule une fraction de l'échantillon d'apprentissage, tirée aléatoirement, est utilisée pour construire un arbre donné. Le second porte sur les variables explicatives : seule une fraction d'entre elles est rendue disponible pour déterminer les divisions.

Ces mécanismes introduisent dans le boosting une logique de diversification proche de celle décrite pour le Random Forest à la section 3.2.2.1. Ils évitent que la construction séquentielle ne se concentre systématiquement sur les mêmes observations ou sur les mêmes variables, et réduisent ainsi la dépendance du modèle final à des configurations particulières.

Comme pour le Random Forest, le sous-échantillonnage des variables doit rester modéré compte tenu du nombre restreint de variables explicatives retenues.

[Plages testées et valeurs retenues pour les deux fractions.]

Paramètres de régularisation. Les paramètres γ et λ introduits à l'équation (3.19) complètent ces mécanismes en agissant directement sur la fonction objectif. Le premier pénalise l'ajout de feuilles supplémentaires et limite ainsi la subdivision de l'espace par chaque arbre. Le second contraint l'amplitude des valeurs attribuées aux feuilles et limite donc la portée de chaque correction.

Ces deux paramètres opèrent au niveau de chaque arbre pris individuellement, tandis que l'arrêt anticipé agit au niveau du nombre total d'arbres composant le modèle. Ils sont donc complémentaires.

[Plages testées et valeurs retenues.]

3.3.2.5 Méthode de recherche retenue

La calibration des hyperparamètres du Random Forest et de XGBoost repose sur la validation croisée définie à la section 3.3.1. Chaque configuration candidate est évaluée à partir de l'erreur Err_{CV} de l'équation (3.25), calculée exclusivement au sein de l'échantillon d'apprentissage. La configuration finalement retenue est celle minimisant cette erreur.

Le modèle correspondant est ensuite réestimé sur l'intégralité de l'échantillon d'apprentissage à partir de ces valeurs, puis évalué sur l'échantillon de test.

[Préciser la méthode d'exploration retenue : recherche exhaustive (*grid search*) ou recherche aléatoire (*random search*), nombre de configurations évaluées, nombre de blocs k de la validation croisée et critère d'optimisation retenu.]

Le tableau 3.3 synthétise les valeurs finalement adoptées pour chacun des modèles.

TABLE 3.3 – Hyperparamètres retenus pour chaque modèle

Modèle	Hyperparamètre	Plage testée	Valeur retenue
GLM	Aucun	<i>Sans objet</i>	<i>Sans objet</i>
Random Forest	Nombre d'arbres	[...]	[...]
	Profondeur maximale	[...]	[...]
	Taille minimale des feuilles	[...]	[...]
	Variables par division	[...]	[...]
XGBoost	<i>Learning rate</i> η	[...]	[...]
	Nombre d'arbres	<i>Arrêt anticipé</i>	[...]
	Profondeur maximale	[...]	[...]
	Fraction d'observations	[...]	[...]
	Fraction de variables	[...]	[...]
	γ	[...]	[...]
	λ	[...]	[...]

3.3.3 Diagnostics et validation de l'apprentissage

Les hyperparamètres définis à la section précédente visent à positionner chaque modèle au meilleur compromis entre biais et variance. Il reste à vérifier que cet objectif est effectivement atteint.

Cette section présente les diagnostics mis en œuvre à cette fin. Ils interviennent après l'apprentissage et poursuivent une logique différente de celle des hyperparamètres : il ne s'agit plus de contraindre la complexité des modèles, mais de vérifier que les contraintes retenues produisent le résultat attendu.

3.3.3.1 Courbes d'apprentissage

Les courbes d'apprentissage représentent l'évolution conjointe de l'erreur mesurée sur l'échantillon d'apprentissage et de celle mesurée sur l'échantillon de validation, en fonction du nombre d'arbres ou d'itérations construits.

Leur lecture repose sur la comparaison des deux trajectoires. Les deux erreurs diminuent d'abord conjointement, ce qui traduit un apprentissage effectif de la relation entre les variables explicatives et la cible. L'erreur de validation se stabilise ensuite, puis peut augmenter alors que l'erreur d'apprentissage continue de décroître. Ce point d'inflexion marque le moment à partir duquel le modèle cesse d'apprendre une structure généralisable et commence à ajuster les particularités de l'échantillon d'apprentissage.

Ces courbes fournissent ainsi une représentation directe du compromis formalisé à l'équation (3.26). Elles permettent de vérifier que la calibration retenue place effectivement chaque modèle avant ce point d'inflexion.

Leur interprétation diffère toutefois selon la méthode considérée. Pour XGBoost, elles constituent la représentation directe du mécanisme d'arrêt anticipé décrit à la section 3.3.2 : l'itération t^* de l'équa-

tion (3.29) correspond au minimum de la courbe de validation. Pour le Random Forest, en revanche, une divergence entre les deux courbes n'est pas attendue à mesure que le nombre d'arbres augmente, puisque ce paramètre ne constitue pas un levier de surapprentissage. La courbe de validation doit y décroître puis se stabiliser, ce qui permet de vérifier que le nombre d'arbres retenu est suffisant.

[Insérer les courbes d'apprentissage obtenues et leur commentaire.]

3.3.3.2 Erreur *Out of Bag*

Le mécanisme de bootstrap décrit à la section 3.2.2.1 offre pour le Random Forest une possibilité d'évaluation intégrée au modèle. Chaque arbre étant construit à partir d'un tirage avec remise parmi les n observations d'apprentissage, une partie de ces observations n'est pas retenue pour la construction d'un arbre donné. La probabilité qu'une observation donnée ne soit jamais tirée lors de la constitution d'un échantillon bootstrap vaut :

$$\left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-1} \approx 0,368. \quad (3.30)$$

Environ 37 % des observations se trouvent donc exclues de la construction de chaque arbre. Ces observations, dites *Out of Bag* (OOB), constituent pour cet arbre un échantillon non utilisé lors de l'apprentissage.

En notant $\mathcal{B}_i$ l'ensemble des arbres pour lesquels l'observation i est *Out of Bag*, une prédiction peut être construite en n'agrégeant que ces arbres :

$$\hat{f}_{\text{OOB}}(x_i) = \frac{1}{|\mathcal{B}_i|} \sum_{b \in \mathcal{B}_i} T_b(x_i). \quad (3.31)$$

L'erreur *Out of Bag* correspond alors à l'erreur moyenne obtenue à partir de ces prédictions :

$$\text{Err}_{\text{OOB}} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}_{\text{OOB}}(x_i)). \quad (3.32)$$

Cette mesure fournit une estimation de l'erreur de généralisation sans mobiliser l'échantillon de test, et pour un coût de calcul négligeable puisqu'elle réutilise les arbres déjà construits. Elle permet notamment de vérifier que le nombre d'arbres retenu est suffisant : sa stabilisation indique que l'ajout d'arbres supplémentaires n'apporte plus de gain.

Ce diagnostic demeure propre au Random Forest. Les arbres de XGBoost étant construits séquentiellement sur l'ensemble des observations disponibles, aucun échantillon *Out of Bag* équivalent n'y est défini.

[Insérer l'erreur *Out of Bag* obtenue et son évolution en fonction du nombre d'arbres.]

3.3.3.3 Comparaison des performances en apprentissage et en test

Les indicateurs de performance présentés à la section 3.4 sont calculés à la fois sur l'échantillon d'apprentissage et sur l'échantillon de test, pour chacun des modèles finalement retenus.

Un modèle présentant une performance élevée en apprentissage et nettement dégradée en test manifeste directement un surapprentissage. À l'inverse, un écart réduit entre les deux échantillons indique que le modèle a principalement appris une structure généralisable à l'intérieur du domaine étudié.

L'ampleur attendue de cet écart diffère selon les modèles. Le GLM, fortement contraint, devrait présenter des performances proches sur les deux échantillons. Les méthodes fondées sur les arbres, plus flexibles, sont susceptibles de manifester un écart plus marqué, dont l'ampleur constitue précisément un indicateur de la qualité de la calibration retenue à la section 3.3.2.

Cette comparaison ne constitue toutefois pas une garantie de généralisation au-delà du domaine étudié. Les deux échantillons proviennent en effet de la même grille de configurations et du même portefeuille central. Un modèle peut donc présenter un écart faible entre apprentissage et test tout en restant fortement dépendant des caractéristiques du portefeuille ayant servi à sa construction, conformément à la limite déjà identifiée à la section 3.2.3.

3.3.3.4 Articulation avec la validation externe

L'ensemble de ces diagnostics s'inscrit dans le protocole défini à la section 3.3.1. La recherche des hyperparamètres s'appuie sur une validation croisée réalisée exclusivement au sein de l'échantillon d'apprentissage, l'échantillon de test n'intervenant qu'au moment de l'évaluation finale.

La validation externe, conduite sur la base construite à partir d'un second portefeuille central, constitue le test de robustesse le plus exigeant de l'étude. Les modèles y sont appliqués sans réestimation à des configurations extérieures au domaine ayant servi à leur apprentissage. Elle permet ainsi d'évaluer ce que les diagnostics internes ne peuvent mesurer, à savoir la capacité des modèles à conserver leur pertinence en dehors du portefeuille et des sensibilités retenus pour leur construction.

Le tableau 3.4 synthétise l'ensemble du dispositif.

TABLE 3.4 – Diagnostics et niveaux de validation retenus

Diagnostic	Modèles concernés	Objectif
Courbes d'apprentissage	Random Forest, XG-Boost	Identifier le point à partir duquel le modèle cesse d'apprendre une structure généralisable
Erreur <i>Out of Bag</i>	Random Forest	Estimer l'erreur de généralisation sans mobiliser l'échantillon de test
Comparaison apprentissage / test	Les trois modèles	Mesurer directement l'écart de performance révélateur d'un surapprentissage
Validation externe	Les trois modèles	Évaluer la robustesse des modèles en dehors du portefeuille d'apprentissage

3.4 Critère de performance

3.4.1 Indices retenus

3.4.2 Comparaison des modèles

3.4.3 Lecture des performances

Chapitre 4

Analyse des résultats et rationalisation des écarts

- 4.1 Performance des modèles (test, comparaison GLM / RF / XGBoost, stabilité sur les répétitions)
- 4.2 Explicabilité et hiérarchisation des facteurs d'écart (coefficients du GLM, importances, SHAP, effets non linéaires et interactions)
- 4.3 Validation externe sur le second portefeuille central
- 4.4 Analyse de variation entre deux dates de valorisation

Chapitre 5

Limites, apports et perspectives

5.1 Apports opérationnels et réglementaires

5.2 Limites de l'approche

5.3 Perspectives d'amélioration

Chapitre 6

Conclusion

Annexes